

**PENGARUH VARIASI OVERSAMPLING DAN
KONFIGURASI SVM PADA METODE HOUM
TERHADAP DATA KLASIFIKASI TIDAK SEIMBANG**


TUGAS AKHIR

Diajukan sebagai syarat menyelesaikan jenjang strata Satu
(S-1) di Program Studi Teknik Informatika, Fakultas
Teknologi Industri, Institut Teknologi Sumatera

Oleh:

Rizki Alfariz Ramadhan

122140061



ITERA

**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
INSTITUT TEKNOLOGI SUMATERA
LAMPUNG SELATAN**

2026

LEMBAR PENGESAHAN

Tugas Akhir Sarjana dengan judul "Pengaruh Variasi Oversampling dan Konfigurasi SVM Pada Metode HOUM Terhadap Data Klasifikasi Tidak Seimbang" adalah benar dibuat oleh saya sendiri dan belum pernah dibuat dan diserahkan sebelumnya, baik sebagian ataupun seluruhnya, baik oleh saya ataupun orang lain, baik di Institut Teknologi Sumatera maupun di institusi pendidikan lainnya.

Lampung Selatan, 02-03-2026

Penulis,

Foto 3x4

Rizki Alfariz Ramadhan

NIM 122140061

Diperiksa dan disetujui oleh,
Pembimbing

Tanda Tangan

1. Meida Cahyo Untoro, S.Kom., M.Kom.

NIP. 19890518 201903 1 011

.....

Penguji

Tanda Tangan

1. Andika Setiawan, S.Kom., M.Cs.

NIP. 19911127 2022 03 1 007

.....

2. Eko Dwi Nugroho, S.Kom., M.Cs.

NIP. 19910209 2024 06 1 001

.....

Disahkan oleh,
Koordinator Program Studi Teknik Informatika
Fakultas Teknologi Industri
Institut Teknologi Sumatera

Andika Setiawan, S.Kom., M.Cs.

NIP 19911127 2022 03 1 007

HALAMAN PERNYATAAN ORISINALITAS

Tugas Akhir dengan judul “Pengaruh Variasi Oversampling dan Konfigurasi SVM Pada Metode HOUM Terhadap Data Klasifikasi Tidak Seimbang” adalah karya saya sendiri, dan semua sumber baik yang dikutip maupun dirujuk telah saya nyatakan benar.

Nama : Rizki Alfariz Ramadhan

NIM : 122140061

Tanda Tangan :

Tanggal :

**HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI
TUGAS AKHIR UNTUK KEPENTINGAN AKADEMIS**

Sebagai civitas akademik Institut Teknologi Sumatera, saya yang bertanda tangan di bawah ini:

Nama : Rizki Alfariz Ramadhan

NIM : 122140061

Program Studi : Teknik Informatika

Fakultas : Teknologi Industri

Jenis Karya : Tugas Akhir

demi pengembangan ilmu pengetahuan, menyetujui untuk memberikan kepada Institut Teknologi Sumatera **Hak Bebas Royalti Noneksklusif** (*Non-exclusive Royalty Free Right*) atas karya ilmiah saya yang berjudul:

**Pengaruh Variasi Oversampling dan Konfigurasi SVM Pada Metode HOUM
Terhadap Data Klasifikasi Tidak Seimbang**

beserta perangkat yang ada (jika diperlukan). Dengan Hak Bebas Royalti Noneksklusif ini Institut Teknologi Sumatera berhak menyimpan, mengalihmedia/formatkan, mengelola dalam bentuk pangkalan data (*database*), merawat, dan memublikasikan tugas akhir saya selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik Hak Cipta.

Demikian pernyataan ini saya buat dengan sebenarnya.

Dibuat di : Lampung Selatan

Pada tanggal : 02-03-2026

Yang menyatakan

Rizki Alfariz Ramadhan

KATA PENGANTAR

Puji syukur kehadiran Tuhan Yang Maha Esa atas limpahan rahmat, karunia, serta petunjuk-Nya sehingga penyusunan tugas akhir ini telah terselesaikan dengan baik. Dalam penyusunan tugas akhir ini penulis telah banyak mendapatkan arahan, bantuan, serta dukungan dari berbagai pihak. Oleh karena itu pada kesempatan ini penulis mengucapkan terima kasih kepada:

1. Bapak Prof. Dr. I. Nyoman Pugeg Aryantha selaku Rektor Institut Teknologi Sumatera.
2. Bapak Hadi Teguh Yudistira, S.T., Ph.D. selaku Dekan Fakultas Teknologi Industri.
3. Bapak Andika Setiawan, S. Kom., M. Cs. selaku Ketua Program Studi Teknik Informatika.
4. Bapak Meida Cahyo Untoro, S.Kom., M.Kom. selaku Dosen Pembimbing atas ide, waktu, tenaga, perhatian, dan masukan yang telah disumbangsikan kepada penulis.
5. Teman-teman penulis yang membantu selama masa perkuliahan dan bekerja sama dalam melakukan penelitian tugas akhir yang tidak bisa disebutkan satu persatu.

Akhir kata penulis berharap semoga tugas akhir ini dapat memberikan manfaat bagi kita semua. Penulis menyadari bahwa tugas akhir ini tidak luput dari kekurangan dan kelemahan, dan penulis terbuka untuk menerima saran, kritik, dan masukan.

RINGKASAN

Pengaruh Variasi Oversampling dan Konfigurasi SVM Pada Metode HOUM

Terhadap Data Klasifikasi Tidak Seimbang

Rizki Alfariz Ramadhan

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

ABSTRAK

Pengaruh Variasi Oversampling dan Konfigurasi SVM Pada Metode HOUM

Terhadap Data Klasifikasi Tidak Seimbang

Rizki Alfariz Ramadhan

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Kata Kunci: kunci1, kunci2

ABSTRACT

Comparison

Rizki Alfariz Ramadhan

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Keywords: keywords1, keywords2

DAFTAR ISI

LEMBAR PENGESAHAN	ii
Halaman Pernyataan Orisinalitas	iii
Halaman Persetujuan Publikasi	iv
KATA PENGANTAR	v
RINGKASAN	vi
ABSTRAK	vii
ABSTRACT	viii
DAFTAR ISI	ix
DAFTAR TABEL	xii
DAFTAR GAMBAR	xiii
DAFTAR RUMUS	xiv
DAFTAR KODE	xiv
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Tujuan Penelitian	3
1.4 Batasan Masalah	3
1.5 Manfaat Penelitian	4
1.6 Sistematika Penulisan	4
BAB II TINJAUAN PUSTAKA	6
2.1 Tinjauan Pustaka	6
2.2 Dasar Teori	8
2.2.1 Klasifikasi	8
2.2.2 Ketidakseimbangan Data (<i>Class Imbalance</i>)	9

2.2.3	<i>Oversampling</i>	11
2.2.3.1	SMOTE (<i>Synthetic Minority Over-sampling Technique</i>) ..	11
2.2.3.2	Safe-Level SMOTE	13
2.2.3.3	ADASYN (<i>Adaptive Synthetic Sampling</i>)	14
2.2.4	<i>Undersampling</i>	15
2.2.5	Metode Hibrida (<i>Hybrid Resampling</i>)	16
2.2.6	HOUM (<i>Hybrid Oversampling and Undersampling Method</i>) ...	16
2.2.7	<i>Support Vector Machine</i> (SVM)	18
2.2.8	Metrik Evaluasi	20
2.2.8.1	<i>Recall</i>	20
2.2.8.2	<i>Precision</i>	21
2.2.8.3	G-mean	21
2.2.8.4	ROC-AUC	22
BAB III	METODE PENELITIAN	24
3.1	Alur Penelitian	24
3.2	Penjabaran Langkah Penelitian	25
3.2.1	Identifikasi Masalah	25
3.3	Alat dan Bahan Tugas Akhir	25
3.3.1	Alat	25
3.3.2	Bahan	26
3.4	Ilustrasi Perhitungan Metode	26
BAB IV	HASIL DAN PEMBAHASAN	27
4.1	Penggunaan Dataset	27
4.2	Akuisisi Gambar	27
4.3	Analisis Hasil Penelitian	28
4.4	Pembahasan	29
BAB V	KESIMPULAN DAN SARAN	30
5.1	Kesimpulan	30
5.2	Saran	30
DAFTAR PUSTAKA		31

LAMPIRAN	35
-----------------------	-----------

DAFTAR TABEL

Tabel 3.1 Data <i>dummy</i> Pengujian	26
---	----

DAFTAR GAMBAR

Gambar 2.1	Ilustrasi Distribusi Data Tidak Seimbang	9
Gambar 2.2	Ilustrasi Teknik <i>Oversampling</i>	11
Gambar 2.3	Ilustrasi Teknik <i>Undersampling</i>	15
Gambar 3.1	Alur Penelitian	24

DAFTAR RUMUS

Rumus 2.1	Imbalance Ratio (IR)	10
Rumus 2.2	Pembentukan Sampel Sintetis SMOTE	12
Rumus 2.3	Distribusi Bobot ADASYN	14
Rumus 2.4	Fungsi Keputusan SVM	18
Rumus 2.5	Optimasi SVM Soft Margin	19
Rumus 2.6	Recall (Sensitivity)	20
Rumus 2.7	Precision	21
Rumus 2.8	G-mean (Geometric Mean)	21
Rumus 2.9	True Positive Rate dan False Positive Rate	23

DAFTAR KODE

Kode 4.1 Akuisisi Gambar	28
--------------------------------	----

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi telah mendorong peningkatan pengumpulan dan pemanfaatan data dalam berbagai bidang, mulai dari sektor kesehatan, keuangan, pendidikan, hingga keamanan siber. Data-data tersebut dapat dimanfaatkan untuk membangun model prediktif yang dapat membantu pengambilan keputusan, seperti deteksi penyakit, prediksi kebangkrutan perusahaan, dan identifikasi transaksi penipuan. Oleh karena itu, *machine learning* menjadi pendekatan yang banyak digunakan karena memiliki kemampuan dalam mempelajari pola dari data untuk melakukan klasifikasi atau prediksi pada data baru [1].

Salah satu tantangan utama dalam penerapan *machine learning* adalah ketidakseimbangan distribusi kelas pada dataset (*class imbalance*). *Class imbalance* terjadi ketika jumlah sampel pada satu kelas jauh lebih banyak dibandingkan kelas lainnya, seperti pada kasus deteksi penipuan di mana transaksi normal jauh lebih banyak daripada transaksi tidak normal. Ketidakseimbangan data menyebabkan algoritma klasifikasi cenderung memprioritaskan kelas mayoritas dan mengabaikan kelas minoritas yang seringkali menjadi fokus utama analisis [2]. Penelitian menunjukkan bahwa model yang dilatih pada data tidak seimbang dapat mencapai akurasi tinggi secara keseluruhan, namun gagal mendeteksi kelas minoritas dengan baik [3].

Berbagai teknik telah dikembangkan untuk mengatasi masalah ketidakseimbangan data, yang secara umum terbagi menjadi dua pendekatan yaitu, *oversampling* dan *undersampling*. Teknik *oversampling* seperti SMOTE (*Synthetic Minority Over-sampling Technique*) bekerja dengan menghasilkan sampel sintetis untuk kelas minoritas, sedangkan *undersampling* mengurangi jumlah sampel pada kelas mayoritas [4]. Masing-masing pendekatan memiliki kelemahan, dimana *oversampling* berpotensi menyebabkan *overfitting*, sementara

undersampling berisiko menghilangkan informasi penting dari kelas mayoritas [5]. Untuk mengatasi kelemahan tersebut, Eroglu dan Pir mengusulkan metode HOUM (*Hybrid Oversampling and Undersampling Method*) yang menggabungkan Safe-Level SMOTE untuk *oversampling* dan *Support Vector Machine* (SVM) untuk *undersampling* secara iteratif hingga dataset mencapai keseimbangan [5].

Metode HOUM memanfaatkan SVM untuk mengidentifikasi dan menghapus data kelas mayoritas yang jauh dari *decision boundary*, sehingga data yang tersisa lebih informatif untuk proses klasifikasi. Namun, performa SVM sangat dipengaruhi oleh pemilihan parameter, khususnya nilai *regularization parameter* (C) dan jenis kernel yang digunakan [6]. Selain itu, komponen *oversampling* pada HOUM menggunakan Safe-Level SMOTE yang memiliki karakteristik berbeda dengan teknik *oversampling* lain seperti ADASYN (*Adaptive Synthetic Sampling*). ADASYN menghasilkan lebih banyak sampel sintesis pada area yang sulit diklasifikasikan, berbeda dengan Safe-Level SMOTE yang mempertimbangkan tingkat keamanan dari *nearest neighbor* [7]. Penelitian sebelumnya menunjukkan bahwa pemilihan teknik *oversampling* mempengaruhi hasil klasifikasi, di mana performa SMOTE dan ADASYN bervariasi tergantung pada karakteristik dataset dan algoritma yang digunakan [8].

Berdasarkan uraian tersebut, penelitian ini bertujuan untuk menganalisis pengaruh variasi konfigurasi pada metode HOUM terhadap performa klasifikasi data tidak seimbang. Pada komponen *undersampling*, dilakukan *tuning* parameter C pada SVM dengan nilai 0.1, 0.5, 0.75, 1, 1.5, dan 2.5 serta perbandingan tiga jenis kernel yaitu Linear, RBF (*Radial Basis Function*), dan Polynomial. Pada komponen *oversampling*, dilakukan perbandingan antara HOUM yang menggunakan Safe-Level SMOTE dengan HOUM yang menggunakan ADASYN. Performa klasifikasi dievaluasi menggunakan metrik ROC-AUC, G-mean, *Recall*, *Precision*, dan F1-Score yang sesuai untuk menilai kemampuan model dalam menangani data tidak seimbang. Hasil penelitian ini diharapkan dapat memberikan rekomendasi konfigurasi HOUM yang optimal untuk menangani berbagai skenario ketidakseimbangan data.

1.2 Rumusan Masalah

Berdasarkan latar belakang, permasalahan penelitian dirumuskan sebagai berikut:

1. Bagaimana pengaruh penggunaan teknik oversampling yang berbeda pada metode HOUM terhadap kinerja klasifikasi data tidak seimbang?
2. Bagaimana pengaruh nilai parameter regularisasi (C) pada Support Vector Machine dalam metode HOUM terhadap kemampuan klasifikasi kelas minoritas?
3. Bagaimana pengaruh pemilihan jenis kernel Support Vector Machine terhadap performa metode HOUM pada data klasifikasi tidak seimbang?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah, tujuan dari penelitian adalah sebagai berikut:

1. Menganalisis pengaruh penggunaan teknik oversampling yang berbeda pada metode HOUM terhadap kinerja klasifikasi data tidak seimbang.
2. Menganalisis pengaruh variasi nilai parameter regularisasi (C) Support Vector Machine terhadap kemampuan metode HOUM dalam mengklasifikasikan kelas minoritas.
3. Menganalisis pengaruh pemilihan jenis kernel Support Vector Machine terhadap performa metode HOUM pada data klasifikasi tidak seimbang.

1.4 Batasan Masalah

Adapun batasan masalah dari penelitian agar sesuai dengan yang diharapkan adalah sebagai berikut:

1. Penelitian ini hanya difokuskan pada data klasifikasi tidak seimbang (*imbalanced classification*) dan tidak mencakup permasalahan regresi.
2. Metode penanganan data tidak seimbang yang digunakan dibatasi pada metode *Hybrid Oversampling and Undersampling Method* (HOUM).
3. Teknik *oversampling* yang dianalisis pada metode HOUM dibatasi pada Safe-Level SMOTE dan ADASYN.
4. Proses *undersampling* pada metode HOUM dibatasi menggunakan algoritma

Support Vector Machine (SVM) sebagaimana yang diusulkan pada metode asli HOUM.

5. Analisis pengaruh konfigurasi SVM dibatasi pada pemilihan jenis kernel, yaitu Linear, *Radial Basis Function* (RBF), dan Polynomial, serta variasi nilai parameter regularisasi (C).
6. Nilai parameter regularisasi (C) yang digunakan dalam penelitian ini dibatasi pada nilai 0.1, 0.5, 0.75, 1, 1.5, dan 2.5.
7. Evaluasi performa metode HOUM dibatasi menggunakan metrik ROC-AUC, G-Mean, *Recall*, *Precision*, dan F1-Score.
8. Implementasi metode HOUM dilakukan dalam bentuk sistem simulasi berbasis perangkat lunak menggunakan bahasa pemrograman Python, tanpa melibatkan perangkat keras atau sistem *real-time*.

1.5 Manfaat Penelitian

Adapun manfaat yang diperoleh dari hasil penelitian adalah sebagai berikut:

1. Memberikan pemahaman empiris mengenai pengaruh variasi teknik *oversampling* dan konfigurasi *Support Vector Machine* terhadap kinerja metode HOUM pada data klasifikasi tidak seimbang.
2. Menjadi referensi terkait sensitivitas metode HOUM terhadap pemilihan parameter SVM dan teknik *oversampling*, yang masih terbatas dibahas pada penelitian sebelumnya.
3. Menambah pemahaman dan pengalaman penulis dalam menerapkan konsep *machine learning*, khususnya dalam penanganan data klasifikasi tidak seimbang menggunakan metode hybrid HOUM.

1.6 Sistematika Penulisan

Penulisan tugas akhir disusun secara sistematis ke dalam lima bab yang saling berkaitan. Berikut adalah uraian mengenai isi masing-masing bab.

Bab I Pendahuluan

Pada bab ini menyajikan gambaran umum penelitian yang meliputi latar belakang permasalahan, rumusan masalah, tujuan penelitian, batasan masalah,

manfaat penelitian, serta sistematika penulisan laporan tugas akhir.

Bab II Tinjauan Pustaka

Pada bab ini menguraikan kajian literatur yang berkaitan dengan topik penelitian, mencakup tinjauan terhadap penelitian-penelitian sebelumnya serta landasan teori yang mendasari metode dan konsep yang digunakan dalam penelitian ini.

Bab III Metodologi Penelitian

Pada bab ini menjelaskan secara rinci metodologi yang diterapkan dalam penelitian, meliputi tahapan alur kerja, perangkat dan dataset yang digunakan, metode yang diimplementasikan, serta rancangan skenario pengujian yang akan dilakukan.

Bab IV Hasil dan Pembahasan

Pada bab ini memaparkan hasil penelitian yang diperoleh dari implementasi metode, beserta analisis dan pembahasan terhadap hasil pengujian.

Bab V Penutup

Pada bab ini berisi kesimpulan yang merangkum hasil penelitian berdasarkan tujuan penelitian, serta saran-saran untuk pengembangan dan penyempurnaan pada penelitian selanjutnya.

BAB II

TINJAUAN PUSTAKA

2.1 Tinjauan Pustaka

Penelitian ini disusun berdasarkan kajian terhadap beberapa penelitian terdahulu yang relevan dengan topik penanganan ketidakseimbangan data dalam klasifikasi. Kajian ini bertujuan untuk memahami pendekatan yang telah dikembangkan serta mengidentifikasi celah penelitian yang dapat dieksplorasi lebih lanjut.

Penelitian pertama adalah karya Eroglu dan Pir (2024) yang mengusulkan metode hibrida bernama HOUM (*Hybrid Oversampling and Undersampling Method*) [5]. HOUM mengombinasikan Safe-Level SMOTE untuk *oversampling* kelas minoritas dan SVM untuk *undersampling* kelas mayoritas dalam proses iteratif. Pada setiap iterasi, SVM dilatih untuk membentuk *decision boundary*, kemudian data mayoritas yang jauh dari *hyperplane* dihapus dan data minoritas ditambahkan di posisi yang aman. Pengujian pada delapan dataset dari UCI *Machine Learning Repository* menunjukkan bahwa HOUM mengungguli metode pembandingan seperti SMOTE, SMOTEENN, SMOTETomek, W-SIMO, dan RusAda pada metrik G-mean dan ROC-AUC [5]. Namun, penelitian tersebut hanya menggunakan konfigurasi *default* pada komponen SVM tanpa mengkaji pengaruh variasi parameter C dan jenis kernel.

Penelitian kedua berasal dari Taskiran *et al.* (2025) yang mengevaluasi 31 teknik *oversampling* untuk klasifikasi teks [4]. Evaluasi dilakukan pada dataset TREC dan Emotions menggunakan enam algoritma klasifikasi dengan representasi teks MiniLMv2. Teknik yang diuji meliputi SMOTE beserta 30 variannya, termasuk Borderline-SMOTE dan ADASYN. Hasil pengujian dengan metrik F1-Score dan *Balanced Accuracy* menunjukkan bahwa tidak ada satu teknik *oversampling* yang secara konsisten unggul di semua kondisi. Efektivitas teknik sangat bergantung pada karakteristik distribusi data dan algoritma klasifikasi yang digunakan [4].

Penelitian ketiga merupakan karya Hou *et al.* (2025) yang membandingkan

delapan teknik *resampling* untuk prediksi *financial distress* menggunakan XGBoost [2]. Teknik yang diuji meliputi SMOTE, ADASYN, Borderline-SMOTE, Tomek Links, *Random Under-Sampling*, SMOTE-Tomek, SMOTE-ENN, dan Bagging-SMOTE. Hasil eksperimen menunjukkan bahwa SMOTE mencapai F1-score tertinggi sebesar 0,73 dengan MCC 0,70, sedangkan Bagging-SMOTE memperoleh F1-score 0,72 dengan AUC 0,96. *Random Under-Sampling* menghasilkan *recall* tinggi (0,85) namun *precision* rendah (0,46), sehingga kurang tepat untuk kasus yang memerlukan keseimbangan kedua metrik [2]. Temuan ini memperkuat argumen bahwa teknik *undersampling* acak berpotensi menurunkan kualitas data pelatihan.

Penelitian keempat diambil dari Tariq *et al.* (2023) yang menguji metode *oversampling* pada dataset pendidikan bertipe *multi-class* [8]. Metode yang diuji meliputi SMOTE, ADASYN, Borderline-SMOTE, dan SMOTETomek yang dikombinasikan dengan sepuluh algoritma klasifikasi. Hasil pengujian menunjukkan bahwa kombinasi SMOTETomek dengan KNN mencapai akurasi tertinggi sebesar 83,7%. Temuan ini mengindikasikan bahwa pendekatan hibrida yang menggabungkan *oversampling* dengan pembersihan data memberikan hasil lebih baik dibandingkan *oversampling* tunggal [8]. Penelitian tersebut juga menunjukkan bahwa pemilihan algoritma klasifikasi turut memengaruhi efektivitas teknik *oversampling* yang diterapkan.

Penelitian kelima adalah karya Van FC *et al.* (2024) yang menerapkan SMOTE dan *random undersampling* pada klasifikasi sentimen media sosial menggunakan SVM [3]. Dataset yang digunakan berasal dari platform Twitter terkait Pemilu 2024 dengan distribusi kelas yang tidak seimbang. Tiga variasi kernel SVM diuji, yaitu Linear, RBF, dan Polynomial. Hasil percobaan menunjukkan bahwa SMOTE mampu meningkatkan akurasi SVM hingga 91%, khususnya pada kernel Polynomial yang menunjukkan peningkatan paling signifikan [3]. Sebaliknya, teknik *random undersampling* tidak memberikan peningkatan yang berarti pada seluruh variasi kernel yang diuji.

Berdasarkan tinjauan terhadap kelima penelitian tersebut, dapat diidentifikasi bahwa teknik *resampling* hibrida secara umum mampu meningkatkan performa klasifikasi pada data tidak seimbang. Namun demikian, terdapat celah penelitian

yang belum dieksplorasi. Pertama, HOUM yang diusulkan oleh Eroglu dan Pir hanya menggunakan konfigurasi *default* pada komponen SVM tanpa mengkaji pengaruh variasi parameter C dan jenis kernel [5]. Kedua, komponen *oversampling* pada HOUM hanya menggunakan Safe-Level SMOTE tanpa membandingkannya dengan teknik adaptif seperti ADASYN. Oleh karena itu, penelitian ini mengisi celah tersebut melalui variasi parameter C pada SVM (0.1, 0.5, 0.75, 1, 1.5, dan 2.5), perbandingan tiga jenis kernel (Linear, RBF, dan Polynomial), serta komparasi Safe-Level SMOTE dan ADASYN sebagai komponen *oversampling* pada HOUM.

2.2 Dasar Teori

Berikut ini merupakan dasar teori yang digunakan pada penelitian ini:

2.2.1 Klasifikasi


Klasifikasi merupakan salah satu tugas fundamental dalam *machine learning* yang bertujuan untuk memetakan data masukan ke dalam kategori atau kelas yang telah ditentukan sebelumnya [9]. Model klasifikasi dibangun melalui proses pelatihan menggunakan dataset berlabel, di mana algoritma mempelajari hubungan antara fitur masukan dan kelas keluaran. Setelah proses pelatihan selesai, model yang dihasilkan dapat digunakan untuk memprediksi kelas dari data baru yang tidak terdapat dalam dataset pelatihan. Tahapan utama dalam klasifikasi meliputi prapemrosesan data, ekstraksi fitur, pemilihan algoritma, pelatihan model, serta validasi menggunakan data uji [9], [10]. Kualitas hasil klasifikasi dipengaruhi secara signifikan oleh representasi fitur yang digunakan dan kesesuaian algoritma terhadap karakteristik dataset.

Berdasarkan jumlah kelas keluaran, klasifikasi dibedakan menjadi dua jenis utama, yaitu klasifikasi *binary* yang melibatkan dua kelas dan klasifikasi *multi-class* yang melibatkan lebih dari dua kelas [9]. Klasifikasi *binary* banyak diterapkan pada permasalahan seperti deteksi penipuan, diagnosis penyakit, dan deteksi intrusi jaringan yang memerlukan pemisahan antara kelas positif dan negatif [11]. Klasifikasi *multi-class* diterapkan pada pengenalan karakter tulisan tangan, analisis sentimen multi-kategori, dan klasifikasi citra [12]. Beberapa algoritma

klasifikasi yang banyak digunakan meliputi *Decision Tree*, *K-Nearest Neighbors* (KNN), *Naive Bayes*, *Random Forest*, dan *Support Vector Machine* (SVM) [6]. Pemilihan algoritma yang tepat menjadi faktor krusial yang menentukan akurasi dan kemampuan generalisasi model klasifikasi [12].

2.2.2 Ketidakseimbangan Data (*Class Imbalance*)

He dan Garcia (2009) mendefinisikan *imbalanced learning* sebagai permasalahan yang muncul ketika distribusi kelas dalam dataset pelatihan tidak seimbang, sehingga performa algoritma klasifikasi standar menjadi terganggu [11]. Kelas dengan jumlah sampel lebih banyak disebut kelas mayoritas, sedangkan kelas dengan jumlah sampel lebih sedikit disebut kelas minoritas. Rasio ketidakseimbangan antar kelas dapat bervariasi dari 100:1, 1.000:1, hingga 10.000:1, di mana satu kelas secara signifikan mendominasi kelas lainnya [11]. Kondisi ini banyak ditemui pada dataset dunia nyata seperti deteksi penipuan kartu kredit, diagnosis penyakit langka, deteksi intrusi jaringan, dan klasifikasi citra biomedis [13], [14]. Semakin tinggi rasio ketidakseimbangan, semakin sulit bagi algoritma klasifikasi konvensional untuk mempelajari pola kelas minoritas secara efektif [15].



Gambar 2.1 Ilustrasi Distribusi Data Tidak Seimbang

Algoritma klasifikasi standar pada umumnya dirancang untuk meminimalkan kesalahan klasifikasi secara keseluruhan tanpa memperhatikan distribusi kelas [16].

Chawla *et al.* (2002) menyatakan bahwa metrik akurasi tidak tepat digunakan pada data tidak seimbang karena strategi sederhana berupa prediksi seluruh data ke kelas mayoritas sudah dapat menghasilkan akurasi yang tinggi [16]. He dan Garcia (2009) memberikan contoh pada dataset mammografi yang berisi 10.923 sampel negatif dan 260 sampel positif, di mana klasifier cenderung menghasilkan akurasi mendekati 100% pada kelas mayoritas namun hanya 0-10% pada kelas minoritas [11]. Konsekuensi dari bias semacam ini dapat sangat merugikan pada domain seperti kedokteran, di mana kegagalan mendeteksi pasien sakit jauh lebih berbahaya daripada kesalahan diagnosis sebaliknya [11]. Oleh karena itu, diperlukan metrik evaluasi yang lebih informatif seperti kurva ROC, *precision-recall*, dan *cost curves* untuk menilai performa model secara komprehensif [11], [17].

Tingkat ketidakseimbangan pada suatu dataset dapat diukur menggunakan *imbalance ratio* (IR), yaitu perbandingan antara jumlah sampel kelas mayoritas dengan jumlah sampel kelas minoritas sebagaimana ditunjukkan pada Rumus 2.1.

$$IR = \frac{N_{majority}}{N_{minority}}$$

Rumus 2.1 Imbalance Ratio (IR)

Keterangan:


$N_{majority}$ = jumlah sampel kelas mayoritas

$N_{minority}$ = jumlah sampel kelas minoritas

He dan Garcia (2009) mengklasifikasikan pendekatan penanganan data tidak seimbang ke dalam empat kategori utama [11]. Kategori pertama adalah metode *sampling* yang memodifikasi distribusi dataset melalui teknik *oversampling* atau *undersampling* untuk menyeimbangkan representasi kelas. Kategori kedua adalah *cost-sensitive learning* yang menetapkan biaya berbeda untuk kesalahan klasifikasi pada masing-masing kelas, sehingga kesalahan pada kelas minoritas mendapat penalti yang lebih besar [11]. Kategori ketiga adalah metode berbasis kernel yang memodifikasi matriks kernel untuk mengakomodasi ketidakseimbangan distribusi data [11]. Kategori keempat adalah *active learning* yang secara selektif memilih sampel paling informatif untuk pelabelan guna mengurangi biaya komputasi pada dataset tidak seimbang yang besar [11].

2.2.3 Oversampling

Oversampling merupakan teknik penanganan data tidak seimbang pada level data yang bekerja dengan cara menambah jumlah sampel pada kelas minoritas hingga distribusi antar kelas menjadi lebih seimbang. Bunkhumpornpat *et al.* (2009) menjelaskan bahwa teknik *re-sampling* paling sederhana adalah *random oversampling* yang menduplikasi sampel kelas minoritas secara acak hingga kedua kelas memiliki representasi yang setara [7]. Namun, teknik ini berpotensi menyebabkan *overfitting* karena area keputusan yang dihasilkan menjadi lebih sempit dan spesifik akibat duplikasi data identik [7]. Untuk mengatasi keterbatasan tersebut, dikembangkan teknik *oversampling* berbasis sintesis yang menghasilkan sampel baru melalui interpolasi antar data minoritas yang sudah ada [16]. Kovács (2019) melakukan perbandingan empiris terhadap 85 teknik *oversampling* minoritas pada 104 dataset dan menemukan bahwa teknik sintesis data secara signifikan mengungguli *random oversampling* dalam berbagai skenario klasifikasi [1], [18].



Gambar 2.2 Ilustrasi Teknik *Oversampling*

2.2.3.1 SMOTE (*Synthetic Minority Over-sampling Technique*)

SMOTE merupakan teknik *oversampling* yang diusulkan oleh Chawla *et al.* (2002) dengan pendekatan menghasilkan sampel sintetis kelas minoritas melalui

interpolasi antar sampel yang sudah ada [16]. Chawla *et al.* menyatakan bahwa SMOTE bekerja dengan mengambil setiap sampel kelas minoritas, kemudian menghasilkan data sintetis di sepanjang segmen garis yang menghubungkan sampel tersebut dengan k tetangga terdekatnya dari kelas yang sama [16]. Pendekatan ini menghasilkan area keputusan yang lebih luas dan umum dibandingkan *random oversampling* yang hanya menduplikasi data identik [16]. Elreedy dan Atiya (2019) mencatat bahwa SMOTE telah menjadi salah satu teknik penanganan data tidak seimbang yang paling dominan dalam literatur dan menjadi fondasi bagi pengembangan lebih dari 85 varian [18], [19]. Proses pembentukan sampel sintetis secara matematis ditunjukkan pada Rumus 2.2.

$$x_{new} = x_i + \lambda \times (x_{nn} - x_i)$$

Rumus 2.2 Pembentukan Sampel Sintetis SMOTE

Keterangan:

x_{new} = sampel sintetis baru

x_i = sampel kelas minoritas

x_{nn} = tetangga terdekat yang dipilih

λ = bilangan acak dalam rentang [0, 1]

Bunkhumpornpat *et al.* (2009) mengidentifikasi bahwa SMOTE memiliki kelemahan berupa masalah *overgeneralization*, yaitu SMOTE secara buta memperluas area kelas minoritas tanpa mempertimbangkan keberadaan kelas mayoritas di sekitarnya [7]. Strategi ini menjadi problematik pada distribusi kelas yang sangat timpang karena kelas minoritas tersebar sangat jarang di antara kelas mayoritas, sehingga peluang tercampurnya kedua kelas menjadi lebih besar [7]. Han *et al.* (2005) juga mengamati bahwa sampel sintetis yang dihasilkan di area *noise* atau di dalam wilayah kelas mayoritas dapat mengaburkan batas keputusan dan menurunkan performa klasifikasi [20]. Kelemahan-kelemahan ini mendorong pengembangan berbagai varian SMOTE seperti Borderline-SMOTE yang hanya melakukan interpolasi pada sampel di area perbatasan, Safe-Level SMOTE yang mempertimbangkan tingkat keamanan posisi interpolasi, dan ADASYN yang mendistribusikan sampel sintetis secara adaptif [7], [20], [21]. Tarawneh *et al.* (2022) menambahkan bahwa sensitivitas SMOTE terhadap *outlier* juga menjadi

perhatian utama karena sampel minoritas yang merupakan *outlier* tetap dijadikan basis interpolasi [22].

2.2.3.2 Safe-Level SMOTE

Safe-Level SMOTE merupakan pengembangan dari SMOTE yang diusulkan oleh Bunkhumpornpat *et al.* (2009) untuk mengatasi masalah pembentukan sampel sintetis di area yang tidak aman [7]. Konsep utama metode ini adalah memberikan setiap sampel kelas minoritas suatu nilai *safe level* sebelum proses sintesis dilakukan. Bunkhumpornpat *et al.* mendefinisikan *safe level* sebagai jumlah tetangga terdekat yang berasal dari kelas minoritas yang sama [7]. Sampel dengan *safe level* mendekati k menandakan bahwa sampel tersebut berada di area yang aman dan didominasi oleh kelasnya sendiri. Sebaliknya, sampel dengan *safe level* mendekati 0 mengindikasikan sampel yang mendekati *noise* karena dikelilingi oleh kelas mayoritas [7].

Penempatan sampel sintetis ditentukan oleh *safe level ratio* antara sampel asli p dan tetangga n yang dihitung sebagai sl_p/sl_n [7]. Bunkhumpornpat *et al.* mendefinisikan lima kasus berdasarkan nilai rasio ini. Apabila rasio bernilai tak hingga dan *safe level* keduanya nol, maka keduanya dianggap *noise* dan sampel sintetis tidak dihasilkan. Apabila rasio bernilai tak hingga namun *safe level* p bukan nol, maka sampel sintetis dihasilkan dengan menduplikasi p untuk menjauhi tetangga yang merupakan *noise*. Apabila rasio bernilai 1, sampel sintetis ditempatkan di posisi acak sepanjang garis antara p dan n karena keduanya memiliki tingkat keamanan yang setara [7]. Apabila rasio lebih besar dari 1, sampel sintetis ditempatkan lebih dekat ke p yang lebih aman, dan sebaliknya apabila rasio kurang dari 1, sampel ditempatkan lebih dekat ke n [7]. Hasil eksperimen Bunkhumpornpat *et al.* menunjukkan bahwa Safe-Level SMOTE menghasilkan akurasi yang lebih baik dibandingkan SMOTE dan Borderline-SMOTE pada berbagai dataset pengujian [7].

2.2.3.3 ADASYN (*Adaptive Synthetic Sampling*)

ADASYN merupakan teknik *oversampling* adaptif yang diusulkan oleh He *et al.* (2008) dengan ide utama menggunakan distribusi berbobot untuk sampel kelas minoritas berdasarkan tingkat kesulitan dalam proses klasifikasi [21]. He *et al.* menjelaskan bahwa ADASYN menghasilkan lebih banyak data sintetis untuk sampel kelas minoritas yang lebih sulit dipelajari dibandingkan sampel yang lebih mudah [21]. Pendekatan ini mempunyai dua tujuan: mengurangi bias yang ditimbulkan oleh ketidakseimbangan distribusi kelas, dan secara adaptif menggeser batas keputusan ke arah sampel yang sulit diklasifikasikan [21]. Tahap pertama ADASYN menghitung derajat ketidakseimbangan $d = m_s/m_l$ dan total sampel sintetis yang diperlukan $G = (m_l - m_s) \times \beta$, di mana $\beta \in [0, 1]$ menentukan tingkat keseimbangan yang diinginkan [21]. Distribusi bobot yang menentukan jumlah sampel sintetis untuk setiap sampel kelas minoritas dihitung sebagaimana ditunjukkan pada Rumus 2.3.

$$\hat{r}_i = \frac{r_i}{\sum_{i=1}^{m_s} r_i}, \quad r_i = \frac{\Delta_i}{k}$$

Rumus 2.3 Distribusi Bobot ADASYN

Keterangan:

$\hat{r}_i$ = bobot ternormalisasi sampel x_i

Δ_i = jumlah tetangga dari kelas mayoritas

k = jumlah tetangga terdekat


m_s = total sampel kelas minoritas

Jumlah sampel sintetis untuk setiap x_i dihitung menggunakan formula $g_i = \hat{r}_i \times G$, di mana G menyatakan total sampel yang perlu ditambahkan agar distribusi kelas menjadi seimbang [21]. He *et al.* menjelaskan bahwa $\hat{r}_i$ secara fisik merupakan pengukuran distribusi bobot untuk berbagai sampel kelas minoritas berdasarkan tingkat kesulitannya dalam proses pembelajaran [21]. Sampel dengan nilai $\hat{r}_i$ lebih tinggi berarti dikelilingi oleh lebih banyak tetangga kelas mayoritas sehingga lebih sulit diklasifikasikan dan memperoleh lebih banyak data sintetis [21]. Setiap sampel sintetis dibentuk melalui interpolasi $s_i = x_i + (x_{zi} - x_i) \times \lambda$ dengan $\lambda \in [0, 1]$ dan x_{zi} merupakan tetangga minoritas yang dipilih secara acak [21]. Namun, Elreedy dan Atiya (2019) mencatat bahwa ADASYN juga berpotensi menghasilkan data sintetis

di area *noise* apabila sampel minoritas yang menjadi acuan merupakan *outlier* yang dikelilingi oleh kelas mayoritas [19].

2.2.4 Undersampling

Undersampling merupakan teknik penanganan data tidak seimbang yang bekerja dengan cara mengurangi jumlah sampel pada kelas mayoritas hingga distribusi antar kelas menjadi lebih proporsional. Bunkhumpornpat *et al.* (2009) menyatakan bahwa *random undersampling* menghapus sampel kelas mayoritas secara acak hingga kedua kelas memiliki jumlah yang setara, namun teknik ini berpotensi menghilangkan informasi penting dari dataset [7]. Elreedy dan Atiya (2019) juga mencatat bahwa *undersampling* bersifat berisiko karena informasi penting yang potensial dapat hilang dari proses penghapusan [19]. Untuk mengatasi risiko tersebut, dikembangkan teknik *undersampling* yang lebih terstruktur berdasarkan aturan heuristik tertentu. Beberapa teknik yang banyak digunakan antara lain Tomek Links, *Edited Nearest Neighbors* (ENN), *condensed nearest neighbor rule*, dan *one-sided selection* [19], [23].



Gambar 2.3 Ilustrasi Teknik *Undersampling*

2.2.5 Metode Hibrida (*Hybrid Resampling*)

Metode hibrida merupakan pendekatan penanganan data tidak seimbang yang menggabungkan teknik *oversampling* dan *undersampling* dalam satu kerangka kerja untuk memanfaatkan kelebihan keduanya secara simultan. He dan Garcia (2009) menjelaskan bahwa komunitas *machine learning* menangani permasalahan ketidakseimbangan kelas melalui dua cara utama: memberikan biaya berbeda pada setiap sampel pelatihan, atau melakukan *re-sampling* melalui *oversampling* kelas minoritas dan/atau *undersampling* kelas mayoritas [11]. Chawla *et al.* (2002) menunjukkan bahwa kombinasi *oversampling* kelas minoritas menggunakan SMOTE dengan *undersampling* kelas mayoritas menghasilkan performa klasifikasi yang lebih baik dalam ruang ROC dibandingkan penggunaan *undersampling* tunggal [16]. Penggabungan kedua teknik bertujuan menghasilkan dataset yang seimbang tanpa kehilangan informasi penting dari kelas mayoritas maupun menciptakan *overfitting* pada kelas minoritas. Pendekatan ini telah terbukti efektif pada berbagai domain aplikasi.

Batista *et al.* (2004) memperkenalkan dua kombinasi hibrida yang paling banyak dirujuk dalam literatur, yaitu SMOTETomek dan SMOTEENN [23]. SMOTETomek mengombinasikan SMOTE untuk menambah sampel kelas minoritas dengan Tomek Links untuk menghapus pasangan sampel yang saling berdekatan dari kelas berbeda. SMOTEENN mengombinasikan SMOTE dengan *Edited Nearest Neighbors* yang membersihkan sampel yang salah diklasifikasikan oleh tetangga terdekatnya. Batista *et al.* menunjukkan melalui eksperimen pada 13 dataset bahwa SMOTETomek dan SMOTEENN secara konsisten menghasilkan performa yang lebih baik dibandingkan SMOTE atau *random undersampling* secara terpisah [23]. Temuan serupa juga dilaporkan oleh Hou *et al.* (2025) pada domain prediksi *financial distress* yang mengonfirmasi keunggulan pendekatan hibrida dibandingkan teknik tunggal [2].

2.2.6 HOUM (*Hybrid Oversampling and Undersampling Method*)

HOUM merupakan metode penanganan data tidak seimbang yang dirancang oleh Eroglu dan Pir (2024) dengan mengombinasikan Safe-Level SMOTE untuk *oversampling* dan SVM untuk *undersampling* secara iteratif [5]. Metode ini

dikembangkan untuk mengatasi kelemahan penggunaan teknik *resampling* tunggal yang seringkali tidak mampu menghasilkan distribusi data yang optimal pada dataset dengan rasio ketidakseimbangan tinggi. Komponen Safe-Level SMOTE bertugas menambah sampel kelas minoritas di area yang aman berdasarkan perhitungan *safe level*, sehingga sampel sintetis tidak terbentuk di wilayah yang didominasi kelas mayoritas. Komponen SVM bertugas menghapus sampel kelas mayoritas yang memiliki kontribusi rendah terhadap pembentukan *decision boundary*, yaitu sampel yang berada jauh dari *hyperplane* pemisah. Kombinasi keduanya menghasilkan distribusi data yang lebih representatif dibandingkan penggunaan masing-masing teknik secara terpisah [5].

Proses kerja HOUM dimulai dengan perhitungan *imbalance ratio* pada dataset untuk menentukan apakah proses penyeimbangan perlu dilakukan [5]. Apabila distribusi kelas belum mencapai keseimbangan yang ditentukan, algoritma menjalankan dua tahap secara bergantian dalam setiap iterasi. Pada tahap pertama, SVM dilatih menggunakan dataset yang tersedia kemudian data kelas mayoritas yang berada di luar batas *margin* dihapus karena dianggap kurang informatif. Pada tahap kedua, Safe-Level SMOTE digunakan untuk menambah sampel kelas minoritas di posisi yang dianggap aman berdasarkan komposisi tetangga terdekat. Kedua tahap tersebut diulang secara iteratif hingga rasio antara kelas mayoritas dan kelas minoritas mencapai keseimbangan yang diharapkan [5].

Pendekatan iteratif pada HOUM memberikan keunggulan karena *decision boundary* SVM diperbarui pada setiap putaran berdasarkan distribusi data terkini, sehingga pemilihan data yang dihapus menjadi semakin tepat pada iterasi berikutnya [5]. Safe-Level SMOTE yang dijalankan pada setiap iterasi juga dapat menyesuaikan posisi dan jumlah sampel sintetis sesuai dengan kebutuhan distribusi terbaru. Pengujian yang dilakukan oleh Eroglu dan Pir pada delapan dataset dari UCI *Machine Learning Repository* menunjukkan bahwa HOUM mampu mengungguli metode pembanding seperti SMOTE, SMOTEENN, SMOTETomek, W-SIMO, dan RusAda [5]. Hasil eksperimen menunjukkan peningkatan yang konsisten pada metrik G-mean dan ROC-AUC, yang mengonfirmasi kemampuan HOUM dalam menyeimbangkan performa klasifikasi pada kedua kelas secara bersamaan [5].

2.2.7 Support Vector Machine (SVM)

SVM merupakan algoritma klasifikasi yang pertama kali diperkenalkan oleh Cortes dan Vapnik (1995) dan telah menjadi salah satu metode yang paling banyak digunakan dalam *machine learning* karena kemampuannya dalam menangani data berdimensi tinggi dan menghasilkan *decision boundary* yang optimal [6]. Ide dasar SVM adalah mencari *hyperplane* pemisah yang memaksimalkan margin antara dua kelas, di mana margin didefinisikan sebagai jarak terpendek antara *hyperplane* dengan sampel data terdekat dari masing-masing kelas. *Hyperplane* tersebut merupakan bidang pemisah berdimensi $n - 1$ dalam ruang fitur berdimensi n yang memisahkan data dari dua kelas yang berbeda. Data yang terletak paling dekat dengan *hyperplane* dan menentukan posisi serta orientasinya disebut sebagai *support vectors* [6], [12]. Fungsi keputusan SVM untuk klasifikasi *binary* dapat dirumuskan sebagaimana ditunjukkan pada Rumus 2.4.

$$f(x) = \text{sign}(w \cdot x + b)$$

Rumus 2.4 Fungsi Keputusan SVM

Keterangan:

$f(x)$ = hasil prediksi kelas

w = vektor bobot

x = vektor fitur masukan

b = bias

Pada banyak permasalahan nyata, data tidak selalu dapat dipisahkan secara linear dalam ruang fitur aslinya karena distribusi data seringkali bersifat nonlinear [6]. Untuk menangani kasus tersebut, SVM menggunakan *kernel trick* yang memetakan data ke ruang fitur berdimensi lebih tinggi di mana data menjadi separabel secara linear. Fungsi kernel menghitung *dot product* pada ruang berdimensi tinggi tanpa perlu melakukan transformasi secara eksplisit, sehingga komputasi tetap efisien meskipun dimensi ruang transformasi sangat besar [6], [12]. Cervantes *et al.* (2020) mengidentifikasi bahwa pemilihan kernel yang tepat merupakan salah satu faktor kunci yang menentukan performa SVM pada berbagai domain aplikasi [6]. Tiga jenis kernel yang umum digunakan adalah sebagai berikut:

1. **Kernel Linear:** $K(x_i, x_j) = x_i \cdot x_j$
2. **Kernel RBF:** $K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$
3. **Kernel Polynomial:** $K(x_i, x_j) = (x_i \cdot x_j + c)^d$

Parameter regularisasi C pada SVM berfungsi mengontrol keseimbangan antara lebar margin dan toleransi kesalahan klasifikasi pada data pelatihan [6]. Nilai C yang kecil menghasilkan margin yang lebih lebar dan memperbolehkan lebih banyak kesalahan klasifikasi sehingga model kurang rentan terhadap *overfitting*. Sebaliknya, nilai C yang besar menghasilkan margin yang lebih sempit dan berusaha meminimalkan setiap kesalahan pada data pelatihan, namun berisiko *overfitting* [6], [24]. Pemilihan nilai C yang tepat sangat penting karena berpengaruh langsung terhadap kemampuan generalisasi model terhadap data yang belum pernah ditemui. Formulasi optimasi *soft margin* SVM yang mengakomodasi kesalahan klasifikasi melalui variabel *slack* ditunjukkan pada Rumus 2.5.

$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i$$

Rumus 2.5 Optimasi SVM Soft Margin

Keterangan:

w = vektor bobot

C = parameter regularisasi

ξ_i = variabel *slack* (kesalahan klasifikasi sampel i)

n = jumlah sampel

SVM terbukti efektif pada data berdimensi tinggi dan telah banyak diterapkan pada berbagai domain seperti pengenalan wajah, diagnosis penyakit, analisis sentimen, dan deteksi intrusi jaringan [12]. Namun, SVM standar memiliki keterbatasan dalam menangani data tidak seimbang karena fungsi optimasinya cenderung menghasilkan *hyperplane* yang bias terhadap kelas mayoritas [24], [25]. Tang *et al.* (2009) mengidentifikasi bahwa pada data tidak seimbang, *support vectors* lebih banyak berasal dari kelas mayoritas sehingga *hyperplane* bergeser ke arah kelas minoritas [25]. Rezvani *et al.* (2024) mengategorikan pendekatan SVM untuk menangani data tidak seimbang ke dalam tiga kelompok, yaitu metode *re-sampling*, metode algoritmik, dan metode fusi, yang masing-masing berupaya

mengatasi bias melalui mekanisme yang berbeda [24]. Berbagai modifikasi SVM untuk data tidak seimbang terus dikembangkan guna meningkatkan kemampuan algoritma ini dalam mengklasifikasikan kedua kelas secara berimbang [24].

2.2.8 Metrik Evaluasi

Metrik evaluasi merupakan ukuran kuantitatif yang digunakan untuk menilai seberapa baik model klasifikasi mampu melakukan prediksi terhadap data uji [26]. Sokolova dan Lapalme (2009) menyatakan bahwa pemilihan metrik evaluasi yang tepat bergantung pada karakteristik permasalahan dan tujuan klasifikasi yang ingin dicapai [26]. Pada domain data tidak seimbang, dibutuhkan metrik yang mampu mengukur performa model pada setiap kelas secara terpisah sehingga kemampuan model dalam mengenali kelas minoritas dapat terlihat dengan jelas [27]. Fawcett (2006) menekankan bahwa teknik evaluasi berbasis kurva ROC menjadi standar untuk merangkum performa klasifikasi pada berbagai titik operasi [17]. Beberapa metrik yang umum digunakan untuk mengevaluasi performa klasifikasi pada data tidak seimbang antara lain *Recall*, *Precision*, G-mean, dan ROC-AUC [26], [28].

2.2.8.1 Recall

Recall atau *sensitivity* merupakan metrik yang mengukur proporsi sampel positif yang berhasil dideteksi oleh model dari keseluruhan sampel positif yang sebenarnya ada dalam dataset [27]. Metrik ini sangat penting pada data tidak seimbang karena menunjukkan kemampuan model dalam mengenali kelas minoritas yang seringkali menjadi target deteksi utama. Nilai *Recall* yang rendah menandakan bahwa model banyak melewatkan sampel positif yang seharusnya terdeteksi, yang disebut sebagai *False Negative*. Pada kasus seperti diagnosis penyakit, nilai *Recall* yang rendah bermakna banyak pasien sakit yang tidak terdiagnosis sehingga dapat berakibat fatal [17], [26]. Rumus *Recall* ditunjukkan pada Rumus 2.6.

$$Recall = \frac{TP}{TP + FN}$$

Rumus 2.6 Recall (Sensitivity)

Keterangan:

$TP = \text{True Positive}$, $FN = \text{False Negative}$

2.2.8.2 Precision

Precision merupakan metrik yang mengukur proporsi prediksi positif yang benar-benar merupakan sampel positif dari keseluruhan data yang diprediksi sebagai positif oleh model [27]. Metrik ini menunjukkan seberapa akurat model ketika memberikan label positif pada suatu data, yang penting untuk menilai tingkat kepercayaan terhadap prediksi positif. Nilai *Precision* yang rendah menandakan bahwa model menghasilkan banyak *false alarm* atau prediksi positif yang salah sehingga mengurangi kepercayaan terhadap hasil prediksi. Pada konteks deteksi penipuan kartu kredit, nilai *Precision* yang rendah berarti banyak transaksi sah yang salah ditandai sebagai penipuan dan memerlukan investigasi tambahan yang tidak perlu [26], [28]. Rumus *Precision* ditunjukkan pada Rumus 2.7.

$$Precision = \frac{TP}{TP + FP}$$

Rumus 2.7 Precision

Keterangan:

$TP = \text{True Positive}$, $FP = \text{False Positive}$

2.2.8.3 G-mean

G-mean atau *Geometric Mean* merupakan metrik yang mengukur keseimbangan performa model pada kedua kelas secara bersamaan melalui perhitungan rata-rata geometris antara *sensitivity* dan *specificity* [27]. Metrik ini dihitung sebagai akar kuadrat dari perkalian *sensitivity* yang mengukur kemampuan mendeteksi kelas positif dengan *specificity* yang mengukur kemampuan mendeteksi kelas negatif. Luque *et al.* (2019) membuktikan secara analitis bahwa G-mean memiliki bias bernilai nol terhadap ketidakseimbangan kelas (*null-biased*), yang berarti nilai metrik ini tidak terpengaruh oleh proporsi kelas dalam dataset [27]. Apabila model hanya unggul pada satu kelas namun buruk pada kelas lainnya, nilai G-mean akan turun secara signifikan karena sifat perkalian pada rata-rata geometris. Karakteristik ini menjadikan G-mean sangat cocok untuk mengevaluasi model pada data tidak seimbang, di mana keseimbangan performa pada kedua kelas merupakan tujuan utama [27]. Rumus G-mean ditunjukkan pada Rumus 2.8.

$$G-mean = \sqrt{\frac{TP}{TP + FN} \times \frac{TN}{TN + FP}}$$

Rumus 2.8 G-mean (Geometric Mean)

Keterangan:

$TP = \text{True Positive}$, $TN = \text{True Negative}$, $FP = \text{False Positive}$, $FN = \text{False Negative}$

Nilai G-mean yang tinggi menandakan bahwa model memiliki performa yang baik dan seimbang pada kedua kelas, yaitu kelas positif maupun kelas negatif. Metrik ini akan bernilai nol apabila model gagal total pada salah satu kelas, meskipun performa pada kelas lainnya mencapai nilai sempurna. Sifat ini sangat berguna dalam konteks data tidak seimbang di mana model yang hanya mampu mengklasifikasikan kelas mayoritas dengan benar akan tetap memperoleh G-mean senilai nol [27]. Chicco dan Jurman (2023) juga merekomendasikan penggunaan metrik yang sensitif terhadap kedua kelas seperti G-mean dan MCC untuk menghindari kesalahan interpretasi yang sering terjadi saat menggunakan akurasi pada data tidak seimbang [29]. Karakteristik yang dimiliki G-mean menjadikannya sebagai salah satu metrik yang paling sesuai untuk mengevaluasi performa model pada dataset dengan distribusi kelas yang tidak seimbang [27].

2.2.8.4 ROC-AUC

ROC-AUC (*Receiver Operating Characteristic - Area Under the Curve*) merupakan metrik yang mengukur kemampuan diskriminatif model dalam membedakan kelas positif dan kelas negatif pada berbagai nilai *threshold* keputusan [17]. Kurva ROC dibentuk dengan membuat plot *True Positive Rate* (TPR) terhadap *False Positive Rate* (FPR) untuk setiap kemungkinan nilai ambang batas, sehingga memberikan gambaran menyeluruh tentang performa model pada seluruh titik operasi. Model dengan kemampuan diskriminatif yang baik memiliki kurva ROC yang mendekati sudut kiri atas grafik, sedangkan model yang melakukan prediksi secara acak menghasilkan garis diagonal [17]. AUC merangkum informasi dari seluruh kurva ROC ke dalam satu nilai skalar antara 0 dan 1 yang mudah dibandingkan antar model. Luque *et al.* (2019) menunjukkan bahwa AUC ekuivalen dengan *Bookmaker Informedness* yang ternormalisasi (*BMn*) pada kasus klasifikasi dengan *threshold* tunggal, sehingga AUC juga bersifat *null-biased*

terhadap ketidakseimbangan kelas [27]. Rumus TPR dan FPR ditunjukkan pada Rumus 2.9.

$$TPR = \frac{TP}{TP + FN}, \quad FPR = \frac{FP}{FP + TN}$$

Rumus 2.9 True Positive Rate dan False Positive Rate

Keterangan:

$TPR = \text{True Positive Rate (= Recall)}$, $FPR = \text{False Positive Rate}$

Nilai AUC berkisar antara 0 hingga 1, di mana nilai 1 menunjukkan model yang memiliki kemampuan diskriminatif sempurna dan nilai 0,5 menunjukkan model yang tidak lebih baik dari prediksi acak [17]. Fawcett (2006) menjelaskan bahwa AUC dapat diinterpretasikan sebagai probabilitas bahwa model memberikan skor lebih tinggi pada sampel positif yang dipilih secara acak dibandingkan sampel negatif yang dipilih secara acak [17]. Keunggulan utama ROC-AUC sebagai metrik evaluasi adalah kemampuannya untuk memberikan penilaian performa yang tidak terpengaruh oleh ketidakseimbangan distribusi kelas maupun distribusi skor keputusan [27]. ROC-AUC direkomendasikan sebagai metrik standar untuk perbandingan performa model klasifikasi pada berbagai domain yang melibatkan data tidak seimbang [17], [28]. Metrik ini banyak digunakan bersamaan dengan G-mean, *Recall*, dan *Precision* untuk memberikan evaluasi performa yang menyeluruh pada berbagai sudut pandang [26].

BAB III

METODE PENELITIAN

3.1 Alur Penelitian

Pada penelitian ini, alur dirancang untuk memastikan setiap tahapan pemrosesan dilakukan secara sistematis dan efisien. Alur penelitian ini mencerminkan langkah-langkah utama yang dilakukan pada penelitian ini, dapat dilihat pada Gambar 3.1.



Gambar 3.1 Alur Penelitian

3.2 Penjabaran Langkah Penelitian

Untuk memperjelas setiap langkah-langkah yang telah didefinisikan pada Gambar 3.1, berikut ini akan dijelaskan secara rinci tahapan-tahapan yang dilakukan dalam penelitian ini.

3.2.1 Identifikasi Masalah

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

3.3 Alat dan Bahan Tugas Akhir

Dalam menjalani penelitian, beberapa alat dan bahan digunakan untuk memastikan penelitian berjalan dengan baik.

3.3.1 Alat

Dalam membuat pengukuran frekuensi denyut nadi non-kontak dalam penelitian, berikut adalah alat-alat yang digunakan:

1. *Visual Studio Code* sebagai *tools* untuk *text editor*.
2. Python versi 3.12.5
3. OpenCV versi 4.10.0.84
4. NumPy versi 2.1.1
5. Mediapipe versi 0.10.14
6. Scipy versi 1.12.0

7. Matplotlib versi 3.8.3

8. Flask versi 3.1.0

3.3.2 Bahan

Dataset yang digunakan pada penelitian ini merupakan dataset

3.4 Ilustrasi Perhitungan Metode

Dalam penelitian ini, hasil perhitungan dari program akan melalui serangkaian pengujian untuk mengevaluasi tingkat keakuratan model yang digunakan. Data dummy tersebut dapat dilihat pada Tabel 3.1.

Tabel 3.1 Data *dummy* Pengujian

Subjek	Hasil Prediksi (BPM)							GT
	F	NA	NO	RC	LC	M	C	
1	68	69	68	70	68	71	69	68
2	69	69	68	70	68	71	69	69
3	70	70	69	71	68	73	69	70
4	71	70	70	72	69	73	70	71
5	72	72	70	72	70	74	70	72
6	73	72	71	74	71	76	71	73
7	74	73	72	74	72	77	71	74
8	75	74	72	74	73	77	73	75
9	76	75	73	75	74	78	75	76
10	77	76	74	78	75	78	76	77

BAB IV

HASIL DAN PEMBAHASAN

4.1 Penggunaan Dataset

Dataset yang digunakan pada penelitian ini merupakan dataset PURE. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

4.2 Akuisisi Gambar

Pada tahap ini, proses pembacaan dataset dilakukan dengan seksama untuk memastikan setiap gambar diperoleh dengan urutan yang benar dan sistematis. Penting untuk memastikan bahwa gambar yang diperoleh terurut dalam format *time-series* agar memudahkan analisis pergerakan wajah yang terjadi dalam video.

Implementasi kode yang digunakan untuk proses ini dapat dilihat pada Kode 4.1.

Kode 4.1 Akuisisi Gambar

```

DATASET_ROOT = os.path.join(os.getcwd(), 'PURE Dataset')
def get_all_dataset_folders(root_path):
    dataset_folders = []
    for root, dirs, files in os.walk(root_path):
        if any(file.endswith('.png') for file in files):
            dataset_folders.append(root)
    return dataset_folders
def process_dataset(dataset_path):
    image_files = glob(os.path.join(dataset_path, '*.png'))
    image_files.sort()
    for image_file in image_files:
        frame = cv2.imread(image_file)
        if frame is None:
            continue
        frame_rgb = cv2.cvtColor(frame, cv2.COLOR_BGR2RGB)
        cv2.imshow('Frame', frame)
        if cv2.waitKey(1) & 0xFF == ord('q'):
            break
    cv2.destroyAllWindows()
def main():
    datasets = get_all_dataset_folders(DATASET_ROOT)
    for dataset in datasets:
        process_dataset(dataset)

```

Kode 4.1 merupakan baris kode untuk melakukan akuisisi gambar.

4.3 Analisis Hasil Penelitian

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus

et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

4.4 Pembahasan

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetur id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan penelitian yang telah dilakukan, maka kesimpulan yang diperoleh adalah sebagai berikut:

1. Berdasarkan pengujian
2. mengimplementasikan

5.2 Saran

Adapun saran yang dapat diberikan untuk penelitian lebih lanjut berdasarkan penelitian ini adalah sebagai berikut:

1. Pengembangan
2. Tampilan

DAFTAR PUSTAKA

- [1] György Kovács. “An Empirical Comparison and Evaluation of Minority Oversampling Techniques on a Large Number of Imbalanced Datasets”. *Applied Soft Computing* 83 (2019), p. 105662.
- [2] Guodong Hou et al. “Comparative Analysis of Resampling Techniques for Class Imbalance in Financial Distress Prediction Using XGBoost”. *Mathematics* 13.7 (2025), p. 1159.
- [3] Lucky Lhaura Van FC et al. “Enhancing Machine Learning Model Performance in Addressing Class Imbalance”. *CogITO Smart Journal* 10.1 (2024), pp. 478–490.
- [4] Salimkan Fatma Taskiran et al. “A Comprehensive Evaluation of Oversampling Techniques for Enhancing Text Classification Performance”. *Scientific Reports* 15 (2025).
- [5] Duygu Yilmaz Eroglu and Mestan Sahin Pir. “Hybrid Oversampling and Undersampling Method (HOUM) via Safe-Level SMOTE and Support Vector Machine”. *Applied Sciences* 14.22 (2024), p. 10438.
- [6] Jair Cervantes et al. “A Comprehensive Survey on Support Vector Machine Classification: Applications, Challenges and Trends”. *Neurocomputing* 408 (2020), pp. 189–215.
- [7] Chumphol Bunkhumpornpat, Krung Sinapiromsaran, and Chidchanok Lursinsap. “Safe-Level-SMOTE: Safe-Level-Synthetic Minority Over-Sampling TEchnique for Handling the Class Imbalanced Problem”. *Advances in Knowledge Discovery and Data Mining (PAKDD 2009)*. Vol. 5476. Lecture Notes in Computer Science. Springer, 2009, pp. 475–482.
- [8] Muhammad Arham Tariq et al. “Comparing Different Oversampling Methods in Predicting Multi-Class Educational Datasets Using Machine

- Learning”. *Cybernetics and Information Technologies* 23.4 (2023), pp. 21–40.
- [9] Iqbal H. Sarker. “Machine Learning: Algorithms, Real-World Applications and Research Directions”. *SN Computer Science* 2.3 (2021), p. 160.
- [10] Raghad Mohammed, Jamal Rawashdeh, and Malak Abdullah. “Machine Learning with Oversampling and Undersampling Techniques: Overview Study and Experimental Results”. *Proceedings of the 11th International Conference on Information and Communication Systems (ICICS)*. IEEE, 2020, pp. 243–248.
- [11] Haibo He and Edwardo A. Garcia. “Learning from Imbalanced Data”. *IEEE Transactions on Knowledge and Data Engineering* 21.9 (2009), pp. 1263–1284.
- [12] Dakhaz Mustafa Abdullah and Adnan Mohsin Abdulazeez. “Machine Learning Applications based on SVM Classification: A Review”. *Qubahan Academic Journal* 1.2 (2021), pp. 81–90.
- [13] Bartosz Krawczyk. “Learning from Imbalanced Data: Open Challenges and Future Directions”. *Progress in Artificial Intelligence* 5.4 (2016), pp. 221–232.
- [14] Fadi Thabtah et al. “Data Imbalance in Classification: Experimental Evaluation”. *Information Sciences* 513 (2020), pp. 429–441.
- [15] Guo Haixiang et al. “Learning from Class-Imbalanced Data: Review of Methods and Applications”. *Expert Systems with Applications* 73 (2017), pp. 220–239.
- [16] Nitesh V. Chawla et al. “SMOTE: Synthetic Minority Over-sampling Technique”. *Journal of Artificial Intelligence Research* 16 (2002), pp. 321–357.
- [17] Tom Fawcett. “An Introduction to ROC Analysis”. *Pattern Recognition Letters* 27.8 (2006), pp. 861–874.
- [18] György Kovács. “smote-variants: A Python Implementation of 85 Minority Oversampling Techniques”. *Neurocomputing* 366 (2019), pp. 352–354.

- [19] Dina Elreedy, Amir F. Atiya, and Firuz Kamalov. “A Comprehensive Analysis of Synthetic Minority Oversampling Technique (SMOTE) and Its Extensions”. *Information Sciences* 643 (2023), p. 119205.
- [20] Hui Han, Wen-Yuan Wang, and Bing-Huan Mao. “Borderline-SMOTE: A New Over-Sampling Method in Imbalanced Data Sets Learning”. *Proceedings of the International Conference on Intelligent Computing (ICIC)*. Vol. 3644. Lecture Notes in Computer Science. Springer, 2005, pp. 878–887.
- [21] Haibo He et al. “ADASYN: Adaptive Synthetic Sampling Approach for Imbalanced Learning”. *Proceedings of the IEEE International Joint Conference on Neural Networks (IJCNN)*. IEEE, 2008, pp. 1322–1328.
- [22] Ahmad S. Tarawneh et al. “SMOTEFUNA: Synthetic Minority Over-Sampling Technique Based on Furthest Neighbour Algorithm”. *IEEE Access* 10 (2022), pp. 59891–59913.
- [23] Gustavo E. A. P. A. Batista, Ronaldo C. Prati, and Maria-Carolina Monard. “A Study of the Behavior of Several Methods for Balancing Machine Learning Training Data”. *ACM SIGKDD Explorations Newsletter* 6.1 (2004), pp. 20–29.
- [24] Salim Rezvani et al. “Methods for Class-Imbalanced Learning with Support Vector Machines: A Review and an Empirical Evaluation”. *Neural Computing and Applications* 36 (2024), pp. 123–158.
- [25] Yuchun Tang et al. “SVMs Modeling for Highly Imbalanced Classification”. *IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics)* 39.1 (2009), pp. 281–288.
- [26] Marina Sokolova and Guy Lapalme. “A Systematic Analysis of Performance Measures for Classification Tasks”. *Information Processing & Management* 45.4 (2009), pp. 427–437.
- [27] Amalia Luque et al. “The Impact of Class Imbalance in Classification Performance Metrics Based on the Binary Confusion Matrix”. *Pattern Recognition* 91 (2019), pp. 216–231.

- [28] Margherita Grandini, Enrico Bagli, and Giorgio Visani. “Metrics for Multi-Class Classification: An Overview”. *arXiv preprint arXiv:2008.05756* (2020).
- [29] Davide Chicco and Giuseppe Jurman. “The Matthews Correlation Coefficient (MCC) is More Reliable Than Balanced Accuracy, Bookmaker Informedness, and Markedness in Two-Class Confusion Matrix Evaluation”. *BioData Mining* 16.1 (2023), pp. 1–23.

LAMPIRAN