

**PENGARUH VARIASI OVERSAMPLING DAN
KONFIGURASI SVM PADA METODE HOUM
TERHADAP DATA KLASIFIKASI TIDAK SEIMBANG**

TUGAS AKHIR

Oleh:

Rizki Alfariz Ramadhan

122140061



**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
INSTITUT TEKNOLOGI SUMATERA
LAMPUNG SELATAN**

2026

LEMBAR PENGESAHAN

Tugas Akhir Sarjana dengan judul "Pengaruh Variasi Oversampling dan Konfigurasi SVM Pada Metode HOUM Terhadap Data Klasifikasi Tidak Seimbang" adalah benar dibuat oleh saya sendiri dan belum pernah dibuat dan diserahkan sebelumnya, baik sebagian ataupun seluruhnya, baik oleh saya ataupun orang lain, baik di Institut Teknologi Sumatera maupun di institusi pendidikan lainnya.

Lampung Selatan, 09-05-2026

Penulis,

Foto 3x4

Rizki Alfariz Ramadhan

NIM 122140061

Diperiksa dan disetujui oleh,
Pembimbing

Tanda Tangan

1. Meida Cahyo Untoro, S.Kom., M.Kom.

NIP. 19890518 201903 1 011

.....

Penguji

Tanda Tangan

1. Andika Setiawan, S.Kom., M.Cs.

NIP. 19911127 2022 03 1 007

.....

2. Eko Dwi Nugroho, S.Kom., M.Cs.

NIP. 19910209 2024 06 1 001

.....

Disahkan oleh,
Koordinator Program Studi Teknik Informatika
Fakultas Teknologi Industri
Institut Teknologi Sumatera

Andika Setiawan, S.Kom., M.Cs.

NIP 19911127 2022 03 1 007

HALAMAN PERNYATAAN ORISINALITAS

Tugas Akhir dengan judul “Pengaruh Variasi Oversampling dan Konfigurasi SVM Pada Metode HOUM Terhadap Data Klasifikasi Tidak Seimbang” adalah karya saya sendiri, dan semua sumber baik yang dikutip maupun dirujuk telah saya nyatakan benar.

Nama : Rizki Alfariz Ramadhan

NIM : 122140061

Tanda Tangan :

Tanggal :

HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI TUGAS AKHIR UNTUK KEPENTINGAN AKADEMIS

Sebagai civitas akademik Institut Teknologi Sumatera, saya yang bertanda tangan di bawah ini:

Nama : Rizki Alfariz Ramadhan

NIM : 122140061

Program Studi : Teknik Informatika

Fakultas : Teknologi Industri

Jenis Karya : Tugas Akhir

demi pengembangan ilmu pengetahuan, menyetujui untuk memberikan kepada Institut Teknologi Sumatera **Hak Bebas Royalti Noneksklusif** (*Non-exclusive Royalty Free Right*) atas karya ilmiah saya yang berjudul:

Pengaruh Variasi Oversampling dan Konfigurasi SVM Pada Metode HOUM Terhadap Data Klasifikasi Tidak Seimbang

beserta perangkat yang ada (jika diperlukan). Dengan Hak Bebas Royalti Noneksklusif ini Institut Teknologi Sumatera berhak menyimpan, mengalihmedia/formatkan, mengelola dalam bentuk pangkalan data (*database*), merawat, dan memublikasikan tugas akhir saya selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik Hak Cipta.

Demikian pernyataan ini saya buat dengan sebenarnya.

Dibuat di : Lampung Selatan

Pada tanggal : 09-05-2026

Yang menyatakan

Rizki Alfariz Ramadhan

KATA PENGANTAR

Puji syukur kehadiran Tuhan Yang Maha Esa atas limpahan rahmat, karunia, serta petunjuk-Nya sehingga penyusunan tugas akhir ini telah terselesaikan dengan baik. Dalam penyusunan tugas akhir ini penulis telah banyak mendapatkan arahan, bantuan, serta dukungan dari berbagai pihak. Oleh karena itu pada kesempatan ini penulis mengucapkan terima kasih kepada:

1. Bapak Prof. Dr. I. Nyoman Pugeg Aryantha selaku Rektor Institut Teknologi Sumatera.
2. Bapak Hadi Teguh Yudistira, S.T., Ph.D. selaku Dekan Fakultas Teknologi Industri.
3. Bapak Andika Setiawan, S. Kom., M. Cs. selaku Ketua Program Studi Teknik Informatika.
4. Bapak Meida Cahyo Untoro, S.Kom., M.Kom. selaku Dosen Pembimbing atas ide, waktu, tenaga, perhatian, dan masukan yang telah disumbangsikan kepada penulis.
5. Teman-teman penulis yang membantu selama masa perkuliahan dan bekerja sama dalam melakukan penelitian tugas akhir yang tidak bisa disebutkan satu persatu.

Akhir kata penulis berharap semoga tugas akhir ini dapat memberikan manfaat bagi kita semua. Penulis menyadari bahwa tugas akhir ini tidak luput dari kekurangan dan kelemahan, dan penulis terbuka untuk menerima saran, kritik, dan masukan.

RINGKASAN

Pengaruh Variasi Oversampling dan Konfigurasi SVM Pada Metode HOUM

Terhadap Data Klasifikasi Tidak Seimbang

Rizki Alfariz Ramadhan

Ketidakseimbangan kelas merupakan permasalahan utama dalam klasifikasi *machine learning*, di mana model cenderung bias terhadap kelas mayoritas. Eroglu dan Pir (2024) mengusulkan HOUM yang menggabungkan Safe-Level SMOTE dan SVM secara iteratif, namun belum mengeksplorasi variasi teknik *oversampling* serta konfigurasi SVM. Oleh karena itu, penelitian ini bertujuan menganalisis pengaruh variasi teknik *oversampling* Safe-Level SMOTE dan ADASYN serta konfigurasi SVM (parameter C dan jenis kernel) pada HOUM terhadap kinerja klasifikasi data tidak seimbang.

Penelitian menggunakan tiga dataset *benchmark* yaitu Pima Indians Diabetes (rasio 1:1,87), Haberman *Survival* (1:2,78), dan *Blood Transfusion* (1:3,20). Data dibagi 80:20 menggunakan *stratified split*. HOUM diimplementasikan dengan 18 kombinasi konfigurasi SVM dengan nilai parameter C 0,5; 1; 1,5; 2; 2,5; 3 dan jenis kernel Linear, RBF, Polynomial yang dikombinasikan dengan Safe-Level SMOTE dan ADASYN. Penyeimbangan dilakukan iteratif hingga rasio kelas seimbang. Data hasil penyeimbangan melatih *Random Forest* dan dievaluasi menggunakan *Recall*, *Precision*, G-Mean, serta ROC-AUC.

Hasil penelitian menunjukkan HOUM-SLSMOTE unggul pada *Recall* di seluruh dataset, sedangkan HOUM-ADASYN unggul pada *Precision*. Nilai C kecil (0,5) optimal untuk Diabetes dan Haberman, sementara $C = 2$ optimal untuk Transfusion. RBF unggul pada data berdimensi tinggi (Diabetes), Linear lebih stabil pada data berdimensi rendah (Haberman, Transfusion). G-Mean tertinggi 0,7401 dicapai pada Diabetes (dengan kombinasi HOUM-ADASYN, RBF, $C = 0,5$). Peningkatan *Recall* signifikan meskipun disertai *trade-off* penurunan *Precision*.

Penelitian menyimpulkan bahwa efektivitas teknik *oversampling* bergantung pada karakteristik dataset, pemilihan parameter SVM harus disesuaikan dimensi data, dan HOUM efektif meningkatkan deteksi kelas minoritas. Direkomendasikan eksplorasi dataset berdimensi lebih tinggi, rentang C di bawah 0,5, teknik *oversampling* alternatif, serta algoritma klasifikasi lainnya.

ABSTRAK

Pengaruh Variasi Oversampling dan Konfigurasi SVM Pada Metode HOUM

Terhadap Data Klasifikasi Tidak Seimbang

Rizki Alfariz Ramadhan

Ketidakseimbangan distribusi kelas merupakan permasalahan yang sering dihadapi dalam klasifikasi *machine learning*, menyebabkan model cenderung bias terhadap kelas mayoritas dan gagal mendeteksi kelas minoritas. HOUM (*Hybrid Oversampling and Undersampling Method*) merupakan metode hibrida yang menggabungkan Safe-Level SMOTE untuk *oversampling* dan SVM untuk *undersampling* secara iteratif. Namun, penelitian sebelumnya belum mengeksplorasi pengaruh variasi parameter regularisasi C dan jenis kernel SVM, serta belum membandingkan Safe-Level SMOTE dengan teknik *oversampling* lain seperti ADASYN. Penelitian ini bertujuan untuk menganalisis pengaruh variasi teknik *oversampling* (Safe-Level SMOTE vs ADASYN) dan konfigurasi SVM (parameter C : 0,5; 1; 1,5; 2; 2,5; 3 serta kernel Linear, RBF, Polynomial) pada metode HOUM terhadap kinerja klasifikasi data tidak seimbang. Tiga dataset *benchmark* digunakan, yaitu Diabetes, Haberman, dan Blood Transfusion dengan variasi rasio ketidakseimbangan. Data dibagi 80:20 secara *stratified*, diseimbangkan dengan 18 kombinasi konfigurasi HOUM, dan diklasifikasi menggunakan *Random Forest*. Hasil menunjukkan HOUM-SLSMOTE konsisten menghasilkan *recall* lebih tinggi (Diabetes: 0,6481; Haberman: 0,3750; Transfusion: 0,7500), sedangkan HOUM-ADASYN unggul pada *precision* khususnya di Diabetes (0,7234). Nilai $C = 0,5$ optimal pada Diabetes dan Haberman, sedangkan $C = 2$ lebih sesuai pada Transfusion. Kernel RBF unggul pada dataset berdimensi tinggi (Diabetes), kernel Linear pada dimensi rendah (Haberman, Transfusion). Konfigurasi terbaik: HOUM-ADASYN RBF $C = 0,5$ (Diabetes, G-Mean 0,7401), HOUM-SLSMOTE Linear $C = 0,5$ (Haberman, G-Mean 0,4778), dan HOUM-SLSMOTE Linear $C = 2$ (Transfusion, G-Mean 0,6977). Kesimpulannya, pemilihan teknik *oversampling*, kernel SVM, dan nilai C harus disesuaikan dengan karakteristik dataset karena terdapat *trade-off* antara *recall* dan *precision*.

Kata Kunci: HOUM, *oversampling*, Safe-Level SMOTE, SVM, data tidak seimbang

ABSTRACT

Comparison

Rizki Alfariz Ramadhan

Class imbalance is a common problem in machine learning classification, causing models to be biased toward the majority class and fail to detect the minority class. HOUM (Hybrid Oversampling and Undersampling Method) is a hybrid method that combines Safe-Level SMOTE for oversampling and SVM for undersampling iteratively. However, previous research has not explored the effect of varying the regularization parameter C and SVM kernel types, nor has it compared Safe-Level SMOTE with alternative oversampling techniques such as ADASYN. This study aims to analyze the effect of oversampling technique variation (Safe-Level SMOTE vs ADASYN) and SVM configuration (parameter C : 0.5; 1; 1.5; 2; 2.5; 3 and kernel types: Linear, RBF, Polynomial) within the HOUM method on imbalanced data classification performance. Three benchmark datasets were used, namely Diabetes, Haberman, and Blood Transfusion, with varying imbalance ratios. Data were split 80:20 using stratified split, balanced with 18 HOUM configuration combinations, and classified using Random Forest. Results show that HOUM-SLSMOTE consistently yields higher recall across all datasets (Diabetes: 0.6481; Haberman: 0.3750; Transfusion: 0.7500), while HOUM-ADASYN excels in precision particularly on Diabetes (0.7234). The $C = 0.5$ value is optimal for Diabetes and Haberman, whereas $C = 2$ is more suitable for Transfusion. The RBF kernel performs best on the higher-dimensional dataset (Diabetes), while the Linear kernel is more optimal on lower-dimensional datasets (Haberman, Transfusion). The best configurations are: HOUM-ADASYN with RBF $C = 0.5$ (Diabetes, G-Mean 0.7401), HOUM-SLSMOTE with Linear $C = 0.5$ (Haberman, G-Mean 0.4778), and HOUM-SLSMOTE with Linear $C = 2$ (Transfusion, G-Mean 0.6977). In conclusion, the selection of oversampling technique, SVM kernel, and C value must be tailored to dataset characteristics due to the trade-off between recall and precision.

Keywords: HOUM, oversampling, Safe-Level SMOTE, SVM, imbalanced data

DAFTAR ISI

LEMBAR PENGESAHAN	ii
Halaman Pernyataan Orisinalitas	iii
Halaman Persetujuan Publikasi	iv
KATA PENGANTAR	v
RINGKASAN	vi
ABSTRAK	vii
ABSTRACT	viii
DAFTAR ISI	ix
DAFTAR TABEL	xii
DAFTAR GAMBAR	xiii
DAFTAR RUMUS	xiv
DAFTAR KODE	xiv
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Tujuan Penelitian	3
1.4 Batasan Masalah	4
1.5 Manfaat Penelitian	4
1.6 Sistematika Penulisan	5
BAB II TINJAUAN PUSTAKA	6
2.1 Tinjauan Pustaka	6
2.2 Dasar Teori	8
2.2.1 Klasifikasi	8
2.2.2 Ketidakseimbangan Data (<i>Class Imbalance</i>)	9

2.2.3	<i>Oversampling</i>	11
2.2.3.1	SMOTE (<i>Synthetic Minority Over-sampling Technique</i>) ..	12
2.2.3.2	Safe-Level SMOTE	13
2.2.3.3	ADASYN (<i>Adaptive Synthetic Sampling</i>)	14
2.2.4	<i>Undersampling</i>	15
2.2.5	Metode Hibrida (<i>Hybrid Resampling</i>)	16
2.2.6	HOUM (<i>Hybrid Oversampling and Undersampling Method</i>) ...	16
2.2.7	<i>Support Vector Machine</i> (SVM)	19
2.2.8	Metrik Evaluasi	23
2.2.8.1	<i>Recall</i>	24
2.2.8.2	<i>Precision</i>	24
2.2.8.3	G-mean	25
2.2.8.4	ROC-AUC	26
BAB III	METODE PENELITIAN	28
3.1	Alur Penelitian	28
3.2	Penjabaran Langkah Penelitian	28
3.2.1	Identifikasi Masalah	28
3.2.2	Studi Literatur	29
3.2.3	Pengumpulan Data	29
3.2.4	Implementasi Metode HOUM dengan Variasi Oversampling dan Konfigurasi SVM	31
3.2.5	Evaluasi	34
3.2.6	Hasil dan Pembahasan	34
3.3	Alat dan Bahan Tugas Akhir	35
3.4	Rancangan Pengujian	35
BAB IV	HASIL DAN PEMBAHASAN	36
4.1	Deskripsi Dataset	36
4.2	Hasil Penelitian	37
4.2.1	Hasil Klasifikasi pada Data Tidak Seimbang (<i>Baseline</i>)	38

4.2.2 Hasil Metode HOUM dengan Safe-Level SMOTE (HOUM-SLSMOTE)	40
4.2.2.1 Dataset Diabetes	40
4.2.2.2 Dataset Haberman	41
4.2.2.3 Dataset Transfusion	43
4.2.3 Hasil Metode HOUM dengan ADASYN (HOUM-ADASYN) ..	44
4.2.3.1 Dataset Diabetes	45
4.2.3.2 Dataset Haberman	46
4.2.3.3 Dataset Transfusion	48
4.2.4 Perbandingan Hasil Secara Umum	49
4.3 Pembahasan Penelitian	50
4.3.1 Analisis Dampak Penerapan HOUM pada Data Tidak Seimbang	50
4.3.1.1 Perubahan Nilai Metrik Evaluasi	51
4.3.1.2 Mekanisme Kerja HOUM	52
4.3.2 Analisis Pengaruh Metode <i>Oversampling</i>	52
4.3.2.1 Perbandingan Performa antar Metode	53
4.3.2.2 Penyebab Perbedaan Performa	53
4.3.2.3 Implikasi terhadap Pemilihan Metode	54
4.3.3 Analisis Pengaruh Kernel SVM	54
4.3.4 Analisis Pengaruh Parameter C	56
4.3.5 Rekomendasi Konfigurasi HOUM	57
4.3.5.1 Alasan Pemilihan <i>Oversampling</i>	58
4.3.5.2 Alasan Pemilihan Kernel	58
4.3.5.3 Alasan Pemilihan Nilai <i>C</i>	59
BAB V KESIMPULAN DAN SARAN	60
5.1 Kesimpulan	60
5.2 Saran	62
DAFTAR PUSTAKA	63
LAMPIRAN	67

DAFTAR TABEL

Tabel 3.1	Karakteristik Dataset yang Digunakan	30
Tabel 3.2	Contoh Format Keluaran Hasil Eksperimen	33
Tabel 4.1	Statistik Dataset yang Digunakan	36
Tabel 4.2	Hasil Klasifikasi <i>Baseline</i> pada Data Tidak Seimbang	38
Tabel 4.3	Hasil HOUM-SLSMOTE pada Dataset Diabetes	40
Tabel 4.4	Hasil HOUM-SLSMOTE pada Dataset Haberman	42
Tabel 4.5	Hasil HOUM-SLSMOTE pada Dataset Transfusion	43
Tabel 4.6	Hasil HOUM-ADASYN pada Dataset Diabetes	45
Tabel 4.7	Hasil HOUM-ADASYN pada Dataset Haberman	47
Tabel 4.8	Hasil HOUM-ADASYN pada Dataset Transfusion	48
Tabel 4.9	Ringkasan Performa Tiap Metode pada Setiap Dataset	50
Tabel 4.10	Perbandingan Metrik Evaluasi <i>Baseline</i> dan HOUM pada Ketiga Dataset	51
Tabel 4.11	Rekomendasi Konfigurasi HOUM Berdasarkan G-Mean Tertinggi	58

DAFTAR GAMBAR

Gambar 2.1	Ilustrasi Distribusi Data Tidak Seimbang	9
Gambar 2.2	Ilustrasi Teknik <i>Oversampling</i>	11
Gambar 2.3	Ilustrasi Teknik <i>Undersampling</i>	15
Gambar 2.4	Alur Kerja Metode HOUM	18
Gambar 2.5	Ilustrasi SVM	20
Gambar 2.6	Ilustrasi <i>Hyperplane</i> di Masing-masing Kernel (Sumber: https://scikit-learn.org/stable/auto_examples/svm/plot_svm_kernels.html)	22
Gambar 2.7	Ilustrasi Kurva ROC-AUC	27
Gambar 3.1	Alur Penelitian	28
Gambar 3.2	Alur Implementasi Metode HOUM	32
Gambar 4.1	Distribusi Kelas pada Masing-Masing Dataset	37
Gambar 4.2	Kurva ROC <i>Baseline</i> pada Data Tidak Seimbang	39
Gambar 4.3	Kurva ROC HOUM-SLSMOTE pada Dataset Diabetes	41
Gambar 4.4	Kurva ROC HOUM-SLSMOTE pada Dataset Haberman	42
Gambar 4.5	Kurva ROC HOUM-SLSMOTE pada Dataset Transfusion ...	44
Gambar 4.6	Kurva ROC HOUM-ADASYN pada Dataset Diabetes	46
Gambar 4.7	Kurva ROC HOUM-ADASYN pada Dataset Haberman	47
Gambar 4.8	Kurva ROC HOUM-ADASYN pada Dataset Transfusion	49

DAFTAR RUMUS

Rumus 2.1	Imbalance Ratio (IR)	10
Rumus 2.2	Pembentukan Sampel Sintetis SMOTE	12
Rumus 2.3	Distribusi Bobot ADASYN	14
Rumus 2.4	Fungsi Keputusan SVM	19
Rumus 2.5	Kernel Linear	21
Rumus 2.6	Kernel Polynomial	21
Rumus 2.7	Kernel RBF	21
Rumus 2.8	Recall (Sensitivity)	24
Rumus 2.9	Precision	24
Rumus 2.10	G-mean (Geometric Mean)	25
Rumus 2.11	True Positive Rate dan False Positive Rate	26

DAFTAR KODE

BAB I

PENDAHULUAN

1.1 Latar Belakang

Ketidakseimbangan distribusi kelas pada dataset menjadi salah satu permasalahan yang paling sering dihadapi dalam penerapan *machine learning* untuk klasifikasi. Kondisi ini terjadi ketika jumlah sampel pada satu kelas jauh lebih banyak dibandingkan kelas lainnya, sehingga kelas dengan jumlah sampel sedikit disebut kelas minoritas dan kelas dengan jumlah banyak disebut kelas mayoritas [1]. Permasalahan data tidak seimbang banyak ditemukan pada berbagai domain nyata seperti deteksi penipuan kartu kredit, diagnosis penyakit langka, pemantauan sistem industri, dan analisis sentimen [2]. Algoritma klasifikasi yang dilatih pada data tidak seimbang cenderung memprioritaskan kelas mayoritas dan mengabaikan kelas minoritas, padahal kelas minoritas seringkali menjadi target utama analisis [3]. Model yang dihasilkan mungkin memperoleh nilai akurasi tinggi secara keseluruhan, namun gagal mendeteksi sampel kelas minoritas yang seharusnya teridentifikasi [4].

Krawczyk (2016) mengategorikan pendekatan untuk menangani data tidak seimbang ke dalam tiga kelompok utama, yaitu metode tingkat data (*data-level*), metode tingkat algoritma (*algorithm-level*), dan metode hibrida [2]. Metode tingkat data bekerja dengan memodifikasi distribusi dataset pelatihan melalui penambahan sampel kelas minoritas (*oversampling*) atau pengurangan sampel kelas mayoritas (*undersampling*). Metode tingkat algoritma memodifikasi algoritma klasifikasi secara langsung agar tidak bias terhadap kelas mayoritas, misalnya melalui pendekatan *cost-sensitive learning* [2]. Metode hibrida menggabungkan pendekatan *data-level* dengan teknik *ensemble* untuk menghasilkan model yang lebih robust dan efektif dalam menangani distribusi kelas yang timpang [2]. Di antara ketiga pendekatan tersebut, metode tingkat data menjadi yang paling banyak diteliti karena bersifat independen terhadap algoritma klasifikasi dan dapat diterapkan tanpa mengubah proses pelatihan model [1].

Pada kategori *data-level*, teknik *oversampling* dan *undersampling* merupakan dua pendekatan yang paling banyak digunakan. Chawla *et al.* (2002) memperkenalkan SMOTE yang menghasilkan sampel sintetis kelas minoritas berdasarkan interpolasi antar tetangga terdekat, sehingga mampu meningkatkan kemampuan model dalam mengenali kelas minoritas [5]. Bunkhumpornpat *et al.* (2009) mengembangkan Safe-Level SMOTE yang memperhitungkan tingkat keamanan posisi sampel sintetis berdasarkan komposisi tetangga terdekatnya, sehingga sampel baru tidak terbentuk di wilayah yang didominasi kelas mayoritas [6]. Masing-masing teknik memiliki kelemahan, dimana *oversampling* berpotensi menimbulkan *overfitting* akibat data sintetis yang redundan, sementara *undersampling* berisiko menghilangkan informasi penting dari kelas mayoritas [7].

Untuk mengatasi kelemahan penggunaan teknik tunggal, Eroglu dan Pir (2024) mengusulkan HOUM (*Hybrid Oversampling and Undersampling Method*) yang menggabungkan Safe-Level SMOTE untuk *oversampling* dan SVM untuk *undersampling* secara iteratif hingga dataset mencapai keseimbangan [7]. HOUM memanfaatkan SVM untuk mengidentifikasi dan menghapus data kelas mayoritas yang berada jauh dari *decision boundary*, sehingga data yang tersisa lebih informatif bagi proses klasifikasi. Pengujian pada delapan dataset menunjukkan bahwa HOUM mampu mengungguli metode pembandingan seperti SMOTE, SMOTEENN, SMOTETomek, W-SIMO, dan RusAda [7]. Namun, penelitian tersebut hanya menggunakan satu konfigurasi parameter SVM dan satu teknik *oversampling* (Safe-Level SMOTE) tanpa mengeksplorasi pengaruh variasi parameter terhadap hasil klasifikasi.

Performa SVM sangat dipengaruhi oleh pemilihan parameter regularisasi C dan jenis kernel yang digunakan [8]. Parameter C mengontrol keseimbangan antara kompleksitas model dan toleransi terhadap kesalahan klasifikasi, sedangkan jenis kernel menentukan cara SVM memetakan data ke dimensi yang lebih tinggi. Variasi konfigurasi parameter tersebut berpengaruh langsung terhadap pembentukan *decision boundary* yang digunakan HOUM untuk proses *undersampling*. Selain konfigurasi SVM, pemilihan teknik *oversampling* berpotensi memengaruhi kualitas data hasil penyeimbangan. He *et al.* (2008) memperkenalkan ADASYN (*Adaptive*

Synthetic Sampling) yang menghasilkan lebih banyak sampel sintetis pada area yang sulit diklasifikasikan berdasarkan distribusi bobot adaptif [9]. Pendekatan ADASYN berbeda dengan Safe-Level SMOTE karena fokus pada sampel minoritas yang sulit dipelajari, sehingga batas keputusan model dapat bergeser secara adaptif ke arah yang tepat [9]. Perbandingan antara kedua teknik ini sebagai komponen *oversampling* pada HOUM belum pernah dilakukan pada penelitian sebelumnya.

Berdasarkan uraian tersebut, penelitian ini bertujuan menganalisis pengaruh variasi konfigurasi pada metode HOUM terhadap performa klasifikasi data tidak seimbang. Pada komponen *undersampling*, dilakukan variasi parameter C pada SVM dengan enam nilai (0,5; 1; 1,5; 2; 2,5; 3) serta perbandingan tiga jenis kernel yaitu Linear, RBF, dan Polynomial. Pada komponen *oversampling*, dilakukan perbandingan antara HOUM yang menggunakan Safe-Level SMOTE dengan HOUM yang menggunakan ADASYN. Performa klasifikasi dievaluasi menggunakan metrik ROC-AUC, G-mean, *Recall*, dan *Precision* yang sesuai untuk menilai kemampuan model dalam menangani data tidak seimbang. Hasil penelitian ini diharapkan dapat memberikan rekomendasi konfigurasi HOUM yang optimal untuk berbagai skenario ketidakseimbangan data.

1.2 Rumusan Masalah

Berdasarkan latar belakang, permasalahan penelitian dirumuskan sebagai berikut:

1. Bagaimana pengaruh penggunaan teknik *oversampling* yang berbeda pada metode HOUM terhadap kinerja klasifikasi data tidak seimbang?
2. Bagaimana pengaruh variasi nilai parameter regularisasi (C) dan jenis kernel Support Vector Machine terhadap kinerja metode HOUM dalam menangani data klasifikasi tidak seimbang?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah, tujuan dari penelitian adalah sebagai berikut:

1. Menganalisis pengaruh penggunaan teknik *oversampling* yang berbeda pada metode HOUM terhadap kinerja klasifikasi data tidak seimbang.

2. Menganalisis pengaruh variasi parameter regularisasi (C) dan jenis kernel Support Vector Machine terhadap kinerja metode HOUM dalam menangani data klasifikasi tidak seimbang.

1.4 Batasan Masalah

Adapun batasan masalah dari penelitian agar sesuai dengan yang diharapkan adalah sebagai berikut:

1. Penelitian difokuskan pada data klasifikasi tidak seimbang (*imbalanced classification*) dan tidak mencakup permasalahan regresi.
2. Teknik *oversampling* yang dianalisis pada metode HOUM dibatasi pada Safe-Level SMOTE dan ADASYN.
3. Analisis pengaruh konfigurasi SVM dibatasi pada pemilihan jenis kernel, yaitu Linear, *Radial Basis Function* (RBF), dan Polynomial, serta variasi nilai parameter regularisasi (C).
4. Nilai parameter regularisasi (C) yang digunakan dalam penelitian ini dibatasi pada nilai 0.5, 1, 1.5, 2, 2.5, dan 3.
5. Evaluasi performa metode HOUM dibatasi menggunakan metrik ROC-AUC, G-Mean, *Recall*, dan *Precision*.

1.5 Manfaat Penelitian

Adapun manfaat yang diperoleh dari hasil penelitian adalah sebagai berikut:

1. Memberikan rekomendasi mengenai teknik *oversampling* yang paling efektif (Safe-Level SMOTE vs ADASYN) untuk diintegrasikan dalam metode HOUM saat menangani data berimbang.
2. Menjadi acuan dalam menentukan nilai parameter regularisasi (C) yang optimal pada SVM untuk meningkatkan kemampuan model HOUM dalam mengklasifikasikan kelas minoritas.
3. Memberikan panduan empiris dalam memilih jenis kernel SVM yang paling sesuai untuk memaksimalkan performa *undersampling* metode HOUM pada karakteristik data yang berbeda.

1.6 Sistematika Penulisan

Penulisan tugas akhir disusun secara sistematis ke dalam lima bab yang saling berkaitan. Berikut adalah uraian mengenai isi masing-masing bab.

Bab I Pendahuluan

Pada bab ini menyajikan gambaran umum penelitian yang meliputi latar belakang permasalahan, rumusan masalah, tujuan penelitian, batasan masalah, manfaat penelitian, serta sistematika penulisan laporan tugas akhir.

Bab II Tinjauan Pustaka

Pada bab ini menguraikan kajian literatur yang berkaitan dengan topik penelitian, mencakup tinjauan terhadap penelitian-penelitian sebelumnya serta landasan teori yang mendasari metode dan konsep yang digunakan dalam penelitian ini.

Bab III Metodologi Penelitian

Pada bab ini menjelaskan secara rinci metodologi yang diterapkan dalam penelitian, meliputi tahapan alur kerja, perangkat dan dataset yang digunakan, metode yang diimplementasikan, serta rancangan skenario pengujian yang akan dilakukan.

Bab IV Hasil dan Pembahasan

Pada bab ini memaparkan hasil penelitian yang diperoleh dari implementasi metode, beserta analisis dan pembahasan terhadap hasil pengujian.

Bab V Penutup

Pada bab ini berisi kesimpulan yang merangkum hasil penelitian berdasarkan tujuan penelitian, serta saran-saran untuk pengembangan dan penyempurnaan pada penelitian selanjutnya.

BAB II

TINJAUAN PUSTAKA

2.1 Tinjauan Pustaka

Penelitian disusun berdasarkan kajian terhadap beberapa penelitian terdahulu yang berkaitan dengan topik penanganan ketidakseimbangan data dalam klasifikasi. Kajian penelitian bertujuan untuk memahami pendekatan yang telah dikembangkan serta mengidentifikasi celah penelitian yang dapat dieksplorasi lebih lanjut.

Penelitian pertama dilakukan oleh Eroglu dan Pir (2024) yang mengusulkan metode hibrida bernama HOUM (*Hybrid Oversampling and Undersampling Method*) [7]. HOUM mengombinasikan Safe-Level SMOTE untuk *oversampling* kelas minoritas dan SVM untuk *undersampling* kelas mayoritas dalam proses iteratif. Pada setiap iterasi, SVM dilatih untuk membentuk *decision boundary*, kemudian data mayoritas yang jauh dari *hyperplane* dihapus dan data minoritas ditambahkan di posisi yang aman. Pengujian pada delapan dataset dari UCI *Machine Learning Repository* menunjukkan bahwa HOUM mengungguli metode pembandingan seperti SMOTE, SMOTEENN, SMOTETomek, W-SIMO, dan RusAda pada metrik G-mean dan ROC-AUC [7]. Namun, penelitian tersebut hanya menggunakan konfigurasi *default* pada komponen SVM tanpa mengkaji pengaruh variasi parameter C dan jenis kernel.

Penelitian kedua berasal dari Taskiran *et al.* (2025) yang mengevaluasi 31 teknik *oversampling* untuk klasifikasi teks [10]. Evaluasi dilakukan pada dataset TREC dan Emotions menggunakan enam algoritma klasifikasi dengan representasi teks MiniLMv2. Teknik yang diuji meliputi SMOTE beserta 30 variannya, termasuk Borderline-SMOTE dan ADASYN. Hasil pengujian dengan metrik F1-Score dan *Balanced Accuracy* menunjukkan bahwa tidak ada satu teknik *oversampling* yang secara konsisten unggul di semua kondisi. Efektivitas teknik sangat bergantung pada karakteristik distribusi data dan algoritma klasifikasi yang digunakan [10].

Penelitian ketiga merupakan karya Hou *et al.* (2025) yang membandingkan

delapan teknik *resampling* untuk prediksi *financial distress* menggunakan XGBoost [3]. Teknik yang diuji meliputi SMOTE, ADASYN, Borderline-SMOTE, Tomek Links, *Random Under-Sampling*, SMOTE-Tomek, SMOTE-ENN, dan Bagging-SMOTE. Hasil eksperimen menunjukkan bahwa SMOTE mencapai F1-score tertinggi sebesar 0,73 dengan MCC 0,70, sedangkan Bagging-SMOTE memperoleh F1-score 0,72 dengan AUC 0,96. *Random Under-Sampling* menghasilkan *recall* tinggi (0,85) namun *precision* rendah (0,46), sehingga kurang tepat untuk kasus yang memerlukan keseimbangan kedua metrik [3]. Temuan ini memperkuat argumen bahwa teknik *undersampling* acak berpotensi menurunkan kualitas data pelatihan.

Penelitian keempat diambil dari Tariq *et al.* (2023) yang menguji metode *oversampling* pada dataset pendidikan bertipe *multi-class* [11]. Metode yang diuji meliputi SMOTE, ADASYN, Borderline-SMOTE, dan SMOTETomek yang dikombinasikan dengan sepuluh algoritma klasifikasi. Hasil pengujian menunjukkan bahwa kombinasi SMOTETomek dengan KNN mencapai akurasi tertinggi sebesar 83,7%. Temuan ini mengindikasikan bahwa pendekatan hibrida yang menggabungkan *oversampling* dengan pembersihan data memberikan hasil lebih baik dibandingkan *oversampling* tunggal [11]. Penelitian tersebut menunjukkan bahwa pemilihan algoritma klasifikasi turut memengaruhi efektivitas teknik *oversampling* yang diterapkan.

Penelitian kelima dilakukan oleh Van FC *et al.* (2024) yang menerapkan SMOTE dan *random undersampling* pada klasifikasi sentimen media sosial menggunakan SVM [4]. Dataset yang digunakan berasal dari platform Twitter terkait Pemilu 2024 dengan distribusi kelas yang tidak seimbang. Tiga variasi kernel SVM diuji, yaitu Linear, RBF, dan Polynomial. Hasil percobaan menunjukkan bahwa SMOTE mampu meningkatkan akurasi SVM hingga 91%, khususnya pada kernel Polynomial yang menunjukkan peningkatan paling signifikan [4]. Sebaliknya, teknik *random undersampling* tidak memberikan peningkatan yang berarti pada seluruh variasi kernel yang diuji.

Berdasarkan tinjauan terhadap kelima penelitian pada Tabel ??, dapat diidentifikasi bahwa teknik *resampling* hibrida mampu meningkatkan performa klasifikasi pada data tidak seimbang. Namun demikian, terdapat celah penelitian

yang belum dieksplorasi. Pertama, HOUM yang diusulkan oleh Eroglu dan Pir hanya menggunakan konfigurasi *default* pada komponen SVM tanpa mengkaji pengaruh variasi parameter C dan jenis kernel [7]. Kedua, komponen *oversampling* pada HOUM hanya menggunakan Safe-Level SMOTE tanpa membandingkannya dengan teknik adaptif seperti ADASYN. Oleh karena itu, penelitian ini mengisi celah tersebut melalui variasi parameter C pada SVM (0.5, 1, 1.5, 2, 2.5, dan 3), perbandingan tiga jenis kernel (Linear, RBF, dan Polynomial), serta komparasi Safe-Level SMOTE dan ADASYN sebagai komponen *oversampling* pada HOUM.

2.2 Dasar Teori

Pada bagian ini dijelaskan konsep-konsep teoritis yang mendasari penelitian ini sebagai berikut.

2.2.1 Klasifikasi


Klasifikasi menjadi salah satu tugas utama dalam *machine learning* yang bertujuan memetakan data masukan ke dalam kategori atau kelas yang telah ditentukan sebelumnya [12]. Model klasifikasi dibangun melalui proses pelatihan menggunakan dataset berlabel, dimana algoritma mempelajari hubungan antara fitur masukan dan kelas keluaran. Setelah proses pelatihan selesai, model yang dihasilkan dapat digunakan untuk memprediksi kelas dari data baru yang tidak terdapat dalam dataset pelatihan. Tahapan utama dalam klasifikasi meliputi prapemrosesan data, ekstraksi fitur, pemilihan algoritma, pelatihan model, serta validasi menggunakan data uji [12], [13]. Kualitas hasil klasifikasi sangat dipengaruhi oleh representasi fitur yang digunakan dan kesesuaian algoritma terhadap karakteristik dataset.

Berdasarkan jumlah kelas keluaran, klasifikasi dibedakan menjadi dua jenis utama, yaitu klasifikasi *binary* yang melibatkan dua kelas dan klasifikasi *multi-class* yang melibatkan lebih dari dua kelas [12]. Klasifikasi *binary* banyak diterapkan pada permasalahan seperti deteksi penipuan, diagnosis penyakit, dan deteksi intrusi jaringan yang memerlukan pemisahan antara kelas positif dan negatif [1]. Klasifikasi *multi-class* diterapkan pada pengenalan karakter tulisan tangan, analisis sentimen multi-kategori, dan klasifikasi citra [14]. Beberapa algoritma klasifikasi yang banyak

digunakan meliputi *Decision Tree*, *K-Nearest Neighbors* (KNN), *Naive Bayes*, *Random Forest*, dan *Support Vector Machine* (SVM) [8]. Pemilihan algoritma yang tepat menjadi faktor penting yang menentukan akurasi dan kemampuan generalisasi model klasifikasi [14].

2.2.2 Ketidakseimbangan Data (*Class Imbalance*)

He dan Garcia (2009) mendefinisikan *imbalanced learning* sebagai permasalahan yang muncul ketika distribusi kelas dalam dataset pelatihan tidak seimbang, sehingga performa algoritma klasifikasi standar menjadi terganggu [1]. Kelas dengan jumlah sampel lebih banyak disebut kelas mayoritas, sedangkan kelas dengan jumlah sampel lebih sedikit disebut kelas minoritas. Rasio ketidakseimbangan antar kelas dapat bervariasi dari 100:1, 1.000:1, hingga 10.000:1, dimana satu kelas secara signifikan mendominasi kelas lainnya [1]. Kondisi ini banyak ditemui pada dataset dunia nyata seperti deteksi penipuan kartu kredit, diagnosis penyakit langka, deteksi intrusi jaringan, dan klasifikasi citra biomedis [2], [15]. Semakin tinggi rasio ketidakseimbangan, semakin sulit bagi algoritma klasifikasi konvensional untuk mempelajari pola kelas minoritas secara efektif [16]. Ilustrasi distribusi data tidak seimbang ditunjukkan pada Gambar 2.1.



Gambar 2.1 Ilustrasi Distribusi Data Tidak Seimbang

Algoritma klasifikasi standar pada umumnya dirancang untuk meminimalkan kesalahan klasifikasi secara keseluruhan tanpa memperhatikan distribusi kelas [5]. Chawla *et al.* (2002) menyatakan bahwa metrik akurasi tidak tepat digunakan

pada data tidak seimbang karena strategi sederhana berupa prediksi seluruh data ke kelas mayoritas sudah dapat menghasilkan akurasi yang tinggi [5]. He dan Garcia (2009) memberikan contoh pada dataset mammografi yang berisi 10.923 sampel negatif dan 260 sampel positif, dimana klasifier cenderung menghasilkan akurasi mendekati 100% pada kelas mayoritas namun hanya 0-10% pada kelas minoritas [1]. Konsekuensi dari bias semacam ini dapat sangat merugikan pada domain seperti kedokteran, dimana kegagalan mendeteksi pasien sakit jauh lebih berbahaya daripada kesalahan diagnosis sebaliknya [1]. Oleh karena itu, diperlukan metrik evaluasi yang lebih informatif seperti kurva ROC, *precision-recall*, dan *cost curves* untuk menilai performa model secara menyeluruh [1], [17].

Tingkat ketidakseimbangan pada suatu dataset dapat diukur menggunakan *imbalance ratio* (IR), yaitu perbandingan antara jumlah sampel kelas mayoritas dengan jumlah sampel kelas minoritas sebagaimana ditunjukkan pada Rumus 2.1.

$$IR = \frac{N_{majority}}{N_{minority}}$$

Rumus 2.1 Imbalance Ratio (IR)

Keterangan:


$N_{majority}$ = jumlah sampel kelas mayoritas

$N_{minority}$ = jumlah sampel kelas minoritas

He dan Garcia (2009) mengklasifikasikan pendekatan penanganan data tidak seimbang ke dalam empat kategori utama [1]. Kategori pertama adalah metode *sampling* yang memodifikasi distribusi dataset melalui teknik *oversampling* atau *undersampling* untuk menyeimbangkan representasi kelas. Kategori kedua adalah *cost-sensitive learning* yang menetapkan biaya berbeda untuk kesalahan klasifikasi pada masing-masing kelas, sehingga kesalahan pada kelas minoritas mendapat penalti yang lebih besar [1]. Kategori ketiga adalah metode berbasis kernel yang memodifikasi matriks kernel untuk mengakomodasi ketidakseimbangan distribusi data [1]. Kategori keempat adalah *active learning* yang secara selektif memilih sampel paling informatif untuk pelabelan guna mengurangi biaya komputasi pada dataset tidak seimbang yang besar [1].

2.2.3 Oversampling

Oversampling termasuk teknik penanganan data tidak seimbang pada level data yang bekerja dengan menambah jumlah sampel pada kelas minoritas hingga distribusi antar kelas menjadi lebih seimbang. Bunkhumpornpat *et al.* (2009) menjelaskan bahwa teknik *re-sampling* paling sederhana adalah *random oversampling* yang menduplikasi sampel kelas minoritas secara acak hingga kedua kelas memiliki representasi yang setara [6]. Namun, teknik ini berpotensi menyebabkan *overfitting* karena area keputusan yang dihasilkan menjadi lebih sempit dan spesifik akibat duplikasi data identik [6]. Untuk mengatasi keterbatasan tersebut, dikembangkan teknik *oversampling* berbasis sintesis yang menghasilkan sampel baru melalui interpolasi antar data minoritas yang sudah ada [5]. Kovács (2019) melakukan perbandingan empiris terhadap 85 teknik *oversampling* minoritas pada 104 dataset dan menemukan bahwa teknik sintesis data secara signifikan mengungguli *random oversampling* dalam berbagai skenario klasifikasi [18], [19]. Ilustrasi teknik *oversampling* ditunjukkan pada Gambar 2.2.



Gambar 2.2 Ilustrasi Teknik *Oversampling*

2.2.3.1 SMOTE (*Synthetic Minority Over-sampling Technique*)

Chawla *et al.* (2002) mengusulkan SMOTE sebagai teknik *oversampling* dengan pendekatan menghasilkan sampel sintetis kelas minoritas melalui interpolasi antar sampel yang sudah ada [5]. Chawla *et al.* menyatakan bahwa SMOTE bekerja dengan mengambil setiap sampel kelas minoritas, kemudian menghasilkan data sintetis di sepanjang segmen garis yang menghubungkan sampel tersebut dengan k tetangga terdekatnya dari kelas yang sama [5]. Pendekatan ini menghasilkan area keputusan yang lebih luas dan umum dibandingkan *random oversampling* yang hanya menduplikasi data identik [5]. Elreedy dan Atiya (2019) mencatat bahwa SMOTE telah menjadi salah satu teknik penanganan data tidak seimbang yang paling dominan dalam literatur dan menjadi fondasi bagi pengembangan lebih dari 85 varian [19], [20]. Proses pembentukan sampel sintetis secara matematis ditunjukkan pada Rumus 2.2.

$$x_{new} = x_i + \lambda \times (x_{nn} - x_i)$$

Rumus 2.2 Pembentukan Sampel Sintetis SMOTE

Keterangan:

x_{new} = sampel sintetis baru

x_i = sampel kelas minoritas

x_{nn} = tetangga terdekat yang dipilih

λ = bilangan acak dalam rentang [0, 1]

Bunkhumpornpat *et al.* (2009) mengidentifikasi bahwa SMOTE memiliki kelemahan berupa masalah *overgeneralization*, yaitu SMOTE secara buta memperluas area kelas minoritas tanpa mempertimbangkan keberadaan kelas mayoritas di sekitarnya [6]. Strategi ini menjadi problematik pada distribusi kelas yang sangat timpang karena kelas minoritas tersebar sangat jarang di antara kelas mayoritas, sehingga peluang tercampurnya kedua kelas menjadi lebih besar [6]. Han *et al.* (2005) mengamati bahwa sampel sintetis yang dihasilkan di area *noise* atau di dalam wilayah kelas mayoritas dapat mengaburkan batas keputusan dan menurunkan performa klasifikasi [21]. Kelemahan-kelemahan ini mendorong pengembangan berbagai varian SMOTE seperti Borderline-SMOTE yang hanya

melakukan interpolasi pada sampel di area perbatasan, Safe-Level SMOTE yang mempertimbangkan tingkat keamanan posisi interpolasi, dan ADASYN yang mendistribusikan sampel sintetis secara adaptif [6], [9], [21]. Tarawneh *et al.* (2022) menambahkan bahwa sensitivitas SMOTE terhadap *outlier* menjadi perhatian utama karena sampel minoritas yang merupakan *outlier* tetap dijadikan basis interpolasi [22].

2.2.3.2 Safe-Level SMOTE

Bunkhumpornpat *et al.* (2009) mengembangkan Safe-Level SMOTE dari SMOTE untuk mengatasi masalah pembentukan sampel sintetis di area yang tidak aman [6]. Konsep utama metode ini adalah memberikan setiap sampel kelas minoritas suatu nilai *safe level* sebelum proses sintesis dilakukan. Bunkhumpornpat *et al.* mendefinisikan *safe level* sebagai jumlah tetangga terdekat yang berasal dari kelas minoritas yang sama [6]. Sampel dengan *safe level* mendekati k menandakan bahwa sampel tersebut berada di area yang aman dan didominasi oleh kelasnya sendiri. Sebaliknya, sampel dengan *safe level* mendekati 0 mengindikasikan sampel yang mendekati *noise* karena dikelilingi oleh kelas mayoritas [6].

Penempatan sampel sintetis ditentukan oleh *safe level ratio* antara sampel asli p dan tetangga n yang dihitung sebagai sl_p/sl_n [6]. Bunkhumpornpat *et al.* mendefinisikan lima kasus berdasarkan nilai rasio ini. Apabila rasio bernilai tak hingga dan *safe level* keduanya nol, maka keduanya dianggap *noise* dan sampel sintetis tidak dihasilkan. Apabila rasio bernilai tak hingga namun *safe level* p bukan nol, maka sampel sintetis dihasilkan dengan menduplikasi p untuk menjauhi tetangga yang merupakan *noise*. Apabila rasio bernilai 1, sampel sintetis ditempatkan di posisi acak sepanjang garis antara p dan n karena keduanya memiliki tingkat keamanan yang setara [6]. Apabila rasio lebih besar dari 1, sampel sintetis ditempatkan lebih dekat ke p yang lebih aman, dan sebaliknya apabila rasio kurang dari 1, sampel ditempatkan lebih dekat ke n [6]. Hasil eksperimen Bunkhumpornpat *et al.* menunjukkan bahwa Safe-Level SMOTE menghasilkan akurasi yang lebih baik dibandingkan SMOTE dan Borderline-SMOTE pada berbagai dataset pengujian [6].

2.2.3.3 ADASYN (*Adaptive Synthetic Sampling*)

He *et al.* (2008) mengusulkan ADASYN sebagai teknik *oversampling* adaptif dengan ide utama menggunakan distribusi berbobot untuk sampel kelas minoritas berdasarkan tingkat kesulitan dalam proses klasifikasi [9]. He *et al.* menjelaskan bahwa ADASYN menghasilkan lebih banyak data sintetis untuk sampel kelas minoritas yang lebih sulit dipelajari dibandingkan sampel yang lebih mudah [9]. Pendekatan ini mempunyai dua tujuan: mengurangi bias yang ditimbulkan oleh ketidakseimbangan distribusi kelas, dan secara adaptif menggeser batas keputusan ke arah sampel yang sulit diklasifikasikan [9]. Tahap pertama ADASYN menghitung derajat ketidakseimbangan $d = m_s/m_l$ dan total sampel sintetis yang diperlukan $G = (m_l - m_s) \times \beta$, dimana $\beta \in [0, 1]$ menentukan tingkat keseimbangan yang diinginkan [9]. Distribusi bobot yang menentukan jumlah sampel sintetis untuk setiap sampel kelas minoritas dihitung sebagaimana ditunjukkan pada Rumus 2.3.

$$\hat{r}_i = \frac{r_i}{\sum_{i=1}^{m_s} r_i}, \quad r_i = \frac{\Delta_i}{k}$$

Rumus 2.3 Distribusi Bobot ADASYN

Keterangan:

$\hat{r}_i$ = bobot ternormalisasi sampel x_i

Δ_i = jumlah tetangga dari kelas mayoritas

k = jumlah tetangga terdekat


m_s = total sampel kelas minoritas

Jumlah sampel sintetis untuk setiap x_i dihitung menggunakan formula $g_i = \hat{r}_i \times G$, dimana G menyatakan total sampel yang perlu ditambahkan agar distribusi kelas menjadi seimbang [9]. He *et al.* menjelaskan bahwa $\hat{r}_i$ secara fisik menjadi pengukuran distribusi bobot untuk berbagai sampel kelas minoritas berdasarkan tingkat kesulitannya dalam proses pembelajaran [9]. Sampel dengan nilai $\hat{r}_i$ lebih tinggi berarti dikelilingi oleh lebih banyak tetangga kelas mayoritas sehingga lebih sulit diklasifikasikan dan memperoleh lebih banyak data sintetis [9]. Setiap sampel sintetis dibentuk melalui interpolasi $s_i = x_i + (x_{zi} - x_i) \times \lambda$ dengan $\lambda \in [0, 1]$ dan x_{zi} merupakan tetangga minoritas yang dipilih secara acak [9]. Namun, Elreedy dan Atiya (2019) mencatat bahwa ADASYN berpotensi menghasilkan data sintetis di

area *noise* apabila sampel minoritas yang menjadi acuan merupakan *outlier* yang dikelilingi oleh kelas mayoritas [20].

2.2.4 Undersampling

Undersampling termasuk teknik penanganan data tidak seimbang yang bekerja dengan mengurangi jumlah sampel pada kelas mayoritas hingga distribusi antar kelas menjadi lebih proporsional. Bunkhumpornpat *et al.* (2009) menyatakan bahwa *random undersampling* menghapus sampel kelas mayoritas secara acak hingga kedua kelas memiliki jumlah yang setara, namun teknik ini berpotensi menghilangkan informasi penting dari dataset [6]. Elreedy dan Atiya (2019) mencatat bahwa *undersampling* bersifat berisiko karena informasi penting yang potensial dapat hilang dari proses penghapusan [20]. Untuk mengatasi risiko tersebut, dikembangkan teknik *undersampling* yang lebih terstruktur berdasarkan aturan heuristik tertentu. Beberapa teknik yang banyak digunakan antara lain Tomek Links, *Edited Nearest Neighbors* (ENN), *condensed nearest neighbor rule*, dan *one-sided selection* [20], [23]. Ilustrasi teknik *undersampling* ditunjukkan pada Gambar 2.3.



Gambar 2.3 Ilustrasi Teknik *Undersampling*

2.2.5 Metode Hibrida (*Hybrid Resampling*)


Metode hibrida menggabungkan teknik *oversampling* dan *undersampling* dalam satu kerangka kerja untuk menangani data tidak seimbang dengan memanfaatkan kelebihan keduanya secara bersamaan. He dan Garcia (2009) menjelaskan bahwa komunitas *machine learning* menangani permasalahan ketidakseimbangan kelas melalui dua cara utama: memberikan biaya berbeda pada setiap sampel pelatihan, atau melakukan *re-sampling* melalui *oversampling* kelas minoritas dan/atau *undersampling* kelas mayoritas [1]. Chawla *et al.* (2002) menunjukkan bahwa kombinasi *oversampling* kelas minoritas menggunakan SMOTE dengan *undersampling* kelas mayoritas menghasilkan performa klasifikasi yang lebih baik dalam ruang ROC dibandingkan penggunaan *undersampling* tunggal [5]. Penggabungan kedua teknik bertujuan menghasilkan dataset yang seimbang tanpa kehilangan informasi penting dari kelas mayoritas maupun menciptakan *overfitting* pada kelas minoritas. Pendekatan ini telah terbukti efektif pada berbagai domain aplikasi.

Batista *et al.* (2004) memperkenalkan dua kombinasi hibrida yang paling banyak dirujuk dalam literatur, yaitu SMOTETomek dan SMOTEENN [23]. SMOTETomek mengombinasikan SMOTE untuk menambah sampel kelas minoritas dengan Tomek Links untuk menghapus pasangan sampel yang saling berdekatan dari kelas berbeda. SMOTEENN mengombinasikan SMOTE dengan *Edited Nearest Neighbors* yang membersihkan sampel yang salah diklasifikasikan oleh tetangga terdekatnya. Batista *et al.* menunjukkan melalui eksperimen pada 13 dataset bahwa SMOTETomek dan SMOTEENN secara konsisten menghasilkan performa yang lebih baik dibandingkan SMOTE atau *random undersampling* secara terpisah [23]. Temuan serupa dilaporkan oleh Hou *et al.* (2025) pada domain prediksi *financial distress* yang mengonfirmasi keunggulan pendekatan hibrida dibandingkan teknik tunggal [3].

2.2.6 HOUM (*Hybrid Oversampling and Undersampling Method*)

Eroglu dan Pir (2024) merancang HOUM sebagai metode penanganan data tidak seimbang yang mengombinasikan Safe-Level SMOTE untuk *oversampling* dan SVM untuk *undersampling* secara iteratif [7]. Metode ini dikembangkan

untuk mengatasi kelemahan penggunaan teknik *resampling* tunggal yang seringkali tidak mampu menghasilkan distribusi data yang optimal pada dataset dengan rasio ketidakseimbangan tinggi. Komponen Safe-Level SMOTE bertugas menambah sampel kelas minoritas di area yang aman berdasarkan perhitungan *safe level*, sehingga sampel sintetis tidak terbentuk di wilayah yang didominasi kelas mayoritas. Komponen SVM bertugas menghapus sampel kelas mayoritas yang memiliki kontribusi rendah terhadap pembentukan *decision boundary*, yaitu sampel yang berada jauh dari *hyperplane* pemisah. Kombinasi keduanya menghasilkan distribusi data yang lebih representatif dibandingkan penggunaan masing-masing teknik secara terpisah [7].



Gambar 2.4 Alur Kerja Metode HOUM

Alur kerja HOUM ditunjukkan pada Gambar 2.4. Proses kerja HOUM dimulai dengan perhitungan *imbalance ratio* pada dataset untuk menentukan apakah proses penyeimbangan perlu dilakukan [7]. Apabila distribusi kelas belum mencapai keseimbangan yang ditentukan, algoritma menjalankan dua tahap secara bergantian dalam setiap iterasi. Pada tahap pertama, SVM dilatih menggunakan dataset yang tersedia kemudian data kelas mayoritas yang berada di luar batas *margin* dihapus karena dianggap kurang informatif. Pada tahap kedua, Safe-Level SMOTE

digunakan untuk menambah sampel kelas minoritas di posisi yang dianggap aman berdasarkan komposisi tetangga terdekat. Kedua tahap tersebut diulang secara iteratif hingga rasio antara kelas mayoritas dan kelas minoritas mencapai keseimbangan yang diharapkan [7].

Pendekatan iteratif pada HOUM memberikan keunggulan karena *decision boundary* SVM diperbarui pada setiap putaran berdasarkan distribusi data terkini, sehingga pemilihan data yang dihapus menjadi semakin tepat pada iterasi berikutnya [7]. Safe-Level SMOTE yang dijalankan pada setiap iterasi dapat menyesuaikan posisi dan jumlah sampel sintetis sesuai dengan kebutuhan distribusi terbaru. Pengujian yang dilakukan oleh Eroglu dan Pir pada delapan dataset dari UCI *Machine Learning Repository* menunjukkan bahwa HOUM mampu mengungguli metode pembanding seperti SMOTE, SMOTEENN, SMOTETomek, W-SIMO, dan RusAda [7]. Hasil eksperimen menunjukkan peningkatan yang konsisten pada metrik G-mean dan ROC-AUC, yang mengonfirmasi kemampuan HOUM dalam menyeimbangkan performa klasifikasi pada kedua kelas secara bersamaan [7].

2.2.7 Support Vector Machine (SVM)

Cortes dan Vapnik (1995) pertama kali memperkenalkan SVM sebagai algoritma klasifikasi yang telah menjadi salah satu metode paling banyak digunakan dalam *machine learning* karena kemampuannya dalam menangani data berdimensi tinggi dan menghasilkan *decision boundary* yang optimal [8]. Ide dasar SVM yaitu mencari *hyperplane* pemisah yang memaksimalkan margin antara dua kelas, dimana margin didefinisikan sebagai jarak terpendek antara *hyperplane* dengan sampel data terdekat dari masing-masing kelas. *Hyperplane* tersebut menjadi bidang pemisah berdimensi $n-1$ dalam ruang fitur berdimensi n yang memisahkan data dari dua kelas yang berbeda. Data yang terletak paling dekat dengan *hyperplane* dan menentukan posisi serta orientasinya disebut sebagai *support vectors* [8], [14]. Fungsi keputusan SVM untuk klasifikasi *binary* dapat dirumuskan sebagaimana ditunjukkan pada Rumus 2.4.

$$f(x) = \text{sign}(w \cdot x + b)$$

Rumus 2.4 Fungsi Keputusan SVM


Keterangan:

$f(x)$ = hasil prediksi kelas

w = vektor bobot

x = vektor fitur masukan

b = bias



Gambar 2.5 Ilustrasi SVM

Gambar 2.5 merupakan ilustrasi cara kerja SVM dalam memisahkan dua kelas data. SVM mencari *hyperplane* optimal yang memaksimalkan margin antara kedua kelas [8]. Margin didefinisikan sebagai jarak antara *hyperplane* dengan sampel data terdekat dari masing-masing kelas, dimana sampel tersebut disebut *support vectors* karena menjadi penentu posisi dan orientasi *hyperplane* [14]. Vektor bobot w tegak lurus terhadap *hyperplane* dan menentukan arah pemisahan, sedangkan bias b mengatur posisi *hyperplane* terhadap titik asal. Data yang berada di sisi positif *hyperplane* diklasifikasikan ke satu kelas, sedangkan data di sisi negatif diklasifikasikan ke kelas lainnya [8]. Dengan memaksimalkan margin, SVM menghasilkan model yang memiliki kemampuan generalisasi yang baik terhadap data baru yang belum pernah ditemui [8], [14].

Pada banyak permasalahan nyata, data tidak selalu dapat dipisahkan secara linear dalam ruang fitur aslinya karena distribusi data seringkali bersifat nonlinear [8]. Untuk menangani kasus tersebut, SVM menggunakan *kernel trick* yang memetakan data ke ruang fitur berdimensi lebih tinggi dimana data menjadi separabel secara

linear. Fungsi kernel menghitung *dot product* pada ruang berdimensi tinggi tanpa perlu melakukan transformasi secara eksplisit, sehingga komputasi tetap efisien meskipun dimensi ruang transformasi sangat besar [8], [14]. Cervantes *et al.* (2020) mengidentifikasi bahwa pemilihan kernel yang tepat merupakan salah satu faktor kunci yang menentukan performa SVM pada berbagai domain aplikasi [8]. Tiga jenis kernel yang digunakan dalam penelitian ini adalah sebagai berikut:

1. Kernel Linear

Kernel linear menghitung perkalian titik antara dua vektor dengan persamaan yang ditunjukkan pada Rumus 2.5.

$$K(x_i, x_j) = x_i^T x_j$$

Rumus 2.5 Kernel Linear

Keterangan:

x_i = data latih

x_j = data uji

2. Kernel Polynomial

Kernel polynomial memiliki dua parameter utama, yaitu c dan d , dengan persamaan yang ditunjukkan pada Rumus 2.6.

$$K(x_i, x_j) = (\gamma(x_i \cdot x_j) + c)^d$$

Rumus 2.6 Kernel Polynomial

Keterangan:

x_i = data latih

x_j = data uji

c = nilai konstan

d = derajat polynomial

3. Kernel RBF (*Radial Basis Function*)

Kernel RBF sering digunakan untuk data yang tidak bisa dipisahkan secara linear, dengan persamaan yang ditunjukkan pada Rumus 2.7.

$$K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$$

Rumus 2.7 Kernel RBF


Keterangan:

x_i = data latih

x_j = data uji

$\|x_i - x_j\|^2$ = jarak euclidean kuadrat

γ = parameter yang menentukan pengaruh setiap sampel data latih



Gambar 2.6 Ilustrasi *Hyperplane* di Masing-masing Kernel

(Sumber: https://scikit-learn.org/stable/auto_examples/svm/plot_svm_kernels.html)

Gambar 2.6 menunjukkan visualisasi batas keputusan (*decision boundary*) dari tiga kernel yang berbeda. Kernel Linear memisahkan data dengan garis lurus, kernel Polynomial menghasilkan batas keputusan melengkung, dan kernel RBF menunjukkan pola yang fleksibel sehingga cocok untuk data nonlinear.

Parameter regularisasi C pada SVM berfungsi mengontrol keseimbangan antara lebar margin dan toleransi kesalahan klasifikasi pada data pelatihan, dimana nilai C berada dalam rentang $0 < C < \infty$ [8]. Nilai C yang kecil menghasilkan margin yang lebih lebar dan memperbolehkan lebih banyak kesalahan klasifikasi sehingga model kurang rentan terhadap *overfitting*. Sebaliknya, nilai C yang besar menghasilkan margin yang lebih sempit dan berusaha meminimalkan setiap kesalahan pada data pelatihan, namun berisiko *overfitting* [8], [24]. Pemilihan nilai C yang tepat sangat

penting karena berpengaruh langsung terhadap kemampuan generalisasi model terhadap data yang belum pernah ditemui.

SVM terbukti efektif pada data berdimensi tinggi dan telah banyak diterapkan pada berbagai domain seperti pengenalan wajah, diagnosis penyakit, analisis sentimen, dan deteksi intrusi jaringan [14]. Namun, SVM standar memiliki keterbatasan dalam menangani data tidak seimbang karena fungsi optimasinya cenderung menghasilkan *hyperplane* yang bias terhadap kelas mayoritas [24], [25]. Tang *et al.* (2009) mengidentifikasi bahwa pada data tidak seimbang, *support vectors* lebih banyak berasal dari kelas mayoritas sehingga *hyperplane* bergeser ke arah kelas minoritas [25]. Rezvani *et al.* (2024) mengategorikan pendekatan SVM untuk menangani data tidak seimbang ke dalam tiga kelompok, yaitu metode *re-sampling*, metode algoritmik, dan metode fusi, yang masing-masing berupaya mengatasi bias melalui mekanisme yang berbeda [24]. Berbagai modifikasi SVM untuk data tidak seimbang terus dikembangkan guna meningkatkan kemampuan algoritma ini dalam mengklasifikasikan kedua kelas secara berimbang [24].

2.2.8 Metrik Evaluasi

Metrik evaluasi berfungsi sebagai ukuran kuantitatif untuk menilai seberapa baik model klasifikasi mampu melakukan prediksi terhadap data uji [26]. Sokolova dan Lapalme (2009) menyatakan bahwa pemilihan metrik evaluasi yang tepat bergantung pada karakteristik permasalahan dan tujuan klasifikasi yang ingin dicapai [26]. Pada domain data tidak seimbang, dibutuhkan metrik yang mampu mengukur performa model pada setiap kelas secara terpisah sehingga kemampuan model dalam mengenali kelas minoritas dapat terlihat dengan jelas [27]. Fawcett (2006) menekankan bahwa teknik evaluasi berbasis kurva ROC menjadi standar untuk merangkum performa klasifikasi pada berbagai titik operasi [17]. Beberapa metrik yang umum digunakan untuk mengevaluasi performa klasifikasi pada data tidak seimbang antara lain *Recall*, *Precision*, *G-mean*, dan *ROC-AUC* [26], [28].

2.2.8.1 *Recall*

Recall atau *sensitivity* mengukur proporsi sampel positif yang berhasil dideteksi oleh model dari seluruh sampel positif yang sebenarnya ada dalam dataset [27]. Metrik ini sangat penting pada data tidak seimbang karena menunjukkan kemampuan model dalam mengenali kelas minoritas yang seringkali menjadi target deteksi utama. Nilai *Recall* yang rendah menandakan bahwa model banyak melewatkan sampel positif yang seharusnya terdeteksi, yang disebut sebagai *False Negative*. Pada kasus seperti diagnosis penyakit, nilai *Recall* yang rendah bermakna banyak pasien sakit yang tidak terdiagnosis sehingga dapat berakibat fatal [17], [26]. Rumus *Recall* ditunjukkan pada Rumus 2.8.

$$Recall = \frac{TP}{TP + FN}$$

Rumus 2.8 Recall (Sensitivity)

Keterangan:

$TP = True\ Positive$

$FN = False\ Negative$

2.2.8.2 *Precision*

Precision mengukur proporsi prediksi positif yang benar-benar termasuk sampel positif dari seluruh data yang diprediksi sebagai positif oleh model [27]. Metrik ini menunjukkan seberapa akurat model ketika memberikan label positif pada suatu data, yang penting untuk menilai tingkat kepercayaan terhadap prediksi positif. Nilai *Precision* yang rendah menandakan bahwa model menghasilkan banyak *false alarm* atau prediksi positif yang salah sehingga mengurangi kepercayaan terhadap hasil prediksi. Pada konteks deteksi penipuan kartu kredit, nilai *Precision* yang rendah berarti banyak transaksi sah yang salah ditandai sebagai penipuan dan memerlukan investigasi tambahan yang tidak perlu [26], [28]. Rumus *Precision* ditunjukkan pada Rumus 2.9.

$$Precision = \frac{TP}{TP + FP}$$

Rumus 2.9 Precision

Keterangan:

$TP = \text{True Positive}$

$FP = \text{False Positive}$

2.2.8.3 G-mean

G-mean atau *Geometric Mean* mengukur keseimbangan performa model pada kedua kelas secara bersamaan melalui perhitungan rata-rata geometris antara *sensitivity* dan *specificity* [27]. Metrik ini dihitung sebagai akar kuadrat dari perkalian *sensitivity* yang mengukur kemampuan mendeteksi kelas positif dengan *specificity* yang mengukur kemampuan mendeteksi kelas negatif. Luque *et al.* (2019) membuktikan secara analitis bahwa G-mean memiliki bias bernilai nol terhadap ketidakseimbangan kelas (*null-biased*), yang berarti nilai metrik ini tidak terpengaruh oleh proporsi kelas dalam dataset [27]. Apabila model hanya unggul pada satu kelas namun buruk pada kelas lainnya, nilai G-mean akan turun secara signifikan karena sifat perkalian pada rata-rata geometris. Karakteristik ini menjadikan G-mean sangat cocok untuk mengevaluasi model pada data tidak seimbang, dimana keseimbangan performa pada kedua kelas merupakan tujuan utama [27]. Rumus G-mean ditunjukkan pada Rumus 2.10.

$$G\text{-mean} = \sqrt{\frac{TP}{TP + FN} \times \frac{TN}{TN + FP}}$$

Rumus 2.10 G-mean (Geometric Mean)

Keterangan:

$TP = \text{True Positive}$

$TN = \text{True Negative}$

$FP = \text{False Positive}$

$FN = \text{False Negative}$

Nilai G-mean yang tinggi menandakan bahwa model memiliki performa yang baik dan seimbang pada kedua kelas, yaitu kelas positif maupun kelas negatif. Metrik ini akan bernilai nol apabila model gagal total pada salah satu kelas, meskipun performa pada kelas lainnya mencapai nilai sempurna. Sifat ini sangat berguna dalam konteks data tidak seimbang dimana model yang hanya mampu mengklasifikasikan kelas mayoritas dengan benar akan tetap memperoleh G-mean senilai nol [27]. Chicco dan Jurman (2023) merekomendasikan penggunaan metrik

yang sensitif terhadap kedua kelas seperti G-mean dan MCC untuk menghindari kesalahan interpretasi yang sering terjadi saat menggunakan akurasi pada data tidak seimbang [29]. Karakteristik tersebut menjadikan G-mean sebagai salah satu metrik yang paling sesuai untuk mengevaluasi performa model pada dataset dengan distribusi kelas yang tidak seimbang [27].

2.2.8.4 ROC-AUC

ROC-AUC (*Receiver Operating Characteristic - Area Under the Curve*) mengukur kemampuan diskriminatif model dalam membedakan kelas positif dan kelas negatif pada berbagai nilai *threshold* keputusan [17]. Kurva ROC dibentuk dengan membuat plot *True Positive Rate* (TPR) terhadap *False Positive Rate* (FPR) untuk setiap kemungkinan nilai ambang batas, sehingga memberikan gambaran menyeluruh tentang performa model pada seluruh titik operasi. Model dengan kemampuan diskriminatif yang baik memiliki kurva ROC yang mendekati sudut kiri atas grafik, sedangkan model yang melakukan prediksi secara acak menghasilkan garis diagonal [17]. AUC merangkum informasi dari seluruh kurva ROC ke dalam satu nilai skalar antara 0 dan 1 yang mudah dibandingkan antar model. Luque *et al.* (2019) menunjukkan bahwa AUC ekuivalen dengan *Bookmaker Informedness* yang ternormalisasi (*BMn*) pada kasus klasifikasi dengan *threshold* tunggal, sehingga AUC bersifat *null-biased* terhadap ketidakseimbangan kelas [27]. Rumus TPR dan FPR ditunjukkan pada Rumus 2.11.


$$TPR = \frac{TP}{TP + FN}, \quad FPR = \frac{FP}{FP + TN}$$

Rumus 2.11 True Positive Rate dan False Positive Rate

Keterangan:

TPR = *True Positive Rate*

FPR = *False Positive Rate*



Gambar 2.7 Ilustrasi Kurva ROC-AUC


Ilustrasi kurva ROC-AUC ditunjukkan pada Gambar 2.7. Nilai AUC berkisar antara 0 hingga 1, dimana nilai 1 menunjukkan model yang memiliki kemampuan diskriminatif sempurna dan nilai 0,5 menunjukkan model yang tidak lebih baik dari prediksi acak [17]. Fawcett (2006) menjelaskan bahwa AUC dapat diinterpretasikan sebagai probabilitas bahwa model memberikan skor lebih tinggi pada sampel positif yang dipilih secara acak dibandingkan sampel negatif yang dipilih secara acak [17]. Keunggulan utama ROC-AUC sebagai metrik evaluasi adalah kemampuannya untuk memberikan penilaian performa yang tidak terpengaruh oleh ketidakseimbangan distribusi kelas maupun distribusi skor keputusan [27]. ROC-AUC direkomendasikan sebagai metrik standar untuk perbandingan performa model klasifikasi pada berbagai domain yang melibatkan data tidak seimbang [17], [28]. Metrik ini banyak digunakan bersamaan dengan *G-mean*, *Recall*, dan *Precision* untuk memberikan evaluasi performa yang menyeluruh pada berbagai sudut pandang [26].

BAB III

METODE PENELITIAN

3.1 Alur Penelitian

Penelitian ini dilaksanakan melalui beberapa tahapan yang disusun secara berurutan agar proses pengolahan data dan eksperimen dapat berjalan dengan terstruktur. Setiap tahapan saling berkaitan satu sama lain, mulai dari pengumpulan dataset hingga analisis hasil klasifikasi. Gambaran umum mengenai alur penelitian yang dilakukan dapat dilihat pada Gambar 3.1.



Gambar 3.1 Alur Penelitian

3.2 Penjabaran Langkah Penelitian

Bagian ini menjelaskan secara rinci setiap tahapan yang telah digambarkan pada Gambar 3.1. Penjelasan mencakup proses mulai dari identifikasi permasalahan, pengumpulan dataset, hingga tahapan akhir berupa analisis hasil eksperimen.

3.2.1 Identifikasi Masalah

Tahap awal penelitian dimulai dengan melakukan identifikasi terhadap permasalahan yang akan diteliti. Permasalahan utama yang melatarbelakangi penelitian ini adalah ketidakseimbangan distribusi kelas pada dataset klasifikasi, yang menyebabkan model *machine learning* cenderung bias terhadap kelas mayoritas dan gagal mengenali kelas minoritas secara efektif [1]. Eroglu dan Pir (2024) telah mengusulkan metode HOUM yang menggabungkan Safe-Level SMOTE dan SVM

untuk menangani permasalahan ini, namun beberapa aspek dari metode tersebut belum dieksplorasi secara mendalam [7]. Aspek pertama adalah pengaruh variasi parameter regularisasi C dan jenis kernel pada komponen SVM terhadap kualitas proses *undersampling*. Aspek kedua adalah perbandingan performa antara Safe-Level SMOTE yang digunakan pada HOUM asli dengan teknik *oversampling* alternatif seperti ADASYN. Kedua aspek tersebut menjadi fokus utama yang akan dianalisis dalam penelitian ini untuk mengisi celah penelitian yang ada.

3.2.2 Studi Literatur

Setelah permasalahan teridentifikasi, tahap selanjutnya adalah melakukan studi literatur untuk memahami konsep-konsep yang berkaitan dengan topik penelitian. Studi literatur dilakukan dengan mengkaji berbagai jurnal ilmiah, prosiding konferensi, dan artikel yang membahas tentang penanganan data tidak seimbang, teknik *oversampling* dan *undersampling*, serta metode hibrida. Beberapa topik utama yang dipelajari meliputi algoritma SMOTE beserta varian-varianannya seperti Safe-Level SMOTE dan ADASYN, mekanisme kerja SVM sebagai algoritma klasifikasi dan perannya dalam proses *undersampling*, serta metrik evaluasi yang sesuai untuk data tidak seimbang seperti ROC-AUC, G-mean, *Recall*, dan *Precision*. Kajian terhadap paper HOUM oleh Eroglu dan Pir (2024) menjadi rujukan utama untuk memahami arsitektur metode dan mengidentifikasi celah penelitian yang belum dieksplorasi [7]. Hasil dari studi literatur ini menjadi landasan dalam menyusun kerangka eksperimen dan menentukan variabel-variabel yang akan diuji pada penelitian ini.

3.2.3 Pengumpulan Data

Dataset yang digunakan pada penelitian ini merupakan tiga dataset benchmark yang digunakan oleh Eroglu dan Pir (2024) dalam pengujian metode HOUM [7]. Ketiga dataset tersebut dipilih karena memiliki karakteristik ketidakseimbangan kelas yang berbeda-beda, sehingga dapat merepresentasikan berbagai tingkat kesulitan dalam penanganan data tidak seimbang. Dataset diperoleh dari dua sumber publik yang umum digunakan dalam penelitian *machine learning*, yaitu Kaggle dan

UCI *Machine Learning Repository*. Pemilihan dataset yang sama dengan penelitian asli HOUM bertujuan agar hasil eksperimen dapat dibandingkan secara langsung dengan temuan sebelumnya. Ringkasan karakteristik ketiga dataset ditunjukkan pada Tabel 3.1.

Tabel 3.1 Karakteristik Dataset yang Digunakan

Dataset	Fitur	Instansi	Mayoritas	Minoritas	IR
Diabetes	9	768	500	268	1:1,87
Haberman	4	305	224	81	1:2,77
Transfusion	5	748	570	178	1:3,20

Dataset Pima Indians Diabetes memuat data rekam medis pasien perempuan keturunan Pima Indian berusia minimal 21 tahun, dengan target klasifikasi berupa diagnosis positif atau negatif diabetes. Dataset ini memiliki 768 instansi dengan 9 fitur numerik yang mencakup informasi seperti jumlah kehamilan, konsentrasi glukosa plasma, tekanan darah, dan indeks massa tubuh. Rasio ketidakseimbangan pada dataset ini tergolong rendah yaitu 1:1,87 sehingga dapat merepresentasikan kondisi *imbalance* tingkat rendah.

Dataset Haberman berisi data kelangsungan hidup pasien yang menjalani operasi kanker payudara di Rumah Sakit University of Chicago antara tahun 1958 hingga 1970. Dataset ini terdiri dari 305 instansi dengan 4 fitur yang meliputi usia pasien saat operasi, tahun operasi, dan jumlah kelenjar getah bening aksila positif yang terdeteksi. Target klasifikasi pada dataset ini adalah apakah pasien bertahan hidup selama lima tahun atau lebih setelah operasi. Rasio ketidakseimbangan sebesar 1:2,77 menempatkan dataset ini pada tingkat *imbalance* yang sedikit lebih tinggi dibandingkan Diabetes.


Dataset Blood Transfusion Service Center memuat data donor darah yang dikumpulkan dari pusat layanan transfusi darah di Taiwan. Dataset ini terdiri dari 748 instansi dengan 5 fitur yang mencakup informasi seperti waktu sejak donasi terakhir (*recency*), frekuensi donasi, total volume darah yang didonasikan, dan lama waktu sejak donasi pertama. Target klasifikasi berupa keputusan apakah donor akan mendonasikan darahnya pada periode berikutnya atau tidak. Rasio ketidakseimbangan sebesar 1:3,20 menjadikan dataset ini memiliki tingkat

imbalance tertinggi di antara ketiga dataset yang digunakan.

Masing-masing dataset dibagi menjadi dua bagian, yaitu data *training* sebesar 80% dan data uji sebesar 20% menggunakan teknik *stratified split* agar proporsi kelas pada kedua bagian tetap merepresentasikan distribusi kelas aslinya. Data uji disisihkan sejak awal dan tidak disentuh selama proses penyeimbangan berlangsung, sehingga evaluasi dilakukan pada data yang benar-benar belum pernah dilihat oleh model.

3.2.4 Implementasi Metode HOUM dengan Variasi Oversampling dan Konfigurasi SVM

Tahap ini merupakan inti dari penelitian yang mencakup keseluruhan proses penerapan metode HOUM beserta variasi konfigurasi yang diuji. Alur implementasi secara lengkap digambarkan pada Gambar 3.2. Proses dimulai dari pembagian data, dilanjutkan dengan penerapan *undersampling* dan *oversampling* secara iteratif, hingga akhirnya dilakukan klasifikasi dan perhitungan metrik performa.



Gambar 3.2 Alur Implementasi Metode HOUM

Langkah pertama dalam implementasi adalah menggunakan data *training* yang telah dipisahkan pada tahap pengumpulan data. Sebagai *baseline*, data *training* yang belum diseimbangkan (*imbalanced*) langsung digunakan untuk melatih algoritma klasifikasi dan diuji pada data uji, sehingga diperoleh hasil performa tanpa penerapan metode HOUM sebagai pembanding.

Apabila data *training* terdeteksi tidak seimbang, proses HOUM dimulai dengan tahap *undersampling* menggunakan SVM. Pada tahap ini, SVM dilatih terlebih

dahulu untuk membentuk *decision boundary*, kemudian sampel kelas mayoritas yang berada jauh dari *hyperplane* dihapus karena dianggap kurang informatif bagi proses klasifikasi. Setiap dataset diproses dengan seluruh kombinasi parameter SVM yang diuji, yaitu enam nilai parameter regularisasi C (0,5; 1; 1,5; 2; 2,5; 3) dan tiga jenis kernel (Linear, RBF, Polynomial), sehingga menghasilkan 18 kombinasi konfigurasi *undersampling* untuk setiap dataset.

Setelah tahap *undersampling*, distribusi kelas diperiksa kembali. Apabila data masih belum seimbang, proses dilanjutkan ke tahap *oversampling*. Pada tahap ini, masing-masing data hasil *undersampling* dengan kombinasi kernel dan nilai C tertentu diproses menggunakan dua teknik *oversampling* secara terpisah, yaitu Safe-Level SMOTE sesuai metode HOUM asli dan ADASYN sebagai teknik alternatif. Dengan demikian, setiap kombinasi *undersampling* menghasilkan dua varian data yang diseimbangkan melalui teknik *oversampling* yang berbeda. Apabila setelah *oversampling* data masih belum mencapai keseimbangan, proses diulang kembali ke tahap *undersampling* secara iteratif hingga rasio antar kelas mencapai keseimbangan yang diharapkan.

Data yang sudah seimbang selanjutnya digunakan untuk melatih algoritma klasifikasi. Model yang telah dilatih kemudian diuji menggunakan data uji yang telah disisihkan pada tahap awal. Hasil pengujian dikalkulasi ke dalam metrik-metrik performa, yaitu ROC-AUC, G-mean, *Recall*, dan *Precision*. Contoh format keluaran hasil eksperimen untuk satu dataset ditunjukkan pada Tabel 3.2.

Tabel 3.2 Contoh Format Keluaran Hasil Eksperimen

Kernel	C	Tipe	ROC-AUC	Recall	Precision	G-Mean
-	-	Imbalanced	0,8118	0,5926	0,6809	0,7097
linear	0,50	Balanced	0,7956	0,6481	0,6140	0,7110
linear	1,00	Balanced	0,8264	0,6111	0,6226	0,6992
linear	1,50	Balanced	0,8081	0,6296	0,6182	0,7053
linear	2,00	Balanced	0,8035	0,6852	0,6271	0,7311
linear	2,50	Balanced	0,7969	0,6296	0,6296	0,7097
linear	3,00	Balanced	0,7912	0,6481	0,6087	0,7054

Pada tabel tersebut, baris dengan tipe *Imbalanced* menunjukkan hasil *baseline* di mana data langsung diklasifikasikan tanpa melalui proses penyeimbangan HOUM. Baris ini hanya ditampilkan satu kali karena tidak melibatkan variasi

parameter apapun. Baris dengan tipe *Balanced* menunjukkan hasil setelah data diseimbangkan menggunakan metode HOUM dengan kombinasi kernel dan nilai C yang bersangkutan. Perbandingan antara baris *Imbalanced* dan *Balanced* menunjukkan dampak penerapan HOUM terhadap performa klasifikasi pada masing-masing konfigurasi.

3.2.5 Evaluasi

Tahap evaluasi bertujuan untuk menganalisis dan membandingkan hasil metrik performa dari seluruh skenario eksperimen yang telah dijalankan. Perbandingan dilakukan dari beberapa sudut pandang, yaitu pengaruh variasi nilai parameter C terhadap performa klasifikasi pada masing-masing jenis kernel, pengaruh pemilihan jenis kernel pada setiap nilai C , serta perbandingan performa antara HOUM yang menggunakan Safe-Level SMOTE dengan HOUM yang menggunakan ADASYN. Selain itu, perbandingan antara hasil *baseline (imbalanced)* dan hasil setelah penyeimbangan (*balanced*) dilakukan untuk mengukur seberapa besar kontribusi metode HOUM dalam meningkatkan kemampuan klasifikasi kelas minoritas. Evaluasi dilakukan secara konsisten pada ketiga dataset untuk melihat apakah tren yang ditemukan bersifat umum atau spesifik terhadap karakteristik dataset tertentu.

3.2.6 Hasil dan Pembahasan

Tahap terakhir dari alur penelitian ini adalah penyajian hasil eksperimen beserta pembahasannya. Hasil performa dari seluruh kombinasi konfigurasi ditampilkan dalam bentuk tabel dan grafik perbandingan agar pola yang terbentuk dapat diamati dengan jelas. Pembahasan mencakup interpretasi terhadap temuan eksperimen, identifikasi konfigurasi HOUM yang menghasilkan performa terbaik, serta analisis mengenai mengapa konfigurasi tertentu menghasilkan performa yang lebih baik atau lebih buruk pada dataset tertentu. Temuan dari penelitian ini kemudian dibandingkan dengan hasil yang dilaporkan oleh Eroglu dan Pir (2024) untuk menilai konsistensi dan kontribusi dari variasi konfigurasi yang diuji [7]. Kesimpulan dan rekomendasi konfigurasi optimal disusun berdasarkan analisis menyeluruh terhadap seluruh hasil eksperimen.

3.3 Alat dan Bahan Tugas Akhir

Perangkat lunak yang digunakan dalam penelitian ini adalah Jupyter Notebook dengan bahasa pemrograman Python untuk implementasi metode, menjalankan eksperimen, dan melakukan pengujian terhadap hasil klasifikasi. Sedangkan bahan yang digunakan dalam penelitian ini terdiri dari tiga dataset, yaitu Pima Indians Diabetes, Haberman, dan Blood Transfusion Service Center yang diperoleh dari situs Kaggle dan UCI *Machine Learning Repository*, serta referensi jurnal dan artikel ilmiah terdahulu yang berkaitan dengan topik penelitian.

3.4 Rancangan Pengujian

Pengujian pada penelitian ini dilakukan dengan menggunakan algoritma *Random Forest* sebagai metode klasifikasi. *Random Forest* dipilih karena merupakan algoritma *ensemble learning* yang menggabungkan beberapa *decision tree* untuk menghasilkan prediksi yang lebih stabil dan akurat dibandingkan penggunaan satu *decision tree* tunggal. Algoritma ini memiliki ketahanan yang baik terhadap *overfitting* dan mampu menangani data dengan jumlah fitur yang beragam.

Model *Random Forest* dilatih menggunakan data *training* yang telah melalui proses penyeimbangan HOUM, kemudian diuji pada data uji yang telah disisihkan sejak awal. Sebagai pembanding, model juga dilatih menggunakan data *training* asli yang belum diseimbangkan (*imbalanced*) untuk mengukur kontribusi metode HOUM terhadap peningkatan performa klasifikasi.

Hasil prediksi dari model klasifikasi kemudian dievaluasi menggunakan beberapa metrik evaluasi, yaitu *Recall*, *Precision*, G-Mean, dan ROC-AUC. Metrik-metrik ini dipilih karena mampu memberikan gambaran kinerja model secara lebih komprehensif, terutama pada kasus data tidak seimbang. Penjelasan mengenai rumus dan cara kerja masing-masing metrik telah diuraikan pada Bab II bagian Metrik Evaluasi.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Deskripsi Dataset

Penelitian ini menggunakan tiga dataset benchmark yang mengacu pada penelitian Eroglu dan Pir (2024) untuk mengevaluasi performa metode HOUM [7]. Ketiga dataset dipilih karena memiliki tingkat ketidakseimbangan kelas yang berbeda, sehingga dapat merepresentasikan variasi kompleksitas dalam penanganan data tidak seimbang. Ringkasan statistik dataset disajikan pada Tabel 4.1.

Tabel 4.1 Statistik Dataset yang Digunakan

Dataset	Jumlah Data	Fitur	Mayoritas	Minoritas	Rasio
Diabetes	768	8	500 (65,10%)	268 (34,90%)	1:1,87
Transfusion	748	4	570 (76,20%)	178 (23,80%)	1:3,20
Haberman	306	3	225 (73,53%)	81 (26,47%)	1:2,78


Dataset Pima Indians Diabetes terdiri dari 768 data pasien perempuan dengan delapan fitur numerik dan target diagnosis diabetes. Kelas mayoritas berjumlah 500 data (65,10%), sedangkan kelas minoritas sebanyak 268 data (34,90%), dengan rasio ketidakseimbangan sebesar 1:1,87 yang tergolong rendah.

Dataset Blood Transfusion Service Center berisi 748 data donor dengan empat fitur utama terkait riwayat donasi. Target klasifikasi menentukan kemungkinan donor melakukan donasi kembali. Dataset ini memiliki 570 data mayoritas (76,20%) dan 178 data minoritas (23,80%), dengan rasio ketidakseimbangan sebesar 1:3,20 yang merupakan yang tertinggi di antara dataset yang digunakan.

Dataset Haberman memuat 306 data pasien kanker payudara dengan tiga fitur, yaitu usia, tahun operasi, dan jumlah kelenjar getah bening positif. Target klasifikasi menunjukkan tingkat kelangsungan hidup pasien. Dataset ini memiliki 225 data mayoritas (73,53%) dan 81 data minoritas (26,47%), dengan rasio ketidakseimbangan sebesar 1:2,78.

Distribusi kelas masing-masing dataset divisualisasikan pada Gambar 4.1 untuk

memperjelas perbandingan jumlah sampel antar kelas.



Gambar 4.1 Distribusi Kelas pada Masing-Masing Dataset

Berdasarkan Tabel 4.1 dan Gambar 4.1, seluruh dataset menunjukkan kondisi tidak seimbang dengan tingkat yang bervariasi. Dataset Diabetes memiliki tingkat *imbalance* rendah, Haberman berada pada tingkat menengah, sedangkan Transfusion menunjukkan ketidakseimbangan paling tinggi.

Selain itu, jumlah fitur pada setiap dataset berbeda, yaitu delapan fitur pada Diabetes, empat pada Transfusion, dan tiga pada Haberman. Dataset dengan jumlah fitur yang lebih sedikit berpotensi mengalami *overlap* antar kelas, sehingga meningkatkan kesulitan dalam proses klasifikasi. Variasi karakteristik ini menjadikan ketiga dataset sesuai untuk menguji performa metode HOUM pada berbagai kondisi ketidakseimbangan data.

4.2 Hasil Penelitian

Bagian ini menyajikan hasil eksperimen yang diperoleh dari penerapan metode HOUM pada ketiga dataset. Penyajian dimulai dari hasil klasifikasi pada data yang belum diseimbangkan (*baseline*) sebagai acuan perbandingan, kemudian dilanjutkan dengan hasil setelah penerapan metode HOUM dengan berbagai konfigurasi.


4.2.1 Hasil Klasifikasi pada Data Tidak Seimbang (*Baseline*)

Sebelum menerapkan metode HOUM, klasifikasi terlebih dahulu dilakukan pada data *training* yang masih dalam kondisi tidak seimbang (*imbalanced*) untuk memperoleh hasil *baseline*. Hasil *baseline* ini berfungsi sebagai titik acuan untuk mengukur seberapa besar kontribusi metode HOUM dalam meningkatkan performa klasifikasi. Model *Random Forest* dilatih menggunakan data *training* asli tanpa penyeimbangan, kemudian diuji pada data *testing* yang telah disisihkan sejak awal. Hasil metrik evaluasi *baseline* untuk ketiga dataset ditunjukkan pada Tabel 4.2.

Tabel 4.2 Hasil Klasifikasi *Baseline* pada Data Tidak Seimbang

Dataset	ROC-AUC	<i>Recall</i>	<i>Precision</i>	G-Mean
Diabetes	0,8194	0,6111	0,6471	0,7079
Transfusion	0,7523	0,4167	0,5000	0,6015
Haberman	0,5557	0,1250	0,2000	0,3213

Kurva ROC untuk masing-masing dataset pada kondisi *baseline* divisualisasikan pada Gambar 4.2 untuk menggambarkan kemampuan diskriminatif model secara visual.



Gambar 4.2 Kurva ROC *Baseline* pada Data Tidak Seimbang

Berdasarkan Tabel 4.2 dan Gambar 4.2, model *Random Forest* pada kondisi *baseline* kesulitan mengenali kelas minoritas di ketiga dataset. Pada dataset Diabetes, nilai ROC-AUC tercatat 0,8194 dan kurva ROC pada Gambar 4.2a terlihat cukup jauh dari garis diagonal, namun *Recall* hanya mencapai 0,6111 sehingga 39% pasien diabetes positif gagal terdeteksi. Dataset Transfusion menunjukkan *Recall* sebesar 0,4167 dengan ROC-AUC 0,7523, dimana kurva ROC pada Gambar 4.2b mendekat ke garis diagonal. Performa terendah terjadi pada dataset Haberman dengan ROC-AUC 0,5557 yang nyaris setara *random classifier* dan *Recall* hanya 0,1250, sebagaimana kurva ROC pada Gambar 4.2c yang hampir berhimpitan dengan garis diagonal.

Pola ini menunjukkan korelasi antara rasio ketidakseimbangan dan performa model. Dataset Diabetes dengan rasio paling rendah (1:1,87) dan delapan fitur menghasilkan kemampuan diskriminatif yang paling memadai, sedangkan Haberman dengan tiga fitur dan rasio 1:2,78 menghasilkan performa terburuk akibat potensi *overlap* antar kelas. Rendahnya *Recall* dan G-Mean pada seluruh

dataset mengindikasikan bahwa model *Random Forest* tanpa penyeimbangan data cenderung bias terhadap kelas mayoritas, sehingga memerlukan penerapan metode seperti HOUM.

4.2.2 Hasil Metode HOUM dengan Safe-Level SMOTE (HOUM-SLSMOTE)

Bagian ini menyajikan hasil klasifikasi setelah data diseimbangkan menggunakan metode HOUM dengan Safe-Level SMOTE sebagai komponen *oversampling*. Seluruh kombinasi parameter SVM (tiga jenis kernel dan enam nilai C) diuji pada masing-masing dataset. Hasil metrik evaluasi untuk setiap kombinasi konfigurasi ditampilkan pada tabel berikut, dengan nilai terbaik pada setiap metrik dicetak tebal.


4.2.2.1 Dataset Diabetes

Hasil klasifikasi HOUM-SLSMOTE pada dataset Diabetes untuk seluruh kombinasi kernel dan nilai C ditunjukkan pada Tabel 4.3.

Tabel 4.3 Hasil HOUM-SLSMOTE pada Dataset Diabetes

No	Kernel	C	ROC-AUC	Recall	Precision	G-Mean
1	Linear	0,5	0,7806	0,6481	0,5932	0,7018
2	Linear	1	0,7863	0,5926	0,6154	0,6885
3	Linear	1,5	0,7815	0,6296	0,6667	0,7229
4	Linear	2	0,7815	0,6296	0,6667	0,7229
5	Linear	2,5	0,7787	0,6111	0,6226	0,6992
6	Linear	3	0,7789	0,6481	0,6364	0,7201
7	RBF	0,5	0,8191	0,6481	0,6863	0,7379
8	RBF	1	0,8146	0,6111	0,6346	0,7036
9	RBF	1,5	0,8174	0,6481	0,6604	0,7290
10	RBF	2	0,8228	0,6481	0,6863	0,7379
11	RBF	2,5	0,8135	0,6111	0,6600	0,7122
12	RBF	3	0,8120	0,6296	0,6296	0,7097
13	Poly	0,5	0,7946	0,6111	0,6600	0,7122
14	Poly	1	0,7941	0,6111	0,6111	0,6948
15	Poly	1,5	0,7859	0,6111	0,6346	0,7036
16	Poly	2	0,7961	0,6296	0,6296	0,7097
17	Poly	2,5	0,8013	0,6111	0,6346	0,7036
18	Poly	3	0,7870	0,6111	0,6111	0,6948

Kurva ROC untuk masing-masing kernel pada dataset Diabetes ditunjukkan pada Gambar 4.3.



Gambar 4.3 Kurva ROC HOUM-SLSMOTE pada Dataset Diabetes

Berdasarkan Tabel 4.3, kernel RBF dengan $C = 2$ menghasilkan performa terbaik secara keseluruhan dengan ROC-AUC 0,8228, *Precision* 0,6863, dan G-Mean 0,7379. Nilai *Recall* tertinggi sebesar 0,6481 dicapai oleh beberapa konfigurasi kernel Linear dan RBF. Kernel RBF secara konsisten mendominasi pada dataset ini dengan ROC-AUC di atas 0,81 pada seluruh nilai C , sedangkan kernel Polynomial stabil namun di bawah RBF, dan kernel Linear mencatat ROC-AUC terendah. Dibandingkan dengan *baseline*, konfigurasi RBF $C = 2$ mempertahankan ROC-AUC sekaligus menghasilkan G-Mean 0,7379 (dari 0,7079) dan *Precision* 0,6863 (dari 0,6471).


4.2.2.2 Dataset Haberman

Hasil klasifikasi HOUM-SLSMOTE pada dataset Haberman untuk seluruh kombinasi kernel dan nilai C ditunjukkan pada Tabel 4.4.


Tabel 4.4 Hasil HOUM-SLSMOTE pada Dataset Haberman

No	Kernel	C	ROC-AUC	Recall	Precision	G-Mean
1	Linear	0,5	0,5788	0,3750	0,2500	0,4778
2	Linear	1	0,4844	0,2500	0,2222	0,4170
3	Linear	1,5	0,4844	0,2500	0,2222	0,4170
4	Linear	2	0,5707	0,3750	0,2500	0,4778
5	Linear	2,5	0,5707	0,3750	0,2500	0,4778
6	Linear	3	0,5707	0,3750	0,2500	0,4778
7	RBF	0,5	0,4810	0,1875	0,2143	0,3777
8	RBF	1	0,5421	0,0625	0,0833	0,2181
9	RBF	1,5	0,6223	0,2500	0,2667	0,4361
10	RBF	2	0,5707	0,1250	0,1429	0,3040
11	RBF	2,5	0,5557	0,2500	0,2353	0,4235
12	RBF	3	0,5082	0,1250	0,1250	0,2949
13	Poly	0,5	0,3961	0,2500	0,1538	0,3612
14	Poly	1	0,3791	0,2500	0,1481	0,3536
15	Poly	1,5	0,3791	0,2500	0,1481	0,3536
16	Poly	2	0,3791	0,2500	0,1481	0,3536
17	Poly	2,5	0,3791	0,2500	0,1481	0,3536
18	Poly	3	0,3791	0,2500	0,1481	0,3536


Kurva ROC untuk masing-masing kernel pada dataset Haberman ditunjukkan pada Gambar 4.4.



(a) Kernel Linear



(b) Kernel RBF



(c) Kernel Polynomial

Gambar 4.4 Kurva ROC HOUM-SLSMOTE pada Dataset Haberman

Berdasarkan Tabel 4.4, ROC-AUC tertinggi dicapai oleh kernel RBF dengan $C = 1,5$ sebesar 0,6223, sedangkan *Recall* (0,3750) dan G-Mean (0,4778) tertinggi diperoleh oleh kernel Linear pada $C = 0,5$; 2; 2,5; dan 3. Kernel Linear menunjukkan konsistensi yang memadai, sedangkan kernel RBF berfluktuasi dan kernel Polynomial mencatat ROC-AUC di bawah 0,40. Dibandingkan *baseline*, *Recall* naik dari 0,1250 menjadi 0,3750, namun capaian ini masih terbatas akibat tumpang tindih (*overlap*) antar kelas pada dataset dengan tiga fitur.


4.2.2.3 Dataset Transfusion

Hasil klasifikasi HOUM-SLSMOTE pada dataset Transfusion untuk seluruh kombinasi kernel dan nilai C ditunjukkan pada Tabel 4.5.

Tabel 4.5 Hasil HOUM-SLSMOTE pada Dataset Transfusion

No	Kernel	C	ROC-AUC	Recall	Precision	G-Mean
1	Linear	0,5	0,6821	0,7222	0,3939	0,6847
2	Linear	1	0,7199	0,7222	0,3939	0,6847
3	Linear	1,5	0,7167	0,6944	0,3676	0,6577
4	Linear	2	0,7197	0,7500	0,4030	0,6977
5	Linear	2,5	0,6943	0,7778	0,3836	0,6861
6	Linear	3	0,6825	0,6667	0,3582	0,6444
7	RBF	0,5	0,7024	0,7222	0,4000	0,6893
8	RBF	1	0,6933	0,6111	0,3667	0,6383
9	RBF	1,5	0,7019	0,6111	0,3929	0,6549
10	RBF	2	0,7139	0,5833	0,3889	0,6438
11	RBF	2,5	0,7267	0,6111	0,3729	0,6425
12	RBF	3	0,7102	0,6111	0,4000	0,6589
13	Poly	0,5	0,6686	0,5000	0,3158	0,5735
14	Poly	1	0,7098	0,6111	0,3607	0,6341
15	Poly	1,5	0,6884	0,6389	0,3194	0,6036
16	Poly	2	0,7091	0,6111	0,3729	0,6425
17	Poly	2,5	0,6801	0,5556	0,3636	0,6205
18	Poly	3	0,6988	0,5833	0,3559	0,6236

Kurva ROC untuk masing-masing kernel pada dataset Transfusion ditunjukkan pada Gambar 4.5.



Gambar 4.5 Kurva ROC HOUM-SLSMOTE pada Dataset Transfusion

Berdasarkan Tabel 4.5, nilai *Recall* tertinggi sebesar 0,7778 dicapai oleh kernel Linear dengan $C = 2,5$. Nilai ROC-AUC tertinggi diperoleh oleh kernel RBF dengan $C = 2,5$ sebesar 0,7267, sedangkan G-Mean tertinggi sebesar 0,6977 dan *Precision* tertinggi sebesar 0,4030 secara bersamaan dicapai oleh kernel Linear dengan $C = 2$. Kernel Linear mendominasi performa pada dataset ini karena memberikan hasil yang lebih seimbang antara *Recall* dan *Precision*, sedangkan kernel Polynomial mencatat performa paling rendah pada seluruh metrik evaluasi.

4.2.3 Hasil Metode HOUM dengan ADASYN (HOUM-ADASYN)

Bagian ini menyajikan hasil klasifikasi setelah data diseimbangkan menggunakan metode HOUM dengan ADASYN sebagai komponen *oversampling*. Seluruh kombinasi parameter SVM yang sama dengan HOUM-SLSMOTE diuji pada masing-masing dataset. Hasil metrik evaluasi untuk setiap kombinasi konfigurasi ditampilkan pada tabel berikut, dengan nilai terbaik pada setiap metrik dicetak tebal.


4.2.3.1 Dataset Diabetes

Hasil klasifikasi HOUM-ADASYN pada dataset Diabetes untuk seluruh kombinasi kernel dan nilai C ditunjukkan pada Tabel 4.6.

Tabel 4.6 Hasil HOUM-ADASYN pada Dataset Diabetes

No	Kernel	C	ROC-AUC	Recall	Precision	G-Mean
1	Linear	0,5	0,7767	0,6111	0,6111	0,6948
2	Linear	1	0,7689	0,6111	0,6735	0,7165
3	Linear	1,5	0,7889	0,6296	0,6667	0,7229
4	Linear	2	0,7889	0,6296	0,6667	0,7229
5	Linear	2,5	0,7683	0,5741	0,6458	0,6903
6	Linear	3	0,7807	0,6111	0,6346	0,7036
7	RBF	0,5	0,8093	0,6296	0,7234	0,7401
8	RBF	1	0,8122	0,5926	0,6667	0,7055
9	RBF	1,5	0,8191	0,5556	0,6122	0,6708
10	RBF	2	0,8094	0,6111	0,6346	0,7036
11	RBF	2,5	0,8033	0,6111	0,6600	0,7122
12	RBF	3	0,8102	0,5741	0,6739	0,6985
13	Poly	0,5	0,7891	0,5556	0,6667	0,6872
14	Poly	1	0,7819	0,5556	0,6977	0,6952
15	Poly	1,5	0,8052	0,6296	0,6667	0,7229
16	Poly	2	0,7878	0,6296	0,6415	0,7141
17	Poly	2,5	0,7920	0,5926	0,7273	0,7221
18	Poly	3	0,7898	0,5926	0,6154	0,6885

Kurva ROC untuk masing-masing kernel pada dataset Diabetes ditunjukkan pada Gambar 4.6.



Gambar 4.6 Kurva ROC HOUM-ADASYN pada Dataset Diabetes

Berdasarkan Tabel 4.6, kernel RBF dengan $C = 1,5$ menghasilkan ROC-AUC tertinggi sebesar 0,8191, sedangkan G-Mean 0,7401 dan *Precision* 0,7234 dicapai oleh kernel RBF dengan $C = 0,5$. Nilai *Recall* tertinggi (0,6296) diperoleh oleh beberapa konfigurasi kernel Linear, RBF, dan Polynomial. Dibandingkan HOUM-SLSMOTE, *Recall* HOUM-ADASYN (0,6296) berada di bawah HOUM-SLSMOTE (0,6481), namun *Precision* HOUM-ADASYN unggul (0,7234 berbanding 0,6863), yang menunjukkan jumlah *false positive* yang lebih sedikit.


4.2.3.2 Dataset Haberman

Hasil klasifikasi HOUM-ADASYN pada dataset Haberman untuk seluruh kombinasi kernel dan nilai C ditunjukkan pada Tabel 4.7.


Tabel 4.7 Hasil HOUM-ADASYN pada Dataset Haberman

No	Kernel	C	ROC-AUC	Recall	Precision	G-Mean
1	Linear	0,5	0,5462	0,2500	0,2353	0,4235
2	Linear	1	0,5557	0,3125	0,2778	0,4735
3	Linear	1,5	0,5557	0,3125	0,2778	0,4735
4	Linear	2	0,5421	0,3125	0,2500	0,4589
5	Linear	2,5	0,5421	0,3125	0,2500	0,4589
6	Linear	3	0,5421	0,3125	0,2500	0,4589
7	RBF	0,5	0,4817	0,1875	0,2143	0,3777
8	RBF	1	0,4966	0,1250	0,1667	0,3128
9	RBF	1,5	0,5197	0,1250	0,1667	0,3128
10	RBF	2	0,5442	0,1250	0,1667	0,3128
11	RBF	2,5	0,5346	0,1250	0,1667	0,3128
12	RBF	3	0,5183	0,1250	0,1667	0,3128
13	Poly	0,5	0,3967	0,3750	0,2000	0,4235
14	Poly	1	0,4164	0,3125	0,1852	0,4038
15	Poly	1,5	0,4164	0,3125	0,1852	0,4038
16	Poly	2	0,4164	0,3125	0,1852	0,4038
17	Poly	2,5	0,4164	0,3125	0,1852	0,4038
18	Poly	3	0,4164	0,3125	0,1852	0,4038


Kurva ROC untuk masing-masing kernel pada dataset Haberman ditunjukkan pada Gambar 4.7.



(a) Kernel Linear



(b) Kernel RBF



(c) Kernel Polynomial

Gambar 4.7 Kurva ROC HOUM-ADASYN pada Dataset Haberman

Berdasarkan Tabel 4.7, performa HOUM-ADASYN pada dataset Haberman secara keseluruhan masih rendah. ROC-AUC tertinggi sebesar 0,5557 dicapai oleh kernel Linear pada $C = 1$ dan 1,5, dengan G-Mean 0,4735 dan *Precision* 0,2778 pada konfigurasi yang sama. Kernel RBF mencatat *Recall* terendah sebesar 0,1250, mengindikasikan bahwa SVM dengan kernel RBF terlalu agresif menghapus sampel mayoritas. Dibandingkan HOUM-SLSMOTE, *Precision* HOUM-ADASYN sedikit unggul (0,2778 berbanding 0,2500) meskipun metrik lainnya relatif setara.


4.2.3.3 Dataset Transfusion

Hasil klasifikasi HOUM-ADASYN pada dataset Transfusion untuk seluruh kombinasi kernel dan nilai C ditunjukkan pada Tabel 4.8.

Tabel 4.8 Hasil HOUM-ADASYN pada Dataset Transfusion

No	Kernel	C	ROC-AUC	<i>Recall</i>	<i>Precision</i>	G-Mean
1	Linear	0,5	0,6868	0,6667	0,3636	0,6489
2	Linear	1	0,6913	0,6944	0,3472	0,6389
3	Linear	1,5	0,6809	0,6944	0,3571	0,6483
4	Linear	2	0,7004	0,6667	0,3529	0,6398
5	Linear	2,5	0,6657	0,7222	0,3377	0,6318
6	Linear	3	0,6430	0,4722	0,2787	0,5385
7	RBF	0,5	0,6741	0,5833	0,3500	0,6195
8	RBF	1	0,6887	0,6667	0,3810	0,6623
9	RBF	1,5	0,6740	0,6389	0,3770	0,6526
10	RBF	2	0,6814	0,5556	0,3279	0,5964
11	RBF	2,5	0,6938	0,5556	0,3448	0,6086
12	RBF	3	0,6930	0,6111	0,3492	0,6256
13	Poly	0,5	0,6611	0,5000	0,3214	0,5774
14	Poly	1	0,6774	0,5833	0,3559	0,6236
15	Poly	1,5	0,6854	0,5556	0,3279	0,5964
16	Poly	2	0,6788	0,5278	0,3115	0,5774
17	Poly	2,5	0,6879	0,5556	0,3226	0,5923
18	Poly	3	0,6615	0,5000	0,2951	0,5580

Kurva ROC untuk masing-masing kernel pada dataset Transfusion ditunjukkan pada Gambar 4.8.



Gambar 4.8 Kurva ROC HOUM-ADASYN pada Dataset Transfusion

Berdasarkan Tabel 4.8, ROC-AUC tertinggi sebesar 0,7004 dicapai oleh kernel Linear dengan $C = 2$, sedangkan *Recall* tertinggi 0,7222 diperoleh kernel Linear dengan $C = 2,5$. G-Mean 0,6623 dan *Precision* 0,3810 dicapai oleh kernel RBF dengan $C = 1$. Dibandingkan HOUM-SLSMOTE, seluruh nilai puncak HOUM-ADASYN berada di bawah HOUM-SLSMOTE pada *Recall* (0,7222 berbanding 0,7778), *Precision* (0,3810 berbanding 0,4030), dan G-Mean (0,6623 berbanding 0,6977).

4.2.4 Perbandingan Hasil Secara Umum

Bagian ini merangkum dan membandingkan performa dari masing-masing metode (*Baseline*, HOUM-SLSMOTE, dan HOUM-ADASYN) pada ketiga dataset. Pemilihan konfigurasi didasarkan pada metrik G-Mean sebagai metrik utama karena G-Mean merepresentasikan keseimbangan deteksi kedua kelas. Apabila nilai G-Mean antar konfigurasi berdekatan, *Recall* digunakan sebagai penentu kedua, diikuti ROC-AUC dan *Precision*. Ringkasan konfigurasi ditunjukkan pada Tabel 4.9.

Tabel 4.9 Ringkasan Performa Tiap Metode pada Setiap Dataset

Dataset	Metode	Konfigurasi	G-Mean	Recall	ROC-AUC	Prec.
Diabetes	<i>Baseline</i>	–	0,7079	0,6111	0,8194	0,6471
	HOUM-SLS	RBF, $C=2$	0,7379	0,6481	0,8228	0,6863
	HOUM-ADASYN	RBF, $C=0,5$	0,7401	0,6296	0,8093	0,7234
Haberman	<i>Baseline</i>	–	0,3213	0,1250	0,5557	0,2000
	HOUM-SLS	Linear, $C=0,5$	0,4778	0,3750	0,5788	0,2500
	HOUM-ADASYN	Linear, $C=1$	0,4735	0,3125	0,5557	0,2778
Transfusion	<i>Baseline</i>	–	0,6015	0,4167	0,7523	0,5000
	HOUM-SLS	Linear, $C=2$	0,6977	0,7500	0,7197	0,4030
	HOUM-ADASYN	RBF, $C=1$	0,6623	0,6667	0,6887	0,3810

Berdasarkan Tabel 4.9, HOUM-ADASYN terpilih pada dataset Diabetes dengan G-Mean tertinggi sebesar 0,7401, sedangkan HOUM-SLSMOTE terpilih pada dataset Haberman (G-Mean 0,4778) dan Transfusion (G-Mean 0,6977). Seluruh konfigurasi terpilih menghasilkan G-Mean dan *Recall* yang melebihi *baseline*, meskipun pada dataset Transfusion terjadi *trade-off* dimana *Precision* turun dari 0,5000 menjadi 0,4030. Kernel RBF dominan pada dataset Diabetes, sedangkan kernel Linear dominan pada Haberman dan Transfusion.

4.3 Pembahasan Penelitian

4.3.1 Analisis Dampak Penerapan HOUM pada Data Tidak Seimbang

Penerapan HOUM mengubah distribusi data *training* melalui dua tahap. Pertama, komponen *undersampling* SVM menghapus sampel kelas mayoritas yang berada jauh dari *decision boundary*. Kedua, komponen *oversampling* (Safe-Level SMOTE atau ADASYN) menambahkan sampel sintetis kelas minoritas. Perubahan distribusi ini memengaruhi keempat metrik evaluasi dengan pola yang berbeda pada setiap dataset, sebagaimana disajikan pada Tabel 4.10.

Tabel 4.10 Perbandingan Metrik Evaluasi *Baseline* dan HOUM pada Ketiga Dataset

Dataset	Metrik	Baseline	HOUM-SLS	HOUM-ADASYN
Diabetes	<i>Recall</i>	0,6111	0,6481	0,6296
	<i>Precision</i>	0,6471	0,6863	0,7234
	G-Mean	0,7079	0,7379	0,7401
	ROC-AUC	0,8194	0,8228	0,8093
Haberman	<i>Recall</i>	0,1250	0,3750	0,3125
	<i>Precision</i>	0,2000	0,2500	0,2778
	G-Mean	0,3213	0,4778	0,4735
	ROC-AUC	0,5557	0,5788	0,5557
Transfusion	<i>Recall</i>	0,4167	0,7500	0,6667
	<i>Precision</i>	0,5000	0,4030	0,3810
	G-Mean	0,6015	0,6977	0,6623
	ROC-AUC	0,7523	0,7197	0,6887

4.3.1.1 Perubahan Nilai Metrik Evaluasi

Penerapan HOUM menghasilkan dua pola perubahan metrik yang berbeda. Pola pertama terjadi pada dataset Diabetes (rasio 1:1,87, delapan fitur), di mana seluruh metrik naik secara bersamaan. *Recall* naik dari 0,6111 ke 0,6481 (HOUM-SLS) dan 0,6296 (HOUM-ADASYN); *Precision* naik ke 0,6863 dan 0,7234; G-Mean naik ke 0,7379 dan 0,7401. Kenaikan ini terjadi karena rasio ketidakseimbangan yang rendah dan delapan fitur memberikan ruang pemisahan yang cukup. HOUM menghapus sampel mayoritas tidak informatif melalui SVM dan menambahkan sampel minoritas sintetis tanpa menciptakan tumpang tindih baru yang berarti, sehingga batas keputusan bergeser menguntungkan kelas minoritas tanpa mengorbankan akurasi pada kelas mayoritas.

Pola kedua terjadi pada dataset Transfusion (rasio 1:3,20, empat fitur), di mana *Recall* dan G-Mean naik signifikan tetapi *Precision* dan ROC-AUC turun. *Recall* naik dari 0,4167 ke 0,7500 (HOUM-SLS) dan 0,6667 (HOUM-ADASYN), namun *Precision* turun dari 0,5000 ke 0,4030 dan 0,3810, serta ROC-AUC turun dari 0,7523 ke 0,7197 dan 0,6887. *Trade-off* ini muncul karena ketidakseimbangan yang tinggi memaksa batas keputusan bergeser cukup jauh untuk menangkap lebih banyak sampel kelas minoritas. Pergeseran ini memperluas area prediksi positif sehingga *false positive* bertambah, yang secara langsung menekan *Precision* dan ROC-AUC. Semakin tinggi rasio ketidakseimbangan, semakin besar pergeseran batas yang diperlukan, dan semakin besar penurunan *Precision* sebagai konsekuensinya.

Dataset Haberman (rasio 1:2,78, tiga fitur) berada di antara kedua pola tersebut. Seluruh metrik naik dari *baseline*, tetapi nilai absolutnya tetap rendah: *Recall* dari 0,1250 ke 0,3750 (HOUM-SLS), G-Mean ke 0,4778, dan ROC-AUC hanya mencapai 0,5788. Kenaikan terjadi karena HOUM mengurangi bias terhadap kelas mayoritas, namun ruang fitur yang hanya tiga dimensi menyebabkan tumpang tindih antar kelas pada *baseline*, ROC-AUC 0,5557 hampir setara *random classifier*. Dalam kondisi ini, sampel sintetis yang ditambahkan oleh *oversampling* jatuh di area yang sudah tercampur antar kelas, sehingga tidak cukup membantu model membentuk batas keputusan yang jelas antara pasien yang bertahan dan tidak bertahan hidup.

4.3.1.2 Mekanisme Kerja HOUM

Komponen *undersampling* SVM pada HOUM menghapus sampel kelas mayoritas yang berada jauh dari *decision boundary*. Proses ini mengurangi dominasi kelas mayoritas tanpa menghilangkan sampel informatif di sekitar batas keputusan, sehingga model dapat mempelajari perbedaan antar kelas dengan proporsi yang lebih seimbang. Pada sisi *oversampling*, Safe-Level SMOTE menempatkan sampel sintetis di posisi aman berdasarkan rasio keamanan terhadap tetangga dari kelas yang sama. Pendekatan ini menjauhkan sampel sintetis dari area yang didominasi kelas mayoritas, sehingga risiko menghasilkan sampel bising (*noise*) yang membingungkan model menjadi kecil. Sebaliknya, ADASYN mengalokasikan lebih banyak sampel sintetis di area yang sulit diklasifikasikan, yaitu di sekitar batas keputusan antar kelas. Pendekatan ini mendorong model untuk membentuk batas keputusan yang lebih tegas di area kritis, namun rentan terhadap *noise* apabila area tersebut sudah memiliki tumpang tindih kelas yang tinggi. Perbedaan mekanisme ini menjelaskan mengapa HOUM-SLSMOTE cenderung menghasilkan *Recall* yang lebih tinggi pada seluruh dataset, sementara HOUM-ADASYN cenderung unggul pada *Precision* di dataset tertentu.

4.3.2 Analisis Pengaruh Metode *Oversampling*

Bagian ini menganalisis pengaruh penggunaan teknik *oversampling* yang berbeda (Safe-Level SMOTE dan ADASYN) pada metode HOUM terhadap kinerja

klasifikasi. Perbandingan merujuk pada Tabel 4.10.

4.3.2.1 Perbandingan Performa antar Metode

Berdasarkan Tabel 4.10, HOUM-SLSMOTE mencatat *Recall* yang selalu di atas HOUM-ADASYN pada ketiga dataset: 0,6481 berbanding 0,6296 pada Diabetes, 0,3750 berbanding 0,3125 pada Haberman, dan 0,7500 berbanding 0,6667 pada Transfusion. Selisih *Recall* terbesar terjadi pada Transfusion (0,0833), yang menunjukkan bahwa perbedaan pengaruh kedua teknik *oversampling* semakin terlihat pada dataset dengan rasio ketidakseimbangan yang tinggi.

Pada metrik G-Mean, HOUM-ADASYN sedikit mengungguli HOUM-SLSMOTE pada dataset Diabetes (0,7401 berbanding 0,7379) dengan selisih hanya 0,0022. Pada Haberman dan Transfusion, HOUM-SLSMOTE mencatat G-Mean yang lebih tinggi (0,4778 berbanding 0,4735 pada Haberman; 0,6977 berbanding 0,6623 pada Transfusion). Pola ini menunjukkan bahwa HOUM-SLSMOTE mampu menjaga keseimbangan deteksi kedua kelas secara lebih konsisten di berbagai karakteristik dataset.

Untuk *Precision*, HOUM-ADASYN mencatat nilai yang lebih tinggi pada Diabetes (0,7234 berbanding 0,6863) dan Haberman (0,2778 berbanding 0,2500), sedangkan pada Transfusion, *Precision* HOUM-SLSMOTE di atas HOUM-ADASYN (0,4030 berbanding 0,3810). Perbedaan *Precision* ini berkaitan langsung dengan cara masing-masing teknik menyebarkan sampel sintetis di ruang fitur.

4.3.2.2 Penyebab Perbedaan Performa

Perbedaan performa kedua teknik *oversampling* disebabkan oleh mekanisme penempatan sampel sintetis yang berbeda secara mendasar. Safe-Level SMOTE menghitung rasio keamanan (*safe level ratio*) setiap sampel minoritas berdasarkan proporsi tetangga yang berasal dari kelas yang sama. Sampel sintetis ditempatkan semakin dekat dengan sampel yang memiliki rasio keamanan tinggi, yaitu sampel yang dikelilingi oleh sesama kelas minoritas. Mekanisme ini mencegah pembentukan sampel sintetis di area yang didominasi kelas mayoritas, sehingga batas keputusan yang terbentuk setelah penyeimbangan menjadi jelas dan tidak

bising. Dampaknya, model mampu mendeteksi lebih banyak sampel minoritas (*Recall* tinggi) tanpa mengorbankan kestabilan prediksi secara keseluruhan.

ADASYN menghitung bobot distribusi setiap sampel minoritas berdasarkan proporsi tetangga dari kelas mayoritas. Sampel minoritas yang dikelilingi lebih banyak oleh kelas mayoritas (area batas keputusan) mendapatkan alokasi sampel sintetis yang lebih besar. Pendekatan ini mendorong batas keputusan untuk bergeser ke area yang sulit, sehingga model dapat memisahkan kelas dengan lebih tegas di area kritis. Pada dataset Diabetes yang memiliki delapan fitur dan batas kelas yang relatif jelas, fokus ADASYN pada area batas justru memperkuat batasan model sehingga *Precision* dan G-Mean tercatat lebih tinggi. Namun, pada dataset dengan tumpang tindih kelas yang tinggi seperti Haberman dan Transfusion, penambahan sampel sintetis di area batas yang sudah bising menyebabkan model sulit membedakan kelas, sehingga *Recall* dan G-Mean turun dibandingkan HOUM-SLSMOTE.

4.3.2.3 Implikasi terhadap Pemilihan Metode

Temuan ini menunjukkan bahwa pemilihan teknik *oversampling* pada HOUM perlu mempertimbangkan karakteristik dataset. Pada dataset dengan tumpang tindih kelas yang tinggi dan fitur yang terbatas (seperti Haberman dan Transfusion), HOUM-SLSMOTE memberikan kestabilan yang lebih memadai karena sampel sintetis ditempatkan di area aman yang tidak menciptakan *noise* tambahan. Pada dataset dengan fitur yang cukup dan batas kelas yang relatif jelas (seperti Diabetes), HOUM-ADASYN mampu memanfaatkan fokusnya pada area batas untuk memperkuat batasan model, yang terlihat dari G-Mean (0,7401) dan *Precision* (0,7234) yang lebih tinggi dibandingkan HOUM-SLSMOTE. Pemilihan teknik *oversampling* yang tidak sesuai dengan karakteristik data dapat menurunkan performa klasifikasi, sebagaimana terlihat pada penurunan G-Mean HOUM-ADASYN di Transfusion dari 0,6977 (HOUM-SLS) menjadi 0,6623.

4.3.3 Analisis Pengaruh Kernel SVM

Bagian ini menganalisis pengaruh pemilihan jenis kernel SVM pada komponen *undersampling* HOUM terhadap kinerja klasifikasi. Kernel SVM menentukan

bentuk batas keputusan yang digunakan untuk mengidentifikasi sampel kelas mayoritas yang akan dihapus, sehingga pemilihan kernel yang sesuai dengan karakteristik dataset memengaruhi kualitas data *training* dan performa akhir model.

Hasil eksperimen menunjukkan bahwa kernel yang menghasilkan G-Mean tertinggi bergantung pada dimensi dataset. Pada dataset Diabetes (delapan fitur), kernel RBF tercatat memiliki G-Mean tertinggi 0,7401 (HOUM-ADASYN, $C=0,5$) dan 0,7379 (HOUM-SLS, $C=2$). Nilai *Precision* kernel RBF mencapai 0,7234, jauh di atas kernel Linear yang hanya 0,6667 pada konfigurasi terbaiknya. Kernel RBF memetakan data ke dimensi yang lebih tinggi melalui fungsi Gaussian sehingga mampu memisahkan kelas yang tidak terpisahkan secara linear pada delapan fitur dataset ini. Pada dataset Haberman (tiga fitur) dan Transfusion (empat fitur), kernel Linear menghasilkan G-Mean tertinggi: 0,4778 (HOUM-SLS, $C=0,5$) pada Haberman dan 0,6977 (HOUM-SLS, $C=2$) pada Transfusion. Sebagai perbandingan, kernel RBF hanya mencapai G-Mean 0,4361 dan 0,6893 pada dataset yang sama. Pada Haberman, *Recall* kernel Linear mencapai 0,3750 sedangkan kernel RBF hanya 0,2500. Dataset dengan tiga hingga empat fitur sudah dapat dipisahkan oleh hyperplane linear tanpa perlu pemetaan ke dimensi yang lebih tinggi. Sebaliknya, kernel RBF pada ruang fitur rendah justru menangkap variasi lokal yang tidak relevan sehingga batas keputusan yang dihasilkan kurang stabil untuk proses *undersampling*.

Kernel Polynomial mencatat performa terendah pada hampir seluruh dataset. Pada Haberman, G-Mean hanya 0,4235 (HOUM-ADASYN, $C=0,5$) dengan ROC-AUC 0,3967; pada Transfusion, G-Mean hanya 0,6341 (HOUM-SLS, $C=1$); pada Diabetes, G-Mean 0,7229 (HOUM-ADASYN, $C=1,5$) setara kernel Linear namun di bawah RBF. Kernel Polynomial cenderung mengalami *overfitting* karena membentuk batas keputusan yang terlalu rumit, terutama pada dataset dengan tumpang tindih kelas yang tinggi.

Temuan ini menunjukkan bahwa dimensi dataset menentukan kernel SVM yang sesuai pada HOUM. Dataset dengan delapan fitur (Diabetes) memerlukan kernel RBF untuk menangani hubungan non-linear antar fitur. Dataset dengan tiga hingga empat fitur (Haberman, Transfusion) cukup ditangani kernel Linear tanpa

kehilangan performa. Kernel Polynomial tidak direkomendasikan karena secara konsisten mencatat performa di bawah Linear dan RBF pada seluruh dataset yang diuji.

4.3.4 Analisis Pengaruh Parameter C

Parameter regularisasi C pada komponen *undersampling* SVM menentukan tingkat toleransi terhadap kesalahan klasifikasi. Nilai ini secara langsung memengaruhi bentuk batas keputusan dan lebar *margin*. Dalam metode HOUM, batas keputusan menjadi acuan utama untuk menghapus sampel kelas mayoritas. Sampel yang berada jauh dari batas keputusan dianggap kurang informatif dan akan dihapus dari dataset. Oleh karena itu, pemilihan nilai C menentukan kualitas dan jumlah data kelas mayoritas yang dihilangkan.

Pada dataset Diabetes (delapan fitur), nilai $C = 0,5$ pada kernel RBF menghasilkan G-Mean tertinggi, yaitu 0,7401 pada HOUM-ADASYN dan 0,7379 pada HOUM-SLSMOTE. Ketika C dinaikkan ke 1, G-Mean pada kernel RBF turun menjadi 0,7055 (HOUM-ADASYN) dan 0,7036 (HOUM-SLSMOTE). Pada nilai C yang rendah, SVM membentuk *margin* yang lebar sehingga batas keputusan bersifat umum. *Margin* yang lebar ini menempatkan lebih banyak sampel mayoritas di luar batas, sehingga lebih banyak sampel dihapus oleh komponen *undersampling*. Saat C dinaikkan, *margin* menyempit dan batas keputusan menjadi lebih ketat mengikuti data *training*. Akibatnya, lebih sedikit sampel mayoritas yang dianggap berada di luar batas, sehingga lebih sedikit yang dihapus. Pengurangan jumlah penghapusan ini melemahkan efek penyeimbangan HOUM dan menurunkan G-Mean.

Pada dataset Haberman (tiga fitur), nilai C memengaruhi kestabilan posisi *hyperplane* pada ruang fitur berdimensi rendah. G-Mean puncak 0,4778 dicapai pada $C = 0,5$ serta $C \geq 2$, namun menurun menjadi 0,4170 pada rentang $C = 1$ hingga $C = 1,5$. Hal ini menunjukkan bahwa pada nilai C menengah, batas keputusan linear sangat sensitif terhadap tumpang tindih data. Kondisi tersebut menyebabkan posisi *hyperplane* bergeser secara tidak optimal sehingga proses *undersampling* menghapus sampel mayoritas yang memiliki informasi penting untuk memisahkan kelas. Kestabilan penghapusan hanya kembali tercapai pada $C = 0,5$

melalui *margin* yang lebar atau pada $C \geq 2$ melalui batasan yang lebih tegas.

Pada dataset Transfusion (empat fitur), nilai C yang lebih tinggi memberikan efek yang berbeda dari Diabetes karena titik awal nilai C yang sudah besar. Peningkatan C dari 2 ke 2,5 pada HOUM-SLSMOTE menaikkan *Recall* dari 0,7500 ke 0,7778, namun menurunkan G-Mean dari 0,6977 ke 0,6861 dan *Precision* dari 0,4030 ke 0,3836. Pada $C = 2$, *margin* sudah cukup sempit sehingga proses *undersampling* menghapus sampel mayoritas dalam jumlah yang optimal. Ketika C dinaikkan ke 2,5, *margin* semakin menyempit dan batas keputusan menangkap variasi lokal pada data *training*. Akibatnya, lebih banyak sampel mayoritas yang dihapus, termasuk sampel yang sebenarnya informatif untuk membedakan kelas. Penghapusan berlebih ini memang menaikkan *Recall* karena distribusi kelas menjadi lebih condong ke minoritas, tetapi *Precision* turun karena model kehilangan informasi penting tentang batas kelas mayoritas. Efek ini semakin terlihat pada $C = 3$ di mana *Recall* turun drastis ke 0,6667 dan G-Mean ke 0,6444, menunjukkan bahwa *undersampling* sudah terlalu agresif dan merusak struktur data asli.

Secara keseluruhan, pengaruh parameter C terhadap HOUM bergantung pada rentang nilai yang digunakan. Pada rentang C rendah (0,5 hingga 1,5), *margin* yang lebar menguntungkan karena lebih banyak sampel mayoritas dihapus dan penyeimbangan lebih efektif. Pada rentang C tinggi (di atas 2,0), *margin* sudah cukup sempit sehingga kenaikan C lebih lanjut justru menyebabkan penghapusan berlebih yang menurunkan *Precision* dan G-Mean. Pola ini konsisten pada seluruh dataset: nilai C optimal untuk Diabetes dan Haberman berada di 0,5, sedangkan untuk Transfusion berada di 2,0 yang merupakan titik keseimbangan antara *Recall* dan *Precision* pada dataset dengan ketidakseimbangan tinggi.

4.3.5 Rekomendasi Konfigurasi HOUM

Berdasarkan seluruh analisis sebelumnya, konfigurasi terbaik untuk setiap dataset ditentukan berdasarkan kombinasi teknik *oversampling*, kernel SVM, dan nilai C yang menghasilkan G-Mean tertinggi. Ringkasan konfigurasi terbaik disajikan pada Tabel 4.11.

Tabel 4.11 Rekomendasi Konfigurasi HOUM Berdasarkan G-Mean Tertinggi

Dataset	Oversampling	Kernel	C	G-Mean	Recall	ROC-AUC	Prec.
Diabetes	HOUM-ADASYN	RBF	0,5	0,7401	0,6296	0,8093	0,7234
Haberman	HOUM-SLSMOTE	Linear	0,5	0,4778	0,3750	0,5788	0,2500
Transfusion	HOUM-SLSMOTE	Linear	2	0,6977	0,7500	0,7197	0,4030

4.3.5.1 Alasan Pemilihan Oversampling

Pada dataset Diabetes, ADASYN terpilih karena menghasilkan G-Mean 0,7401. Nilai ini hanya berselisih 0,0022 dari Safe-Level SMOTE (0,7379) sehingga selisihnya tipis. Keunggulan ADASYN berasal dari *Precision* yang lebih tinggi (0,7234 berbanding 0,6863 pada Safe-Level SMOTE). Dataset Diabetes memiliki delapan fitur yang memberikan ruang pemisahan yang cukup, sehingga data sintetis yang ditempatkan di sekitar batas keputusan oleh ADASYN tidak memperbutuk tumpang tindih antar kelas.

Pada Haberman dan Transfusion, Safe-Level SMOTE terpilih. Kedua dataset hanya memiliki tiga dan empat fitur, sehingga tumpang tindih antar kelas menjadi tinggi. Pada Transfusion, *Recall* ADASYN hanya mencapai 0,6667, turun dari 0,7500 pada Safe-Level SMOTE. Data sintetis ADASYN yang dikonsentrasikan di area dengan campuran kedua kelas justru menambah tumpang tindih alih-alih memperjelas batas keputusan. Safe-Level SMOTE membatasi penempatan data sintetis pada area yang didominasi tetangga sekelas sehingga tidak memperburuk tumpang tindih yang sudah ada.

4.3.5.2 Alasan Pemilihan Kernel

Kernel RBF terpilih pada Diabetes karena seluruh konfigurasi RBF mencatat ROC-AUC di atas 0,80 dan G-Mean di atas 0,70 pada kedua metode *oversampling*. Tidak ada konfigurasi Linear maupun Polynomial pada Diabetes yang mampu melampaui capaian tersebut.

Kernel Linear terpilih pada Haberman dan Transfusion. Pada Haberman, *Recall* tertinggi kernel Linear mencapai 0,3750, sedangkan kernel RBF hanya 0,2500. Pada Transfusion, G-Mean tertinggi kernel Linear sebesar 0,6977 melampaui G-Mean tertinggi kernel RBF sebesar 0,6893. Kernel Linear sudah cukup untuk memisahkan

kelas pada dataset dengan tiga dan empat fitur, dan hasil pengujian menunjukkan kernel ini lebih stabil pada dataset berdimensi rendah.

Kernel Polynomial tidak terpilih di seluruh dataset karena performanya secara konsisten berada di bawah Linear dan RBF. Pada Haberman, ROC-AUC kernel Polynomial hanya berkisar 0,38–0,40, menunjukkan bahwa bentuk batas keputusan polinomial mengalami *overfitting* pada data dengan tumpang tindih tinggi.

4.3.5.3 Alasan Pemilihan Nilai C

Pada Diabetes dengan HOUM-ADASYN, nilai parameter $C = 0,5$ menghasilkan G-Mean 0,7401 dimana nilai tertinggi di antara seluruh nilai parameter C lainnya pada konfigurasi ADASYN. Ketika nilai parameter C dinaikkan ke 1,5 pada kernel RBF, ROC-AUC memang meningkat ke 0,8191, namun *Recall* turun ke 0,5556 dan G-Mean turun ke 0,6708. Hal ini menunjukkan bahwa nilai parameter C yang lebih tinggi memperketat batas keputusan dan justru mengurangi deteksi kelas minoritas.

Pada Haberman dengan HOUM-SLSMOTE, nilai parameter $C = 0,5$ pada kernel Linear menghasilkan G-Mean 0,4778 yang setara dengan $C \geq 2$. Karena nilai parameter $C = 0,5$ sudah mencapai puncak performa, tidak diperlukan nilai parameter C yang lebih tinggi untuk dataset ini.

Pada Transfusion dengan HOUM-SLSMOTE, nilai parameter $C = 2$ menghasilkan G-Mean 0,6977 dimana nilai tertinggi di antara seluruh nilai parameter C lainnya pada konfigurasi ADASYN. Pada nilai parameter $C = 2,5$, *Recall* memang naik menjadi 0,7778, namun *Precision* turun menjadi 0,3836 dan G-Mean turun menjadi 0,6861. Nilai parameter $C = 2$ dipilih karena memberikan keseimbangan terbaik antara *Recall* (0,7500) dan *Precision* (0,4030) tanpa mengorbankan G-Mean.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil eksperimen dan analisis yang telah dilakukan, diperoleh beberapa kesimpulan sebagai berikut:

1. Pengaruh teknik *oversampling* pada metode HOUM terhadap kinerja klasifikasi:
 - a. HOUM-SLSMOTE menghasilkan *recall* yang selalu di atas HOUM-ADASYN pada ketiga dataset: 0,6481 berbanding 0,6296 pada Diabetes, 0,3750 berbanding 0,3125 pada Haberman, dan 0,7500 berbanding 0,6667 pada Transfusion. Selisih terbesar terjadi pada Transfusion (0,0833), yang menunjukkan bahwa Safe-Level SMOTE lebih stabil dalam meningkatkan deteksi kelas minoritas pada dataset dengan ketidakseimbangan tinggi. Safe-Level SMOTE membatasi data sintesis pada area yang didominasi tetangga sekelas sehingga tidak menambah tumpang tindih yang sudah ada.
 - b. HOUM-ADASYN unggul pada *precision* di Diabetes (0,7234) dan Haberman (0,2778) berbanding Safe-Level SMOTE (0,6863 dan 0,2500). Namun, pada Transfusion, *precision* ADASYN justru lebih rendah (0,3810 berbanding 0,4030) dan *recall*-nya turun dari 0,7500 menjadi 0,6667. Penurunan ini terjadi karena ADASYN menempatkan data sintesis di area dengan campuran kedua kelas, yang pada dataset dengan tumpang tindih tinggi justru memperburuk pemisahan. Tidak terdapat teknik *oversampling* yang mutlak unggul karena efektivitasnya bergantung pada dimensi dan tingkat tumpang tindih dataset.
2. Pengaruh variasi parameter C dan jenis kernel SVM terhadap kinerja HOUM:
 - a. Nilai $C = 0,5$ menghasilkan G-Mean tertinggi pada Diabetes (0,7401) dan Haberman (0,4778). Pada C rendah, *margin* SVM yang lebar

menempatkan lebih banyak sampel mayoritas di luar batas keputusan, sehingga lebih banyak sampel dihapus oleh komponen *undersampling*. Pada Diabetes, kenaikan C dari 0,5 ke 1 pada kernel RBF menurunkan G-Mean dari 0,7401 ke 0,7055 karena *margin* yang menyempit mengurangi jumlah sampel mayoritas yang dihapus.

- b. Pada Transfusion, $C = 2$ memberikan G-Mean tertinggi (0,6977) dengan *recall* 0,7500. Kenaikan C ke 2,5 memang menaikkan *recall* menjadi 0,7778, namun G-Mean turun menjadi 0,6861 dan *precision* turun menjadi 0,3836. Pada rentang C yang sudah tinggi, *margin* yang semakin sempit menyebabkan penghapusan berlebih, yaitu sampel mayoritas yang informatif turut terhapus sehingga model kehilangan informasi tentang batas kelas mayoritas. Efek ini semakin parah pada $C = 3$ di mana *recall* turun drastis ke 0,6667.
 - c. Kernel RBF mencatat performa tertinggi pada Diabetes (delapan fitur) dengan seluruh konfigurasi RBF memiliki ROC-AUC di atas 0,80 dan G-Mean di atas 0,70, sementara kernel Linear hanya mencapai G-Mean 0,7229. Kernel Linear unggul pada Haberman (tiga fitur) dan Transfusion (empat fitur) dengan G-Mean 0,4778 dan 0,6977. Kernel Polynomial mencatat performa terendah di seluruh dataset, di mana pada Haberman ROC-AUC kernel Polynomial hanya 0,38–0,40 yang menunjukkan *overfitting* pada data dengan tumpang tindih tinggi.
3. Kinerja metode HOUM dalam menangani data tidak seimbang:
- a. HOUM meningkatkan *recall* dan G-Mean pada seluruh dataset dibandingkan *baseline*. Pada Haberman, *recall* naik dari 0,1250 menjadi 0,3750; pada Transfusion, dari 0,4167 menjadi 0,7500. Pada Diabetes, seluruh metrik naik serempak karena rasio ketidakseimbangan rendah (1:1,87) dan delapan fitur memberikan ruang pemisahan cukup. Sebaliknya, pada Transfusion (rasio 1:3,20), kenaikan *recall* disertai penurunan *precision* dari 0,5000 ke 0,4030 dan ROC-AUC dari 0,7523 ke 0,7197. Semakin tinggi rasio ketidakseimbangan, semakin besar pergeseran batas keputusan yang diperlukan untuk menangkap

kelas minoritas, dan semakin besar penurunan *precision* sebagai konsekuensinya. Pemilihan konfigurasi HOUM perlu menyesuaikan tujuan: jika prioritas adalah mendeteksi sebanyak mungkin kelas minoritas, Safe-Level SMOTE dengan C rendah lebih sesuai; jika keseimbangan *recall* dan *precision* diutamakan, ADASYN pada dataset dengan fitur memadai dapat dipertimbangkan.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran untuk pengembangan penelitian selanjutnya:

1. Menggunakan dataset dengan dimensi fitur lebih tinggi dan kompleksitas lebih beragam untuk menguji konsistensi kernel RBF pada ruang fitur berdimensi tinggi.
2. Memperluas rentang nilai C ke bawah 0,5 untuk menganalisis pengaruh *margin* yang lebih longgar terhadap proses *undersampling*.
3. Membandingkan teknik *oversampling* lain seperti *Borderline-SMOTE* dengan Safe-Level SMOTE dan ADASYN dalam kerangka HOUM.
4. Menguji HOUM dengan algoritma klasifikasi lain seperti *Gradient Boosting* atau *Neural Network* untuk mengukur konsistensi peningkatan performa di berbagai model.
5. Mengeksplorasi parameter tambahan SVM seperti *gamma* pada kernel RBF untuk mengoptimalkan *undersampling*.
6. Menambah jumlah dan variasi rasio ketidakseimbangan dataset untuk mengevaluasi generalisasi HOUM secara lebih menyeluruh.

DAFTAR PUSTAKA

- [1] Haibo He and Edwardo A. Garcia. “Learning from Imbalanced Data”. *IEEE Transactions on Knowledge and Data Engineering* 21.9 (2009), pp. 1263–1284.
- [2] Bartosz Krawczyk. “Learning from Imbalanced Data: Open Challenges and Future Directions”. *Progress in Artificial Intelligence* 5.4 (2016), pp. 221–232.
- [3] Guodong Hou et al. “Comparative Analysis of Resampling Techniques for Class Imbalance in Financial Distress Prediction Using XGBoost”. *Mathematics* 13.7 (2025), p. 1159.
- [4] Lucky Lhaura Van FC et al. “Enhancing Machine Learning Model Performance in Addressing Class Imbalance”. *CogITO Smart Journal* 10.1 (2024), pp. 478–490.
- [5] Nitesh V. Chawla et al. “SMOTE: Synthetic Minority Over-sampling Technique”. *Journal of Artificial Intelligence Research* 16 (2002), pp. 321–357.
- [6] Chumphol Bunkhumpornpat, Krung Sinapiromsaran, and Chidchanok Lursinsap. “Safe-Level-SMOTE: Safe-Level-Synthetic Minority Over-Sampling TEchnique for Handling the Class Imbalanced Problem”. *Advances in Knowledge Discovery and Data Mining (PAKDD 2009)*. Vol. 5476. Lecture Notes in Computer Science. Springer, 2009, pp. 475–482.
- [7] Duygu Yilmaz Eroglu and Mestan Sahin Pir. “Hybrid Oversampling and Undersampling Method (HOUM) via Safe-Level SMOTE and Support Vector Machine”. *Applied Sciences* 14.22 (2024), p. 10438.
- [8] Jair Cervantes et al. “A Comprehensive Survey on Support Vector Machine Classification: Applications, Challenges and Trends”. *Neurocomputing* 408 (2020), pp. 189–215.

- [9] Haibo He et al. “ADASYN: Adaptive Synthetic Sampling Approach for Imbalanced Learning”. *Proceedings of the IEEE International Joint Conference on Neural Networks (IJCNN)*. IEEE, 2008, pp. 1322–1328.
- [10] Salimkan Fatma Taskiran et al. “A Comprehensive Evaluation of Oversampling Techniques for Enhancing Text Classification Performance”. *Scientific Reports* 15 (2025).
- [11] Muhammad Arham Tariq et al. “Comparing Different Oversampling Methods in Predicting Multi-Class Educational Datasets Using Machine Learning”. *Cybernetics and Information Technologies* 23.4 (2023), pp. 21–40.
- [12] Iqbal H. Sarker. “Machine Learning: Algorithms, Real-World Applications and Research Directions”. *SN Computer Science* 2.3 (2021), p. 160.
- [13] Raghad Mohammed, Jamal Rawashdeh, and Malak Abdullah. “Machine Learning with Oversampling and Undersampling Techniques: Overview Study and Experimental Results”. *Proceedings of the 11th International Conference on Information and Communication Systems (ICICS)*. IEEE, 2020, pp. 243–248.
- [14] Dakhaz Mustafa Abdullah and Adnan Mohsin Abdulazeez. “Machine Learning Applications based on SVM Classification: A Review”. *Qubahan Academic Journal* 1.2 (2021), pp. 81–90.
- [15] Fadi Thabtah et al. “Data Imbalance in Classification: Experimental Evaluation”. *Information Sciences* 513 (2020), pp. 429–441.
- [16] Guo Haixiang et al. “Learning from Class-Imbalanced Data: Review of Methods and Applications”. *Expert Systems with Applications* 73 (2017), pp. 220–239.
- [17] Tom Fawcett. “An Introduction to ROC Analysis”. *Pattern Recognition Letters* 27.8 (2006), pp. 861–874.
- [18] György Kovács. “An Empirical Comparison and Evaluation of Minority Oversampling Techniques on a Large Number of Imbalanced Datasets”. *Applied Soft Computing* 83 (2019), p. 105662.

- [19] György Kovács. “smote-variants: A Python Implementation of 85 Minority Oversampling Techniques”. *Neurocomputing* 366 (2019), pp. 352–354.
- [20] Dina Elreedy, Amir F. Atiya, and Firuz Kamalov. “A Comprehensive Analysis of Synthetic Minority Oversampling Technique (SMOTE) and Its Extensions”. *Information Sciences* 643 (2023), p. 119205.
- [21] Hui Han, Wen-Yuan Wang, and Bing-Huan Mao. “Borderline-SMOTE: A New Over-Sampling Method in Imbalanced Data Sets Learning”. *Proceedings of the International Conference on Intelligent Computing (ICIC)*. Vol. 3644. Lecture Notes in Computer Science. Springer, 2005, pp. 878–887.
- [22] Ahmad S. Tarawneh et al. “SMOTEFUNA: Synthetic Minority Over-Sampling Technique Based on Furthest Neighbour Algorithm”. *IEEE Access* 10 (2022), pp. 59891–59913.
- [23] Gustavo E. A. P. A. Batista, Ronaldo C. Prati, and Maria-Carolina Monard. “A Study of the Behavior of Several Methods for Balancing Machine Learning Training Data”. *ACM SIGKDD Explorations Newsletter* 6.1 (2004), pp. 20–29.
- [24] Salim Rezvani et al. “Methods for Class-Imbalanced Learning with Support Vector Machines: A Review and an Empirical Evaluation”. *Neural Computing and Applications* 36 (2024), pp. 123–158.
- [25] Yuchun Tang et al. “SVMs Modeling for Highly Imbalanced Classification”. *IEEE Transactions on Systems, Man, and Cybernetics, Part B (Cybernetics)* 39.1 (2009), pp. 281–288.
- [26] Marina Sokolova and Guy Lapalme. “A Systematic Analysis of Performance Measures for Classification Tasks”. *Information Processing & Management* 45.4 (2009), pp. 427–437.
- [27] Amalia Luque et al. “The Impact of Class Imbalance in Classification Performance Metrics Based on the Binary Confusion Matrix”. *Pattern Recognition* 91 (2019), pp. 216–231.

- [28] Margherita Grandini, Enrico Bagli, and Giorgio Visani. “Metrics for Multi-Class Classification: An Overview”. *arXiv preprint arXiv:2008.05756* (2020).
- [29] Davide Chicco and Giuseppe Jurman. “The Matthews Correlation Coefficient (MCC) is More Reliable Than Balanced Accuracy, Bookmaker Informedness, and Markedness in Two-Class Confusion Matrix Evaluation”. *BioData Mining* 16.1 (2023), pp. 1–23.

LAMPIRAN